

פתרון שאלה מס' 1: רגולריזציית Dropout (35%)

א. נחשב:

$$E[D_{ii}^{(n)}] = \frac{1}{1-p_i} [1 \cdot (1-p_i) + 0 \cdot p_i] = 1$$

בנוסף

$$E\left[\left(D_{ii}^{(n)}\right)^2\right] = \frac{1}{(1-p_i)^2} (p_i \cdot 0 + (1-p_i) \cdot 1) = \frac{1}{1-p_i}$$

ולכן

$$E[D_{ii}^{(n)} D_{jj}^{(n)}] = \begin{cases} E[D_{ii}^{(n)}] E[D_{jj}^{(n)}] & i \neq j \\ E\left[\left(D_{ii}^{(n)}\right)^2\right] & i = j \end{cases}$$

$$\Rightarrow E[D_{ii}^{(n)} D_{jj}^{(n)}] = \frac{1}{1-p_i} \frac{1}{1-p_j} \left[(1-p_i)(1-p_j) + \delta_{ij} \left((1-p_i) - (1-p_i)^2 \right) \right]$$

$$= 1 + \delta_{ij} \left(\frac{1}{1-p_i} - 1 \right) = 1 + \delta_{ij} \frac{p_i}{1-p_i}$$

ב. נחשב את הממוצע

$$E\mathcal{L}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N E \left(y^{(n)} - \mathbf{w}^T \mathbf{D}^{(n)} \mathbf{x}^{(n)} \right)^2$$

$$= \frac{1}{2} \sum_{n=1}^N E \left(\left(y^{(n)} \right)^2 - 2y^{(n)} \sum_{i=1}^d w_i D_{ii}^{(n)} x_i^{(n)} + \left(\sum_{i=1}^d w_i D_{ii}^{(n)} x_i^{(n)} \right)^2 \right)$$

$$= \frac{1}{2} \sum_{n=1}^N \left(\left(y^{(n)} \right)^2 - 2y^{(n)} \sum_{i=1}^d w_i E[D_{ii}^{(n)}] x_i^{(n)} + \sum_{i=1}^d \sum_{j=1}^d w_i w_j x_i^{(n)} x_j^{(n)} E[D_{ii}^{(n)} D_{jj}^{(n)}] \right)$$

$$= \frac{1}{2} \sum_{n=1}^N \left(\left(y^{(n)} \right)^2 - 2y^{(n)} \sum_{i=1}^d w_i E[D_{ii}^{(n)}] x_i^{(n)} + \sum_{i=1}^d \sum_{j=1}^d w_i w_j x_i^{(n)} x_j^{(n)} \left(1 + \delta_{ij} \frac{p_i}{1-p_i} \right) \right)$$

$$= \frac{1}{2} \sum_{n=1}^N \left(\left(y^{(n)} \right)^2 - 2y^{(n)} \sum_{i=1}^d w_i x_i^{(n)} + \sum_{i=1}^d \sum_{j=1}^d w_i w_j x_i^{(n)} x_j^{(n)} + \sum_{i=1}^d \sum_{j=1}^d \frac{p_i}{1-p_i} w_i w_j x_i^{(n)} x_j^{(n)} \delta_{ij} \right)$$

$$= \frac{1}{2} \sum_{n=1}^N \left(\left(y^{(n)} \right)^2 - 2y^{(n)} \sum_{i=1}^d w_i x_i^{(n)} + \sum_{i=1}^d \sum_{j=1}^d w_i w_j x_i^{(n)} x_j^{(n)} + \sum_{i=1}^d \frac{p_i}{1-p_i} w_i^2 \left(x_i^{(n)} \right)^2 \right)$$

$$= \frac{1}{2} \sum_{n=1}^N \left(y^{(n)} - \mathbf{w}^T \mathbf{x}^{(n)} \right)^2 + \frac{1}{2} \sum_{i=1}^d \frac{p_i}{1-p_i} w_i^2 \sum_{n=1}^N \left(x_i^{(n)} \right)^2$$

ג. קיבלנו תוספת רגולריזציית L2 עם משקל שונה לכל רכיב. הרגולריזציה תהיה גבוהה יותר ככל ש- p_i

גדול יותר, כלומר רכיבים i בעלי הסתברות גבוהה לאיפוס יתנו w_i קטן יותר. בנוסף הרגולריזציה חזקה

יותר ולכן w_i קטן יותר ככל שהמומנט השני של הכניסה $\sum_{n=1}^N \left(x_i^{(n)} \right)^2$ גדול יותר.

ד. נציע למשל סיגמואיד $f(u) = \frac{1}{1+e^{-u}}$, כאשר כמו בפונקציות אקטיבציה, הפונקציה מופעלת רכיב-רכיב.

ה. לא. קל לראות כי גם הפתרון הדליל w_0 וגם הלא דליל w_* מאפסים (ומביאים למינימום) את $\bar{\mathcal{L}}(w, p)$ עבור $p=0$, ולכן לא בהכרח נקבל את הפתרון הדליל.

ו. כפי שנתון

$$\bar{\mathcal{L}}(w, p) = \frac{1}{2} \sum_{n=1}^N \left(y^{(n)} - w^T x^{(n)} \right)^2 + \frac{1}{2} \sum_{i=1}^d \frac{1}{1-p_i} w_i^2 c_i + \mu \sum_{i=1}^d (1-p_i)$$

נגזור לפי p_i ונשווה לאפס:

$$\frac{1}{2} \frac{1}{(1-p_i)^2} w_i^2 c_i - \mu = 0 \Rightarrow \frac{1}{(1-p_i)^2} = \frac{2\mu}{w_i^2 c_i} \Rightarrow 1-p_i = |w_i| \sqrt{\frac{c_i}{2\mu}}$$

נציב פתרון זה ב- $\bar{\mathcal{L}}(w, p)$ ונקבל:

$$\bar{\mathcal{L}}(w) = \frac{1}{2} \sum_{n=1}^N \left(y^{(n)} - w^T x^{(n)} \right)^2 + \sum_{i=1}^d \sqrt{2\mu c_i} |w_i|$$

קיבלנו רגולריזציית L1 (ממושקלת) ישירות על w , מה שמעודד בחירת מאפיינים כפי שלמדנו בהרצאה.

הערה: שימו לב שבסעיף זה, בניגוד לקודמים, הנחנו ש- $p \in \mathbb{R}^d$, במקום ש- $p \in [0,1]^d$ כפי שהיה צריך להניח. זה היה כדי להקל את החישוב (ומכיוון שלא בהכרח למדתם כיצד לפתור את הבעיה עם האילוצים).

ז. כאן צריך היה להזכיר הרחבות כמו dropconnect, dropblock, או stochastic depth. ולתת הסבר מההרצאה.

פתרון שאלה מס' 2: השפעה של רגולריזציה L2 בנירון בודד (25%)

א. ניתן לרשום את הביטוי לשגיאה כ:

$$\mathcal{L}(\mathbf{w}) = \frac{1}{2} \sum_{i=1}^d (1 - \eta(\lambda_i + \mu))^{2t} (\lambda_i + \mu) z_i^2(0)$$

מכיוון שזהו סכום של איברים שדועכים אקספוננציאלית, עבור $t \gg 1$ הסכום ישלט ע"י האיברים שדועכים הכי לאט בסכום, כלומר האיבר הניתן ע"י קצב ההתכנסות

$$\text{rate}(\eta) = \max_i |1 - \eta(\lambda_i + \mu)| = \max(|1 - \eta(\lambda_{\max} + \mu)|, |1 - \eta(\lambda_{\min} + \mu)|)$$

כאשר, לשם הבהירות סימנו $\lambda_1 = \lambda_{\min}, \lambda_d = \lambda_{\max}$.

ב. אם נגזור ביטוי זה נקבל קבוע בכל נקודה דיפרנציאבילית. כלומר הפונקציה היא לינארית למקוטעין, לכן המינימום מתקבל בנקודה קריטית שאינה גזירה ("שפיץ"). קל לראות כי נקודת המינימום מתקבלת ב

$$\begin{aligned} |1 - \eta(\lambda_{\max} + \mu)| &= |1 - \eta(\lambda_{\min} + \mu)| \Rightarrow \eta(\lambda_{\max} + \mu) - 1 = 1 - \eta(\lambda_{\min} + \mu) \\ \Rightarrow \eta(\lambda_{\max} + \lambda_{\min} + 2\mu) &= 2 \Rightarrow \eta = \frac{2}{\lambda_{\max} + \lambda_{\min} + 2\mu} \end{aligned}$$

נציב בביטוי ל- $\text{rate}(\eta)$ כדי לקבל את קצב ההתכנסות

$$\text{rate}(\eta) = 1 - \frac{2}{\lambda_{\max} + \lambda_{\min} + 2\mu} (\lambda_{\min} + \mu) = \frac{\lambda_{\max} - \lambda_{\min}}{\lambda_{\max} + \lambda_{\min} + 2\mu}$$

ג. מהביטוי שקיבלנו בסעיף קודם (ואפילו ישירות מההגדרה של קצב ההתכנסות) ברור קצב ההתכנסות ישתפר ככל שנגדיל את הרגולריזציה, לכן ניקח $\mu \rightarrow \infty$. אולם במקרה זה

$$\mathbf{w}(\infty) = \mathbf{w}_\mu = \mathbf{H}_\mu^{-1} \mathbf{X}^T \mathbf{y} = (\mu \mathbf{I} + \mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \mu^{-1} \left(\mathbf{I} + \frac{1}{\mu} \mathbf{X}^T \mathbf{X} \right)^{-1} \mathbf{X}^T \mathbf{y} \rightarrow 0$$


ולכן השגיאה הסופית תהיה $\mathcal{L}(\mathbf{w}(\infty)) = \mathcal{L}(\mathbf{0}) = \frac{1}{2} \|\mathbf{y}\|^2$.

ד. כאשר $\mu = 0$ אינה סינגולרית, הפתרון יהיה $\mathbf{H}_0^{-1} \mathbf{X}^T \mathbf{y}$

כאשר $\mathbf{H}_0$ אינה סינגולרית, $\mathbf{X}$ הוא מדרגה מלאה, ולכן פתרון זה מביא אותנו לשגיאה אפס: זהו פתרון של d משוואות ב- d נעלמים של מערכת משוואות לא סינגולרית: $\mathbf{y} = \mathbf{X}\mathbf{w}$. מכיוון שלא ניתן לרדת מתחת לשגיאה אפס, זו ה- μ הממוזער את השגיאה הסופית.

פתרון שאלה מס' 3: רשתות רב שכבתיות וסימטריות (40%)

א.



ב. קיימת סימטריה בדידה לפרמוטציה של הנוירונים בשכבה נסתרת, כלומר לכל שתי זוגות אינדקסים $(i, j), (k, r)$, מוצא הרשת לא ישתנה אם נבצע את החילופים הבאים בפרמטרים:

$$W_1[r, k, :, :] \leftrightarrow W_1[i, j, :, :] \text{ and } W_2[r, k] \leftrightarrow W_2[i, j]$$

בנוסף קיימת סימטריה רציפה להכפלה וחלוקה בקבוע בכל נוירון. לכן מוצא הרשת אינוואריאנטי לטרנספורמציה:

$$\forall r, k, \forall c > 0: W_1[r, k, :, :] \rightarrow c W_1[r, k, :, :] \text{ and } W_2[r, k] \rightarrow \frac{1}{c} W_2[r, k]$$

ג. כפי שנלמד בהרצאה, הייצוג בשכבה הנסתרת יהיה equivariant לטרנספורמציה אם מתקיים הפעלת הטרנספורמציה על הכניסה והיציאה של W_1 לא תשנה את הטנזור. ספציפית, כאן נקבל את הדרישה:

$$\forall i, j, k, r: W_1[r, k, j, i] = W_1[r, d+1-k, j, d+1-i]$$

בנוסף, כדי שמוצא הרשת יהיה אינוואריאנטי לטרנספורמציה זו נדרוש:

$$(*) \quad \forall r, k: W_2[r, k] = W_2[r, d+1-k]$$

מדוע זה ייצור מוצא אינוואריאנטי? ניתן לחשוב על השכבה השנייה בתור שכבה המשמרת ייצוג equivariant שלאחריה עושים מיד average pooling. כלומר, ניתן להגדיר טנזור $\tilde{W}_2 \in \mathbb{R}^{4 \times d \times 4 \times d}$ כך ש-

$$\forall i, j, k, r: \tilde{W}_2[j, i, r, k] = \tilde{W}_2[j, d+1-i, r, d+1-k]$$

$$W_2[k, r] = \frac{1}{4} \sum_{j=1}^4 \sum_{i=1}^d \tilde{W}_2[j, i, r, k]$$

ואז מתקיים בהכרח (*).

ד. (1) לא. קל לראות שמתקיים $f(c\mathbf{X}) = cf(\mathbf{X})$ ולכן הסיווג לא משתנה: $\text{sign}(f(c\mathbf{X})) = \text{sign}(f(\mathbf{X}))$.

(2) כן, האופטימיזציה יכולה להיות מאוד מושפעת מזה. פונקציית המחיר על הדוגמא ה- (n) מושפעת מהסקאלה

$$\ell(y^{(n)}, f_w(c\mathbf{X}^{(n)})) = \log(1 + \exp(-cy^{(n)} f_w(\mathbf{X}^{(n)})))$$

וגם הגרדיאנט

$$\nabla_w \ell(y^{(n)}, f_w(c\mathbf{X}^{(n)})) = \frac{\exp(-cy^{(n)} f_w(\mathbf{X}^{(n)}))}{1 + \exp(-cy^{(n)} f_w(\mathbf{X}^{(n)}))} - cy^{(n)} \nabla_w f_w(\mathbf{X}^{(n)}) = \frac{-cy^{(n)}}{1 + \exp(-cy^{(n)} f_w(\mathbf{X}^{(n)}))} \nabla_w f_w(\mathbf{X}^{(n)})$$

מביטוי זה נראה שנקבל גרדיאנט קטן מאוד עבור דוגמאות עם c קטן מאוד, וגם עבור דוגמאות עם c גדול מאוד המסווגות נכון. לעומת זאת נקבל גרדיאנט גדול מאוד עבור דוגמאות המסווגות לא נכון עבורן c גדול מאוד. הבדלים גדולים ושרירותיים אלה בין עוצמת הגרדיאנטים של דוגמאות שונות יכולה לפגוע בתהליך האימון.

(3) פשוט ננרמל את הכניסה לפני שנכנס אותה לרשת, למשל:

$$f_w(\mathbf{X}) = \sum_{r=1}^4 \sum_{k=1}^m W_2[r, k] \phi \left(\sum_{j=1}^4 \sum_{i=1}^d W_1[r, k, j, i] \frac{X[j, i]}{\sqrt{\sum_{j'=1}^4 \sum_{i'=1}^d X^2[j', i']}} \right)$$