

פתרון שאלה מס' 1: קונבולוציה (35%)

א. בשכבת קונבולוציה ללא padding האורך של הוקטור במוצא קטן מהוקטור בכניסה ב-1, k , כאשר k הוא גודל הגרעין. לכן אורכם של וקטורי הביניים ברשת הינם:

$$d_1 = 20 - 2 = 18$$

$$d_2 = 18 - 2 = 16$$

$$d_3 = 16 - 4 = 12$$

$$d_4 = 12 - 2 = 10$$

ב. כמות הפרמטרים בשכבת קונבולוציה ללא היסט הינה: גודל הגרעין $\times$ מספר הערוצים בכניסה $\times$ מספר הערוצים ביציאה. לכן כמות הפרמטרים בשכבות הקונבולוציה הינו:

$$n_1 = 3 \times 1 \times 3 = 9$$

$$n_2 = 3 \times 3 \times 2 = 18$$

$$n_3 = 5 \times 2 \times 1 = 10$$

$$n_4 = 3 \times 1 \times 1 = 3$$

כמות הפרמטרים בשכבת הfully connected הינה מספר האיברים בכניסה $\times$ מספר האיברים במוצא:

$$n_5 = d_4 \times 1 = d_4$$

סה"כ יש ברשת $40 + d_4$ פרמטרים.
ג. כמות המכפלות שאותה מבצעת שכבת קונבולוציה הינה גודל הגרעין $\times$ אורך המוצא $\times$ מספר הערוצים במוצא $\times$ מספר הערוצים בכניסה. לכן כמות המכפלות שמבצעות שכבות הקונבולוציה הינם:

$$p_1 = 3 \times d_1 \times 3 \times 1 = 9d_1$$

$$p_2 = 3 \times d_2 \times 2 \times 3 = 18d_2$$

$$p_3 = 5 \times d_3 \times 1 \times 2 = 10d_3$$

$$p_4 = 3 \times d_4 \times 1 \times 1 = 3d_4$$

כמות הכפלים בשכבת הfully connected שווה למספר מספר האיברים בכניסה $\times$ מספר האיברים במוצא:

$$p_5 = d_4 \times 1 = d_4$$

ולכן כמות הכפלים הכוללת ברשת הינה

$$9d_1 + 18d_2 + 10d_3 + 3d_4 + d_4$$

ד. האיברים אשר משפיעים על $z_{2,1,5}$ בכניסה לשכבה השנייה (z_1) הינם: $\{z_{1,n,5}, z_{1,n,6}, z_{1,n,7}\}$.
כאשר n הינו האינדקס אשר רק על שלושת הערוצים בכניסה לשכבה. האיברים בכניסה לרשת אשר משפיעים על האיברים ב- z_1 הינם $\{x_5, x_6, x_7, x_8, x_9\}$.
ה.

$$w^* = \operatorname{argmin}_w \frac{1}{N} \sum_i (g(\vec{x}_i, \vec{w}) - y_i)^2 + \lambda \|\vec{w}\|^2$$

ו. stochastic gradient descent בכל צעד נשתמש רק בדגימה אחת. בצעד t נרצה למזער את

$$f(\vec{w}, \vec{x}_k, y_k) = (g(\vec{x}_k, \vec{w}) - y_k)^2 + \lambda \|\vec{w}\|^2$$

צעד העדכון של $w_{5,5}$ יהיה:

$$w_{5,5}^{(t+1)} = w_{5,5}^{(t)} - \alpha \frac{\partial f}{\partial w_{5,5}} = w_{5,5}^{(t)} - 2\alpha \left((g(\vec{x}_k; \vec{w}) - y_k) \frac{\partial g}{\partial w_{5,5}} + 2\lambda w_{5,5}^{(t)} \right)$$

נחשב את האיבר $\frac{\partial g}{\partial w_{5,5}}$

המוצא של הרשת נתון על ידי:

$$\hat{y} = g(\vec{x}, \vec{w}) = \sum_n z_{4,1,n} \cdot w_{5,n}$$

ולכן $\frac{\partial g}{\partial w_{5,5}} = z_{4,1,5}$ סה"כ נקבל כי צעד העדכון יהיה:

$$w_{5,5}^{(t+1)} = w_{5,5}^{(t)} - 2\alpha \left((\hat{y} - y_k) z_{4,1,5} + 2\lambda w_{5,5}^{(t)} \right)$$

ז. בדומה לסעיף הקודם, צעד העדכון יהיה :

$$w_{4,2}^{(t+1)} = w_{4,2}^{(t)} - \alpha \frac{\partial f}{\partial w_{4,2}} = w_{4,2}^{(t)} - 2\alpha \left((g(\vec{x}_k; \vec{w}) - y_k) \frac{\partial g}{\partial w_{4,2}} + 2\lambda w_{4,2}^{(t)} \right)$$

את האיבר $\frac{\partial g}{\partial w_{4,2}}$ נוכל לחשב על פי כלל השרשרת

$$\frac{\partial g}{\partial w_{4,2}} = \sum_{i=1}^{d_4} \frac{\partial g}{\partial z_{4,1,i}} \frac{\partial z_{4,1,i}}{\partial w_{4,2}}$$

(זאת מכיוון ומוצא הרשת תלוי בפרמטר $w_{4,2}$ רק דרך האיברים $z_{4,i}$ הפעולה אותה מבצעת רשת הקונבולוציה הינה :

$$z_{4,1,i} = \sum_{j=1}^3 z_{3,1,i+j-1} w_{4,j}$$

ולכן

$$\frac{\partial z_{4,1,i}}{\partial w_{4,2}} = z_{3,1,i+1}$$

מכאן שצעד העדכון יהיה :

$$w_{4,2}^{(t+1)} = w_{4,2}^{(t)} - 2\alpha \left((\hat{y} - y_k) \left(\sum_{i=1}^{d_4} \frac{\partial g}{\partial z_{4,1,i}} z_{3,1,i+1} \right) + 2\lambda w_{4,2}^{(t)} \right)$$

א.

$$\begin{aligned}w(t+1) &= w(t) + \eta \sum_{n=1}^N (y^{(n)} - w(t)x^{(n)})x^{(n)} \\w(t+1) &= w(t) + \eta \sum_{n=1}^N \varepsilon^{(n)} x^{(n)} + \eta w_* \sum_{n=1}^N (x^{(n)})^2 - \eta w(t) \sum_{n=1}^N (x^{(n)})^2 \\w(t+1) &= w(t) + \eta h_1 + \eta w_* h_0 - \eta w(t) h_0 \\w(t+1) &= \eta h_1 + \eta w_* h_0 + (1 - \eta h_0) w(t)\end{aligned}$$

נראה כי הפתרון הנתון מקיים את המשוואה, ע"י הצבה (אפשרות אחרת היא לפתור ע"י הנוסחא לסכום של סדרה הנדסית). מצד אחד:

$$w(t+1) = \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-r(t+1)})$$

ומצד שני:

$$\begin{aligned}\eta h_1 + \eta w_* h_0 + (1 - \eta h_0) \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-rt}) &= \left(\frac{h_1}{h_0} + w_* \right) (1 - (1 - \eta h_0) e^{-rt}) \\&= \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-r} e^{-rt}) = \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-r(t+1)})\end{aligned}$$

ב. זהו פירוק ההטיה-שונות הידוע (Bias-Variance Decomposition):

$$\begin{aligned}E(w(t) - w_*)^2 &= E(w(t) - Ew(t) + Ew(t) - w_*)^2 \\&= E(Ew(t) - w_*)^2 + E(w(t) - Ew(t))^2 + 2E(w(t) - Ew(t))(Ew(t) - w_*) \\&= (Ew(t) - w_*)^2 + E(w(t) - Ew(t))^2 + 2 \overbrace{(Ew(t) - Ew(t))}^0 (Ew(t) - w_*) \\&= (Ew(t) - w_*)^2 + E(w(t) - Ew(t))^2\end{aligned}$$

ג. מסעיף קודם,

$$Ew(t) = E \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-rt}) = \left(\frac{\sum_{n=1}^N x^{(n)} E \varepsilon^{(n)}}{h_0} + w_* \right) (1 - e^{-rt}) = w_* (1 - e^{-rt})$$

מכאן:

$$E\left(Ew(t) - w_*\right)^2 = e^{-rt} w_*^2$$

וגם

$$E\left(w(t) - Ew(t)\right)^2 = \left(1 - e^{-rt}\right)^2 E\left(\frac{h_1}{h_0}\right)^2 = \left(1 - e^{-rt}\right)^2 \frac{E\left[\sum_{n=1}^N x^{(n)} \varepsilon^{(n)} \sum_{m=1}^N x^{(m)} \varepsilon^{(m)}\right]}{h_0} \left(1 - e^{-rt}\right)^2 \frac{\sigma^2}{h_0}$$

כאשר בשוויון האחרון השתמשנו בכך ש :

$$E \sum_{n=1}^N x^{(n)} \varepsilon^{(n)} \sum_{m=1}^N x^{(m)} \varepsilon^{(m)} = \sum_{n=1}^N \sum_{m=1}^N x^{(m)} x^{(n)} E \varepsilon^{(n)} \varepsilon^{(m)} = \sigma^2 \sum_{n=1}^N \sum_{m=1}^N x^{(m)} x^{(n)} \delta_{m,n} = \sigma^2 \sum_{n=1}^N \left(x^{(n)}\right)^2 = \sigma^2 h_0$$

מכאן :

$$\begin{aligned} E\left(w(t) - w_*\right)^2 &= E\left(w(t) - w_*\right)^2 = \left(Ew(t) - w_*\right)^2 + E\left(w(t) - Ew(t)\right)^2 \\ &= e^{-2rt} w_*^2 + \left(1 - e^{-rt}\right)^2 \sigma^2 h_0^{-1} \end{aligned}$$

ד. נגזור לפי t ונשווה לאפס :

$$E\left(w(t) - w_*\right)^2 = -2r \exp(-2rt) w_*^2 + 2r(1 - \exp(-rt)) \exp(-rt) \sigma^2 h_0^{-1} = 0$$

נחלק ב- $2 \exp(-rt)$ ונקבל

$$\begin{aligned} -r \exp(-rt) w_*^2 + r(1 - \exp(-rt)) \sigma^2 h_0^{-1} &= 0 \\ \Rightarrow \exp(rt) &= h_0 w_*^2 \sigma^{-2} + 1 \\ \Rightarrow t^* &= \frac{1}{r} \ln(h_0 w_*^2 \sigma^{-2} + 1) \end{aligned}$$

וזהו זמן העצירה האופטימלי.

ה. זמן זה גדל ככל שיחס האות ($w_*^2 \sigma^{-2}$) לרעש גדול יותר. זה הגיוני כי ככל שהרעש גדול (כלומר יחס האות לרעש נמוך יותר) אז יותר קשה יותר להכליל ונצטרך רגולריזציה חזקה יותר (כלומר, זמן עצירה קצר יותר), בדומה למצב שלמדנו בכיתה, עם רגולריזציות L2.

פתרון שאלה מס' 3 : אופטימיזציה (30%)

א. נבחר $\eta \mathbf{A} = \mathbf{H}^{-1}$ כדי שנקבל התכנסות תוך צעד אחד

$$\mathbf{w}(t+1) = \mathbf{w}(t) - \eta \mathbf{A} \nabla f(\mathbf{w}(t)) = \mathbf{w}(t) - \eta \mathbf{A} \mathbf{H} \mathbf{w}(t) = \mathbf{w}(t) - \mathbf{H}^{-1} \mathbf{H} \mathbf{w}(t) = 0$$

עבור d גדול זה נהיה יקר להפוך מטריצה, ולכן קירוב מקובל הוא להשתמש במטריצה אלכסונית, כלומר

$$(\eta \mathbf{A})_{ij} = \begin{cases} H_{ii}^{-1}, & \text{if } i = j \\ 0, & \text{if } i \neq j \end{cases}$$

קיימים גם קירובים אחרים שלמדנו בהרצאה.

ב. מתקיים :

$$\begin{aligned} f(\mathbf{w}(T)) - f(\mathbf{w}(0)) &= \int_0^T \frac{d}{dt} f(\mathbf{w}(t)) dt = \int_0^T \nabla f(\mathbf{w}(t))^T \dot{\mathbf{w}}(t) dt \\ &= - \int_0^T \nabla f(\mathbf{w}(t))^T \mathbf{A} \nabla f(\mathbf{w}(t)) dt \leq -\lambda_{\min}(\mathbf{A}) \int_0^T \|\nabla f(\mathbf{w}(t))\|^2 dt \leq 0 \end{aligned}$$

כאשר במעבר האחרון :

$$(1) \quad \text{השתמשנו בכך ש- } \mathbf{A} \text{ מטריצה סימטרית וחיובית ממש, ולכן } \lambda_{\min}(\mathbf{A}) > 0.$$

$$(2) \quad \text{יש שוויון אם ורק אם } \forall t \in [0, T]: \nabla f(\mathbf{w}(t)) = 0$$

כלומר, אלא אם כן $\nabla f(\mathbf{w}(t)) \rightarrow 0$, נקבל $\lim_{T \rightarrow \infty} f(\mathbf{w}(T)) = -\infty$. אבל זה סותר את התנאי

$$\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) = f_* > -\infty. \text{ מכאן } \nabla f(\mathbf{w}(t)) \rightarrow 0, \text{ ואנו מתכנסים לנקודה קריטית של } f.$$

ג. נעזר ברמז :

$$\begin{aligned} f(\mathbf{w}(t+1)) - f(\mathbf{w}(t)) &\leq (\mathbf{w}(t+1) - \mathbf{w}(t))^T \nabla f(\mathbf{w}(t)) + \frac{\beta}{2} \|\mathbf{w}(t+1) - \mathbf{w}(t)\|^2 \\ &= -(\eta \mathbf{A} \nabla f(\mathbf{w}(t)))^T \nabla f(\mathbf{w}(t)) + \frac{\beta}{2} \|\eta \mathbf{A} \nabla f(\mathbf{w}(t))\|^2 \\ &= -\eta \nabla f(\mathbf{w}(t))^T \mathbf{A} \nabla f(\mathbf{w}(t)) + \frac{\beta \eta^2}{2} \nabla f(\mathbf{w}(t))^T \mathbf{A}^2 \nabla f(\mathbf{w}(t)) \\ &\leq -\eta \lambda_{\min} \|\nabla f(\mathbf{w}(t))\|^2 + \frac{\beta \eta^2 \lambda_{\max}^2}{2} \|\nabla f(\mathbf{w}(t))\|^2 \\ &= -\eta \left(\lambda_{\min} - \frac{\beta \eta \lambda_{\max}^2}{2} \right) \|\nabla f(\mathbf{w}(t))\|^2 \end{aligned}$$

מכאן, אם $\eta < \frac{2\lambda_{\min}}{\beta\lambda_{\max}^2}$, אזי $c \triangleq \eta \left(\lambda_{\min} - \frac{\beta\eta\lambda_{\max}^2}{2} \right) > 0$ ומתקיים

$$f(\mathbf{w}(t+1)) - f(\mathbf{w}(t)) \leq -c \|\nabla f(\mathbf{w}(t))\|^2$$

נסכום טור טלסקופי זה מ-0 עד $T-1$ ונקבל:

$$f(\mathbf{w}(T)) \leq -c \sum_{t=0}^{T-1} \|\nabla f(\mathbf{w}(t))\|^2 + f(\mathbf{w}(0))$$

כלומר, כמו מקודם, אלא אם כן $\nabla f(\mathbf{w}(t)) \rightarrow 0$, נקבל $\lim_{T \rightarrow \infty} f(\mathbf{w}(T)) = -\infty$. אבל זה סותר את

התנאי $\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) = f_* > -\infty$. מכאן $\nabla f(\mathbf{w}(t)) \rightarrow 0$, ואנו מתכנסים לנקודה קריטית של f כל

$$\text{עוד } \eta < \frac{2\lambda_{\min}}{\beta\lambda_{\max}^2}.$$

מכיוון שרק נדרשתם למצוא תנאי כלשהו, הפתרון עד כה הוא מספיק לפתרון השאלה. אולם, קיים פתרון עוד יותר הדוק:

$$\begin{aligned} f(\mathbf{w}(t+1)) - f(\mathbf{w}(t)) &\leq (\mathbf{w}(t+1) - \mathbf{w}(t))^T \nabla f(\mathbf{w}(t)) + \frac{\beta}{2} \|\mathbf{w}(t+1) - \mathbf{w}(t)\|^2 \\ &= -(\eta \mathbf{A} \nabla f(\mathbf{w}(t)))^T \nabla f(\mathbf{w}(t)) + \frac{\beta}{2} \|\eta \mathbf{A} \nabla f(\mathbf{w}(t))\|^2 \\ &= -\eta \nabla f(\mathbf{w}(t))^T \mathbf{A} \nabla f(\mathbf{w}(t)) + \frac{\beta\eta^2}{2} \nabla f(\mathbf{w}(t))^T \mathbf{A}^2 \nabla f(\mathbf{w}(t)) \\ &= -\nabla f(\mathbf{w}(t))^T \left(\eta \mathbf{A} - \frac{\beta\eta^2}{2} \mathbf{A}^2 \right) \nabla f(\mathbf{w}(t)) \\ &\leq -\lambda_{\min} \left(\eta \mathbf{A} - \frac{\beta\eta^2}{2} \mathbf{A}^2 \right) \|\nabla f(\mathbf{w}(t))\|^2 \end{aligned}$$

כדי להמשיך בהוכחה כמו מקודם, מספיק לדרוש $c \triangleq \lambda_{\min} \left(\eta \mathbf{A} - \frac{\beta\eta^2}{2} \mathbf{A}^2 \right) > 0$, כלומר ש-

$$\eta \mathbf{A} - \frac{\beta\eta^2}{2} \mathbf{A}^2 \text{ מטריצה חיובית ממש, כלומר כל הערכים העצמיים שלה חיוביים ממש, שזה גורר}$$

$$\forall i: \eta \lambda_i - \frac{\beta\eta^2}{2} \lambda_i^2 > 0 \Rightarrow \eta > \frac{2}{\beta \lambda_{\max}}$$