

למידה עצמית - 046211

בחינה סופית - מועד א'

משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

ב ה צ ל ח ה !!!

שאלה מס' 1: עצירה מוקדמת בנוירון בודד (30%)

נבחן את ההשפעה של עצירה מוקדמת בנוירון בודד עם כניסה חד מימדית, אקטיבציה לינארית, ופונקציית מחיר ריבועית כלומר, רגרסיה לינארית ללא רגולריזציה:

$$\mathcal{L}(w) = \frac{1}{2} \sum_{n=1}^N \left(y^{(n)} - wx^{(n)} \right)^2$$

נרצה למזער את השגיאה $\mathcal{L}(w)$ באמצעות GD מאתחול $w(0) = 0$ וגודל צעד η . נניח וכי הדוגמאות מיוצרות ממודל לינארי $y^{(n)} = w_* x^{(n)} + \varepsilon^{(n)}$ כאשר w_* קבוע ו- $\varepsilon^{(n)}$ רעש גאוסי i.i.d. עם שונות σ^2 .

א. הראו כי מתקיים

$$w(t) = \left(\frac{h}{h_0} + w_* \right) (1 - e^{-rt})$$

כאשר $h_0 = \sum_{n=1}^N \left(x^{(n)} \right)^2$, $h_1 = \sum_{n=1}^N x^{(n)} \varepsilon^{(n)}$, ו- $r = -\ln(1 - \eta h_0)$. הניחו כי $h_0 > 0$.

ב. הראו כי מתקיים $E \left[\left(w(t) - w_* \right)^2 \right] = \left(Ew(t) - w_* \right)^2 + E \left[\left(w(t) - Ew(t) \right)^2 \right]$. איך קוראים לפירוק זה?

ג. הראו כי השגיאה הריבועית הממוצעת (על פני הרעש $\varepsilon^{(n)}$) היא

$$E \left(w(t) - w_* \right)^2 = \exp(-2rt) w_*^2 + \left(1 - \exp(-rt) \right)^2 \sigma^2 h_0^{-1}$$

ד. מצאו את זמן העצירה האופטימלי t^* הממזער את השגיאה הריבועית הממוצעת.

ה. יחס האות לרעש בבעיה זו הוא $\text{SNR} = w_*^2 \sigma^{-2}$. כיצד זמן העצירה האופטימלי משתנה עם ה- SNR ? האם זה דומה למה שלמדנו ברגולריזציה L2?

שאלה מס' 2 – Attention (35%)

נתונה שכבת (MHSA) Multi-Head-Self-Attention המופעלת על כניסה $X \in \mathbb{R}^{T \times Hd}$, עם מטריצות המשקולות $W_Q^h, W_K^h, W_V^h \in \mathbb{R}^{Hd \times d}$ ו- $W_O^h \in \mathbb{R}^{d \times Hd}$. כזכור, בשכבה זו מבוצעות הפעולות הבאות:

$$(1) \forall h \leq H: XW_Q^h = Q^h, XW_K^h = K^h, XW_V^h = V^h$$

$$(2) \forall h \leq H: U^h = Q^h(K^h)^\top / \sqrt{d}; \quad \text{MHSA}(X) = \sum_{h=1}^H (\text{Softmax}(U^h) V^h W_O^h)$$

א. באיזה ארכיטקטורת רשת נפוצה מופיעה שכבה זו? ציינו שני יתרונות וחסרון אחד של ארכיטקטורה זו ביחס לרשתות עם משב (recurrent neural networks).

אחת הבעיות בחישוב MHSA, היא הזיכרון הנדרש לשמור את U^h לפני הפעלת ה-Softmax.

- ב. (1) רשמו מפורשות מהם המימדים של Q^h, K^h, V^h, U^h .
- (2) כיצד נכתוב את $\text{Softmax}(U^h)[i, j]$ כפונקציה של U^h ללא התפוצצות אקספוננטים? הסבירו מדוע. מכאן ואילך הניחו שנחשב כל Softmax בצורה זו.
- (3) על פני איזה מימד יותר קל למקבל פונקציה זו (כלומר, המימד בו החישובים בלתי תלויים)?
- ג. כדי לפתור את בעיית הזיכרון מוצע לחלק את U^h ל- T שורות, ובכל שורה לחלק לשני בלוקים

$$J_1 = [1, \dots, T/2], J_2 = [T/2 + 1, \dots, T]$$

בכל בלוק $r \in \{1, 2\}$ נחשב את $\text{Softmax}(U[i, J_r : :])$, את מקדם הנרמול שלו $n_r[i]$, ואת $m_r[i] = \max_{k \in J_r} [U^h[i, k]]$. כיצד נחשב את $\text{Softmax}(U[i, :])$ (על שני הבלוקים ביחד) בעזרת תוצאות החישובים שביצענו בכל בלוק? הניחו כי T מספר זוגי.

השאלות הבאות אינן תלויות בקודמות. עוד בעיה בחישוב (1) + (2), היא כמות החישובים הנדרשים.

- ד. כמה מכפלות נדרשות בסה"כ, ללא החישוב של פעולת ה-Softmax? הניחו כי אנו מבצעים מכפלת מטריצות "נאיבית", כלומר עבור מכפלה של $A \in \mathbb{R}^{d_1 \times d_2}$ ו- $B \in \mathbb{R}^{d_2 \times d_3}$, כמות המכפלות ב- AB היא $d_1 d_2 d_3$. בנוסף, הניחו כי סדר המכפלות הוא (1) ואז (2), ובתוך כל משוואה משמאל לימין.
- ה. כדי לחסוך בפעולות חישוב, הוצא להוריד חלק מהאיברים שמשתתפים בחישוב. כדי לרשום זאת מתמטית נגדיר אוסף של קבוצות אינדקסים $\{S_i\}_{i=1}^T$, כאשר כל $S_i \subset \{1, \dots, T\}$ הוא אוסף של M אינדקסים שונים ונגדיר $A[S_i, :][j, k] = A[S_i[j], k]$. כעת, החישוב במשוואה (2) משתנה ל:

$$\forall h \leq H, \forall i \leq T: U^h[i, S_i] = Q^h[i, :](K^h[S_i, :])^\top / \sqrt{d};$$

$$\forall i \leq T: \text{MHSA}(X)[i, :] = \sum_{h=1}^H (\text{Softmax}(U^h[i, S_i]) V^h[S_i, :] W_O^h)$$

כמה מכפלות נדרש לעשות בסה"כ (לפי אותם כללים כמו ב-ד)? עבור איזה M, T, d זה משמעותי?

שאלה מס' 3 – אתחול רשתות (35%)

נתונה רשת עם חיבורי קפיצה (skip connections):

$$\mathbf{u}_{l+1} = \mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l)$$

במקרה שבו $\mathbf{F}_l(\mathbf{u}_l) = \mathbf{W}_l' \varphi(\mathbf{W}_l \mathbf{u}_l)$, מטריצת משקולות בגודל $d \times d$, ו- φ פונקציית אקטיבציה מסוג ReLU. הכניסה לרשת היא $\mathbf{u}_0 = \mathbf{x}$, עבורה כל רכיב בעל ממוצע אפס ושונות 1.

א. כזכור, שיטות האתחול הסטנדרטיות של $\mathbf{W}_l$ ו- $\mathbf{W}_l'$ של רשת ללא חיבורי קפיצה צריכה לקיים

$$(1) \quad E(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) = \mathbf{0} \quad \text{וגם} \quad (2) \quad E\text{Var}(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) = \text{Var}(\mathbf{u}_l)$$

איזה אתחולים של $\mathbf{W}_l$ ו- $\mathbf{W}_l'$ יקיימו זאת?

ב. הראו כי השונות $\mathbf{u}_l$ מתפוצצת ככל שמתקדמים ברשת, כלומר $\lim_{l \rightarrow \infty} \text{Var}(\mathbf{u}_l) = \infty$ (השונות כאן מופעלת

רכיב-רכיב), עבור האתחול הסטנדרטי מסעיף קודם, שמקיים את משוואות 1 ו-2.

ג. כדי למנוע את ההתפוצצות מוצע לשנות את האתחול הסטנדרטי בהתאם לשכבה בצורה הבאה

$$(3) \quad E(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) = \mathbf{0} \quad \text{וגם} \quad (4) \quad E\text{Var}(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) = c_l \text{Var}(\mathbf{u}_l)$$

כאשר $c_l > 0$. כיצד נשנה את אתחול של $\mathbf{W}_l$ ו- $\mathbf{W}_l'$ לקבל זאת? בנוסף, הציעו בחירה של $\{c_l\}_{l=1}^\infty$ חיוביים

המונעת התפוצצות של השונות, כלומר $\lim_{l \rightarrow \infty} \text{Var}(\mathbf{u}_l) < \infty$.

ד. מהו הגבול $\lim_{l \rightarrow \infty} \text{Var}(\mathbf{u}_l)$ עבור אתחול אפס $\mathbf{W}_l' = \mathbf{W}_l = \mathbf{0}$? מהי הבעיה העיקרית עם אתחול זה?

הנחיה: עבור האתחול הנתון חשבו בצורה מפורשת את הגרדיאנט של פונקציית ההפסד הכללית ℓ על מוצא

הרשת ביחס למשקולות $\mathbf{W}_l$ ו- $\mathbf{W}_l'$.

ה. איזה פתרון נפוץ ברשתות סטנדרטיות עם חיבורי קפיצה כדי למנוע את התפוצצות השונות $\text{Var}(\mathbf{u}_l)$? ציינו

יתרון וחסרון של פתרון שכזה.