

למידה עצמית - 046211
פתרון בחינה סופית - מועד א'

משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

ב ה צ ל ח ה !!!

פתרון

פתרון שאלה 1

א.

$$\begin{aligned}w(t+1) &= w(t) + \eta \sum_{n=1}^N (y^{(n)} - w(t)x^{(n)})x^{(n)} \\w(t+1) &= w(t) + \eta \sum_{n=1}^N \varepsilon^{(n)} x^{(n)} + \eta w_* \sum_{n=1}^N (x^{(n)})^2 - \eta w(t) \sum_{n=1}^N (x^{(n)})^2 \\w(t+1) &= w(t) + \eta h_1 + \eta w_* h_0 - \eta w(t) h_0 \\w(t+1) &= \eta h_1 + \eta w_* h_0 + (1 - \eta h_0) w(t)\end{aligned}$$

נראה כי הפתרון הנתון מקיים את המשוואה, ע"י הצבה (אפשרות אחרת היא לפתור ע"י הנוסחה לסכום של סדרה הנדסית). מצד אחד:

$$w(t+1) = \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-r(t+1)})$$

ומצד שני:

$$\begin{aligned}\eta h_1 + \eta w_* h_0 + (1 - \eta h_0) \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-rt}) &= \left(\frac{h_1}{h_0} + w_* \right) (1 - (1 - \eta h_0) e^{-rt}) \\&= \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-r} e^{-rt}) = \left(\frac{h_1}{h_0} + w_* \right) (1 - e^{-r(t+1)})\end{aligned}$$

ב. זהו פירוק ההטיה-שונות הידוע (Bias-Variance Decomposition):

$$\begin{aligned}E(w(t) - w_*)^2 &= E(w(t) - Ew(t) + Ew(t) - w_*)^2 \\&= E(Ew(t) - w_*)^2 + E(w(t) - Ew(t))^2 + 2E(w(t) - Ew(t))(Ew(t) - w_*) \\&= (Ew(t) - w_*)^2 + E(w(t) - Ew(t))^2 + 2 \cancel{(Ew(t) - Ew(t))} (Ew(t) - w_*) \\&= (Ew(t) - w_*)^2 + E(w(t) - Ew(t))^2\end{aligned}$$

ג. מסעיף קודם,

$$Ew(t) = E\left(\frac{h_1}{h_0} + w_*\right)(1 - e^{-rt}) = \left(\frac{\sum_{n=1}^N x^{(n)} E\varepsilon^{(n)}}{h_0} + w_*\right)(1 - e^{-rt}) = w_*(1 - e^{-rt})$$

מכאן:

$$E\left(Ew(t) - w_*\right)^2 = e^{-rt} w_*^2$$

וגם

$$E\left(w(t) - Ew(t)\right)^2 = (1 - e^{-rt})^2 E\left(\frac{h_1}{h_0}\right)^2 = (1 - e^{-rt})^2 \frac{E\left[\sum_{n=1}^N x^{(n)} \varepsilon^{(n)} \sum_{m=1}^N x^{(m)} \varepsilon^{(m)}\right]}{h_0} (1 - e^{-rt})^2 \frac{\sigma^2}{h_0}$$

כאשר בשוויון האחרון השתמשנו בכך ש:

$$E \sum_{n=1}^N x^{(n)} \varepsilon^{(n)} \sum_{m=1}^N x^{(m)} \varepsilon^{(m)} = \sum_{n=1}^N \sum_{m=1}^N x^{(m)} x^{(n)} E \varepsilon^{(n)} \varepsilon^{(m)} = \sigma^2 \sum_{n=1}^N \sum_{m=1}^N x^{(m)} x^{(n)} \delta_{m,n} = \sigma^2 \sum_{n=1}^n \left(x^{(n)}\right)^2 = \sigma^2 h_0$$

מכאן:

$$\begin{aligned} E\left(w(t) - w_*\right)^2 &= E\left(w(t) - w_*\right)^2 = \left(Ew(t) - w_*\right)^2 + E\left(w(t) - Ew(t)\right)^2 \\ &= e^{-2rt} w_*^2 + (1 - e^{-rt})^2 \sigma^2 h_0^{-1} \end{aligned}$$

ד. נגזור לפי t ונשווה לאפס:

$$\frac{d}{dt} E\left(w(t) - w_*\right)^2 = -2r \exp(-2rt) w_*^2 + 2r(1 - \exp(-rt)) \exp(-rt) \sigma^2 h_0^{-1} = 0$$

נחלק ב- $2 \exp(-rt)$ ונקבל

$$\begin{aligned} -r \exp(-rt) w_*^2 + r(1 - \exp(-rt)) \sigma^2 h_0^{-1} &= 0 \\ \Rightarrow \exp(rt) &= h_0 w_*^2 \sigma^{-2} + 1 \\ \Rightarrow t^* &= \frac{1}{r} \ln(h_0 w_*^2 \sigma^{-2} + 1) \end{aligned}$$

וזהו זמן העצירה האופטימלי.

ה. זמן זה גדל ככל שיחס האות ($w_2^2 \sigma^{-2}$) לרעש גדול יותר. זה הגיוני כי ככל שהרעש גדול (כלומר יחס האות לרעש נמוך יותר) אז יותר קשה יותר להכליל ונצטרך רגולריזציה חזקה יותר (כלומר, זמן עצירה קצר יותר), בדומה למצב שלמדנו בכיתה, עם רגולריזציה L2.

פתרון שאלה 2

א. זו היא שכבה שמופיעה בארכיטקטורת Transformer. לארכיטקטורה זו יש כמה יתרונות על פני רשתות עם משוב, כפי שלמדנו בכיתה. למשל, יש לה פחות בעיה של התפוצצות/דעיכת גרדיאנטים, ולכן היא יכולה ללמוד יותר בקלות בעיות הדורשות זיכרון ארוך. בנוסף, היא מאפשר חישוב מקבילי על פני סדרת הקלט (בניגוד לרשת עם משוב שעובדת בצורה טורית). החסרון העיקרי הוא שכמות פעילות החישוב גדלה ריבועית עם אורך סדרת הקלט T (כפי שאמרנו בהרצאה ונחשב מפורשת בהמשך השאלה), לעומת רשתות עם משוב בה כמות החישוב גדלה לינארית עם T .

$$Q^h \in \mathbb{R}^{T \times d}, K^h \in \mathbb{R}^{T \times d}, V^h \in \mathbb{R}^{T \times d}, U^h \in \mathbb{R}^{T \times T} \quad (1) \quad \text{ב.}$$

(2) אם נסמן

$$m[i] = \max_{k \in [1, \dots, T]} [U^h[i, k]]$$

אז גרסה ללא התפוצצות של האקספוננטים של ה-Softmax (שמונעת בעיות נומריות) תהיה

$$\text{Softmax}(U^h)[i, j] = \frac{\exp(U^h[i, j] - m[i])}{\sum_{k=1}^T \exp(U^h[i, k] - m[i])}$$

הסיבה לכך היא, שמצד אחד, השימוש ב- $m[i]$ מונע מכל אקספוננט לגדול מעל 1, ומצד שני, מתמטית זה לא משנה את המשוואה. העקרון זהה למה שראינו בהרצאה בטריק ה-log-sum-exp.

(3) ברור כי ניתן לחלק את U^h לשורות, ולבצע את החישוב על כל שורה בנפרד, כי החישוב של ה-Softmax בכל שורה לא תלוי בחישוב בשורות האחרות.

ג. כזכור $J_1 = [1, \dots, T/2], J_2 = [T/2 + 1, \dots, T]$, ואנחנו נמצאים בשורה ה- i .

נגדיר $\forall r \in \{1, 2\}$:

$$m_r[i] = \max_{k \in J_r} [U^h[i, k]]$$

$$\forall j \in J_r: E_r[i, j] = \exp(U^h[i, j] - m_r[i])$$

$$n_r[i] = \sum_{j \in J_r} E_r[i, j]$$

מכאן, בכל אחד מהבלוקים נוכל להגדיר Softmax משלו:

$$\forall j \in J_r: \text{Softmax}_r(\mathbf{U}^h)[i, j] = \frac{E_r[i, j]}{n_r[i]}$$

החישוב של כל אחד מהגדלים האלה יכול להתבצע בנפרד בכל בלוק (אין תלות בין הבלוקים). עכשיו, נוכל לחבר את החישוב בין שני הבלוקים:

$$m[i] = \max_{r \in 1,2} m_r[i] \quad , \quad n[i] = \sum_{r \in 1,2} n_r[i],$$

$$\text{Softmax}(\mathbf{U}^h)[i, j] = \begin{cases} \frac{n_1[i] \exp(m_1[i] - m[i]) \text{Softmax}_1(\mathbf{U}^h)[i, j]}{n[i]} & j \in J_1 \\ \frac{n_2[i] \exp(m_2[i] - m[i]) \text{Softmax}_2(\mathbf{U}^h)[i, j]}{n[i]} & j \in J_2 \end{cases}$$

קל לזוודא ע"י הצבה שהמשוואה האחרונה אכן נותנת $\text{Softmax}(\mathbf{U}^h)[i, j]$ על כל הבלוק.

ד. בחישוב של $\mathbf{Q}^h, \mathbf{K}^h, \mathbf{V}^h$ במשוואה (1) יש בכל אחד THd^2 מכפלות. בחישוב של $\mathbf{U}^h$ במשוואה (2) יש T^2d מכפלות. בחישוב של כל איבר בסכום על h במשוואה (2) יש $T^2d + Td^2H$ מכפלות. מכיוון שעושים את זה לכל h (סוכמים על כולם בסוף), צריך להכפיל ב- H , וקיבלנו $4TH^2d^2 + 2HT^2d$ מכפלות.

שימו לב: סדר פעולות אחר יכול לגרור מספר שונה של מכפלות.

הערה: במועד זה, התקבלו גם תשובות שהחשיבו את החלוקה בשורש המימד בתור מכפלה.

ה. במקרה זה, מימד אחד יורד מ- T ל- M , בחישובים עבור משוואה (2), כך שבחישוב של $\mathbf{U}^h$ יש כעת TMd מכפלות, ובחישוב של איבר בסכום על h יש כעת $TMd + Td^2H$ מכפלות. נוסיף את אותן פעולות ממשוואה (1) כמו מקודם, ונכפיל שוב ב- H את הכל כמו מקודם, ונקבל בסופו של דבר $4TH^2d^2 + 2HTMd$ מכפלות.

השינוי משמעותי כאשר $T \gg M$.

פתרון שאלה 3

א. השכבה הראשונה מאותחלת i.i.d. לפי אתחול He שראינו בהרצאה:

$$\mathbf{W}[i,j] \sim N(0, \frac{2}{d^2})$$

חישוב דומה עבור השכבה השנייה (בה פונקציית האקטיבציה לינארית), ייתן:

$$\mathbf{W}'[i,j] \sim N(0, \frac{1}{d^2})$$

הערה: מה שחשוב בביטויים מעלה הם הממוצע והשונות, שנובעים מהחישוב. הבחירה של הפילוג כאן (גאוס) היא לפי המקובל אבל אפשר גם דברים אחרים (כמו פילוג אחיד).

ב. כמו שראינו בהרצאה, מחוק השונות הכוללת (כאמור, השונות כאן מופעלת רכיב-רכיב):

$$\begin{aligned}\text{Var}(\mathbf{u}_{l+1}) &= E\text{Var}(\mathbf{u}_{l+1} | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_{l+1} | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(\mathbf{u}_l) = \text{Var}(\mathbf{u}_l) + \text{Var}(\mathbf{u}_l) \\ &= 2\text{Var}(\mathbf{u}_l) = 2^l \text{Var}(\mathbf{u}_0) \rightarrow \infty\end{aligned}$$

כאשר השיויון השני נובע ממשוואה (1) והשלישי ממשוואה (2).

ג. כדי לקבל אתחול שמקיים את (3) ו-(4), פשוט נכפיל את האתחול של שתי השכבות מסעיף א' ב- $\sqrt{c_l}$. עבור אתחול זה, בדומה לפיתוח מסעיף ב'

$$\begin{aligned}\text{Var}(\mathbf{u}_{l+1}) &= E\text{Var}(\mathbf{u}_{l+1} | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_{l+1} | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(\mathbf{u}_l) = c_l \text{Var}(\mathbf{u}_l) + \text{Var}(\mathbf{u}_l) \\ &= (1 + c_l) \text{Var}(\mathbf{u}_l) = \text{Var}(\mathbf{u}_0) \prod_{l'=1}^l (1 + c_{l'}) < \infty\end{aligned}$$

מכאן תנאי מספיק למניעת התפוצצות הוא $\prod_{l=1}^{\infty} (1 + c_l) < \infty$.

אפשר לפשט תנאי זה עוד (אבל לא חובה בשביל לזכות במלוא הניקוד). נתחיל בהפעלת לוג על שני הצדדים

$$\sum_{l=1}^{\infty} \log(1 + c_l) < \infty$$

שימוש בחסם $\log(1 + x) \leq x$ ייתן תנאי מספיק פשוט יותר

$$\sum_{l=1}^{\infty} c_l < \infty$$

תנאי המתקיים למשל עבור $c_l = 1/l^2$.

ד. עבור אתחול אפס, $\mathbf{u}_{l+1} = \mathbf{u}_l$ ולכן בפרט $\text{Var}(\mathbf{u}_{l+1}) = \text{Var}(\mathbf{u}_l) = \text{Var}(\mathbf{u}_0) = 1$, כלומר אין התפוצצות או דעיכה של השונות. אבל יש בעיה עם אתחול. כדי לראות אותה, נחשב את הנגזרת של פונקציית ההפסד ℓ על מוצא הרשת ביחס למשקולות, כפי שנרמז:

$$\frac{\partial \ell}{\partial \mathbf{w}'_l[i, j]} = \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[i]} \frac{\partial \mathbf{u}_{l+1}[i]}{\partial \mathbf{w}'_l[i, j]} = \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[i]} \varphi(\mathbf{w}_l \mathbf{u}_l)[j] = \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[i]} \varphi(\mathbf{0} \mathbf{u}_l)[j] = 0$$

$$\begin{aligned} \frac{\partial \ell}{\partial \mathbf{w}_l[i, j]} &= \frac{\partial \ell}{\partial \mathbf{u}_{l+1}} \frac{\partial \mathbf{u}_{l+1}}{\partial \mathbf{w}_l[i, j]} = \sum_k \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[k]} \frac{\partial \mathbf{u}_{l+1}[k]}{\partial \varphi(\mathbf{w}_l \mathbf{u}_l)[i]} \frac{\partial \varphi(\mathbf{w}_l \mathbf{u}_l)[i]}{\partial \mathbf{w}_l[i, j]} \\ &= \left(\sum_k \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[k]} \mathbf{w}'_l[k, i] \right) \varphi'(\mathbf{w}_l \mathbf{u}_l)[i] \mathbf{u}_l[j] \\ &= \left(\sum_k \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[k]} 0 \right) \varphi'(\mathbf{w}_l \mathbf{u}_l)[i] \mathbf{u}_l[j] = 0 \end{aligned}$$

מכאן, הגרדיאנט יהיה אפס, ו-SGD יתקע ולא נוכל ללמוד כלום.

ה. הפתרון הוא להשתמש בשכבת נרמול כמו למשל עם Batch-Norm או Layer-norm. יתרון בשכבה כזו שהיא דואגת לנרמול גם אחרי האתחול (כלומר, בזמן האימון). חסרון לדוגמא הוא העלות החישובית של שכבות אלה, שיכול להיות משמעותי.