

למידה עצמית - 046211
בחינה סופית - מועד ב'

משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

ב ה צ ל ח ה !!!


פתרון

פתרון שאלה 1

מבוסס על המאמר <https://arxiv.org/abs/2006.16236>

א. טרנספורמר הוא מודל למידה עמוקה המשמש בעיקר בתחומי עיבוד שפה טבעית (NLP) וראייה ממוחשבת. מבנה המקודד מפענח שימושי למשל למשימות של תרגום בין שפות.

ב.



כפי שניתן לראות בציור, ייחודו של המודל בשימוש במנגנון תשומת הלב העצמית מרובת ראשים, או Multi Head Self-Attention (MHSA). הארכיטקטורה בנויה מטוקניזציה של הטקסט (או אות אחר), קידוד תלוי מיקום (Positional Encoding), מנגנון תשומת הלב העצמית מרובת ראשים MHSA, רשת רב שכבתית עם חיבוריות מלאה (Fully Connected), נרמול (עם Layer normalization) וחיבור עם Skip-connection.

ג. במקודד, הקלט (למשל, השפה שרוצים לתרגם) נכנס בשכבה הראשונה.

במפענח, נכנס קלט בשכבה הראשונה (למשל השפה שרוצים לתרגם אליה), וזאת בצורה ממוסכת (כדי לא להסתמך על העתיד בביצוע חיזוי ההווה), וגם נכנס, בשכבות הביניים, קלט של מפתחות וערכים (K, V) משכבות הביניים של המקודד.

ד. מספר המכפלות הנדרשות לחשב את משוואה (2) הן:

$$TDT + TTM$$

כאשר TDT הוא בגלל המכפלה QK^T , ו- TTM הוא בגלל המכפלה של V עם תוצאת ה-softmax.

ה. אם מניחים

$$\text{sim}(\mathbf{q}, \mathbf{k}) = \exp\left(\frac{\mathbf{q}^\top \mathbf{k}}{\sqrt{D}}\right)$$

אז

$$\mathbf{v}'_i = \frac{\sum_{j=1}^T \text{sim}(\mathbf{Q}_i, \mathbf{K}_j) \mathbf{v}_j}{\sum_{r=1}^T \text{sim}(\mathbf{Q}_i, \mathbf{K}_r)} = \sum_{j=1}^T \frac{\exp(\mathbf{Q}_i^\top \mathbf{K}_j / \sqrt{D})}{\sum_{r=1}^T \exp(\mathbf{Q}_i^\top \mathbf{K}_r / \sqrt{D})} \mathbf{v}_j = \sum_{r=1}^T \text{softmax}(\mathbf{Q}_i^\top \mathbf{K}_r / \sqrt{D}) \mathbf{v}_j$$

הביטוי הזה שווה לביטוי (1) בשאלה כאשר מניחים ש-softmax פועל איבר-איבר.

ו.

$$\mathbf{v}'_i = \frac{\sum_{j=1}^d \text{sim}(\mathbf{Q}_i, \mathbf{K}_j) \mathbf{v}_j}{\sum_{r=1}^d \text{sim}(\mathbf{Q}_i, \mathbf{K}_r)} = \frac{\sum_{j=1}^T \phi(\mathbf{Q}_i)^\top \phi(\mathbf{K}_j) \mathbf{v}_j}{\sum_{r=1}^T \phi(\mathbf{Q}_i)^\top \phi(\mathbf{K}_r)} = \frac{\phi(\mathbf{Q}_i)^\top \sum_{j=1}^T \phi(\mathbf{K}_j) \mathbf{v}_j}{\phi(\mathbf{Q}_i)^\top \sum_{r=1}^T \phi(\mathbf{K}_r)}$$

אם מחשבים את הביטוי $\sum_{j=1}^T \phi(\mathbf{K}_j) \mathbf{v}_j$ ואת הביטוי $\sum_{r=1}^T \phi(\mathbf{K}_r)$ מראש בתחילת הפעולה אז מספר פעולות הכפל הנדרש במונה $\phi(\mathbf{Q})(\phi(\mathbf{K})^\top \mathbf{V})$ הן

$$DTM + TDM = 2DTM$$

כאשר איבר אחד הוא על חישוב המכפלה בתוך הסוגריים, והאיבר השני הוא על חישוב המכפלה מחוץ לסוגריים. מספר הפעולות במכנה הוא זניח – TD .

ז. נדרוש

$$TDT + TTM > 2DTM$$

נקבל

$$T > \frac{2DM}{D + M}$$

תנאי זה סביר, כי בד"כ מתקיים $T \gg M, D$.

מבוסס על המאמר Implicitly Learned Invariance and Equivariance in Linear Regression

<https://openreview.net/pdf?id=ZnxYNriPlg> Yonatan Gideon

- א. הפונקציה הזו מתאימה משום שהיא תדאג לקרב $\mathbf{X}\mathbf{w}$ ל- $\mathbf{y}$, אך גם חזאים של דוגמאות שעברו את הטרנספורמציה, $\mathbf{XGw}$, היא תקרב ל- $\mathbf{y}$. למעשה אפשר לראות זאת כאילו הכנסנו לסט הדוגמאות עוד דוגמאות שעברו טרנספורמציה $\mathbf{XG}$.
- ב. עבור $\mathbf{w} \rightarrow \mathbf{Gw}$ מתקיים:

$$\begin{aligned}\mathcal{L}_1(\mathbf{Gw}) &= \frac{1}{2} \sum_{\tilde{\mathbf{G}} \in \mathcal{G}} \|\mathbf{y} - \mathbf{x}\tilde{\mathbf{G}}^T \mathbf{Gw}\|^2 = \frac{1}{2} \sum_{\tilde{\mathbf{G}} \in \mathcal{G}} \|\mathbf{y} - \mathbf{x}\tilde{\mathbf{G}}^T \mathbf{Gw}\|^2 \\ &= \frac{1}{2} \sum_{\tilde{\mathbf{G}} \in \mathcal{G}} \|\mathbf{y} - \mathbf{x}(\mathbf{G}^T \tilde{\mathbf{G}})^T \mathbf{w}\|^2 = \frac{1}{2} \sum_{\tilde{\mathbf{G}} \in \mathcal{G}} \|\mathbf{y} - \mathbf{x}\tilde{\mathbf{G}}^T \mathbf{w}\|^2\end{aligned}$$

ג. כאשר בשיויון האחרון סימנו $\tilde{\mathbf{G}} = \mathbf{G}^T \mathbf{G}$ השתמשנו בתכונות (1) ו-(3) שהנחנו על $\mathbf{G} \in \mathcal{G}$.

$$\begin{aligned}\mathcal{L}_1(\mathbf{w}) &= \frac{1}{2} \sum_{\mathbf{G} \in \mathcal{G}} \|\mathbf{y} - \mathbf{XG}^T \mathbf{w}\|^2 \\ \nabla_{\mathbf{w}} \left[\frac{1}{2} \sum_{\mathbf{G} \in \mathcal{G}} \|\mathbf{y} - \mathbf{XG}^T \mathbf{w}\|^2 \right] &= \nabla_{\mathbf{w}} \left[\frac{1}{2} \sum_{\mathbf{G} \in \mathcal{G}} (\mathbf{y} - \mathbf{XG}^T \mathbf{w})^T (\mathbf{y} - \mathbf{XG}^T \mathbf{w}) \right] \\ &= \frac{1}{2} \sum_{\mathbf{G} \in \mathcal{G}} \nabla_{\mathbf{w}} [\mathbf{y}^T \mathbf{y} - \mathbf{y}^T \mathbf{XG}^T \mathbf{w} - \mathbf{w}^T \mathbf{GX}^T \mathbf{y} + \mathbf{w}^T \mathbf{GX}^T \mathbf{XG}^T \mathbf{w}] \\ &= \frac{1}{2} \sum_{\mathbf{G} \in \mathcal{G}} -2\mathbf{GX}^T \mathbf{y} + 2\mathbf{GX}^T \mathbf{XG}^T \mathbf{w} = \mathbf{0} \\ \Rightarrow \mathbf{w}_1^* &= \left(\sum_{\mathbf{G} \in \mathcal{G}} \mathbf{G}^T \mathbf{X}^T \mathbf{XG} \right)^{-1} \left(\sum_{\mathbf{G} \in \mathcal{G}} \mathbf{G} \right) \mathbf{X}^T \mathbf{y}\end{aligned}$$

שזה מה שהיינו צריכים להוכיח.

ד. נראה כי $\tilde{\mathbf{G}}\mathbf{R} = \mathbf{R}$ לכל $\tilde{\mathbf{G}} \in \mathcal{G}$.

$$\tilde{\mathbf{G}}\mathbf{R} = \tilde{\mathbf{G}} \sum_{\mathbf{G} \in \mathcal{G}} \mathbf{G} = \sum_{\mathbf{G} \in \mathcal{G}} \tilde{\mathbf{G}}\mathbf{G} = \sum_{\mathbf{G}' \in \mathcal{G}} \mathbf{G}' = \mathbf{R}$$

כאשר בשיויון האחרון סימנו $\mathbf{G}' = \tilde{\mathbf{G}}\mathbf{G}$ והשתמשנו ב-(3).

ה. נראה כי $\tilde{\mathbf{G}}\mathbf{K}^{-1}\tilde{\mathbf{G}}^T = \mathbf{K}^{-1}$ לכל $\tilde{\mathbf{G}} \in \mathcal{G}$.

$$\begin{aligned}
\tilde{\mathbf{G}}\mathbf{K}^{-1}\tilde{\mathbf{G}}^T &= \tilde{\mathbf{G}}\left(\sum_{\mathbf{G} \in \mathcal{G}} \mathbf{G}^T \mathbf{X}^T \mathbf{X} \mathbf{G}\right)^{-1} \tilde{\mathbf{G}}^T = \left((\tilde{\mathbf{G}}^T)^{-1} \left(\sum_{\mathbf{G} \in \mathcal{G}} \mathbf{G}^T \mathbf{X}^T \mathbf{X} \mathbf{G}\right) (\tilde{\mathbf{G}})^{-1}\right)^{-1} \\
&= \left(\tilde{\mathbf{G}} \left(\sum_{\mathbf{G} \in \mathcal{G}} \mathbf{G}^T \mathbf{X}^T \mathbf{X} \mathbf{G}\right) \tilde{\mathbf{G}}^T\right)^{-1} = \left(\sum_{\mathbf{G} \in \mathcal{G}} \tilde{\mathbf{G}} \mathbf{G}^T \mathbf{X}^T \mathbf{X} \mathbf{G} \tilde{\mathbf{G}}^T\right)^{-1} \\
&= \left(\sum_{\mathbf{G} \in \mathcal{G}} (\mathbf{G} \tilde{\mathbf{G}}^T)^T \mathbf{X}^T \mathbf{X} \mathbf{G} \tilde{\mathbf{G}}^T\right)^{-1} = \left(\sum_{\mathbf{G} \in \mathcal{G}} \bar{\mathbf{G}}^T \mathbf{X}^T \mathbf{X} \bar{\mathbf{G}}\right)^{-1} = \mathbf{K}^{-1}
\end{aligned}$$

כאשר בשיויון הראשון השתמשנו בתכונה $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$, בשיויון השני בתכונת האורתוגונליות (2), ובשיויון האחרון סימנו $\bar{\mathbf{G}} = \mathbf{G}\tilde{\mathbf{G}}^T$ והשתמשנו בתכונה (3).

1. נראה כי $\tilde{\mathbf{G}}\mathbf{w}_1^* = \mathbf{w}_1^*$ לכל $\tilde{\mathbf{G}} \in \mathcal{G}$.

$$\tilde{\mathbf{G}}\mathbf{w}_1^* = \tilde{\mathbf{G}}\mathbf{K}^{-1}\mathbf{R}\mathbf{X}^T\mathbf{y} = \tilde{\mathbf{G}}\mathbf{K}^{-1}\tilde{\mathbf{G}}^T\tilde{\mathbf{G}}\mathbf{R}\mathbf{X}^T\mathbf{y} = \mathbf{K}^{-1}\mathbf{R}\mathbf{X}^T\mathbf{y} = \mathbf{w}_1^*$$

מכאן, החזאי אינווארינטי לכל טרנספורמציה $\mathbf{G} \in \mathcal{G}$:

$$\hat{\mathbf{y}}(\mathbf{G}\mathbf{x}) = \mathbf{x}^T \mathbf{G}^T \mathbf{w}_1^* = \mathbf{x}^T \mathbf{w}_1^*$$

כאשר השתמשנו בתכונה (1).


2. נציע את הפונקציה:

$$\mathcal{L}_2(\mathbf{w}) = \frac{1}{2} \sum_{\mathbf{G} \in \mathcal{G}} \|\mathbf{Y}\mathbf{G}^T - \mathbf{X}\mathbf{G}^T\mathbf{w}\|^2$$

בדומה לסעיף א', פונקציית המחיר הזו "מוסיפה" דוגמאות אימון המקיימות אקוויוריאנטיות.

פתרון שאלה מס' 3: גזירה (35%)

א. כדי ששאר השאלה תהיה פשוטה, נבחר את הגרף הכי פשוט שאנחנו יכולים



ב. קודם נחשב פעפוע קדמי של הערכים:

$$v_1 = \exp(x_1 + x_2^3)x_3 = e^3, v_2 = \sqrt{x_3 \sin(\pi(x_1 - x_2)/2)} = 1$$

$$\rightarrow v_3 = v_1 + v_2 = e^3 + 1$$

כעת פעפוע קדמי של הנגזרות:

$$\dot{v}_1 \triangleq \frac{\partial v_1}{\partial x_1} = \exp(x_1 + x_2^3)x_3 = e^3$$

$$\dot{v}_2 \triangleq \frac{\partial v_2}{\partial x_1} = \frac{\pi \cos(\pi(2 - 1)/2)}{\sqrt{16 \sin(\pi(2 - 1)/2)}} = 0$$

$$\rightarrow \dot{v}_3 \triangleq \frac{\partial v_3}{\partial v_{-2}} = \frac{\partial v_3}{\partial x_1} = \dot{v}_1 + \dot{v}_2 = e^3$$

ג. מכיוון שזו אותה נקודה כמו בסעיף קודם, נשתמש באותו פעפוע קדמי. נשאר לחשב פעפוע אחורי של

הנגזרות:

$$\bar{v}_3 \triangleq \frac{\partial v_3}{\partial v_3} = 1, \bar{v}_2 \triangleq \frac{\partial v_3}{\partial v_2} = 1, \bar{v}_1 \triangleq \frac{\partial v_3}{\partial v_1} = 1$$

$$\begin{aligned}\bar{v}_{-1} &\triangleq \frac{\partial v_3}{\partial v_0} = \frac{\partial v_3}{\partial x_2} = \frac{\partial v_3}{\partial v_1} \frac{\partial v_1}{\partial x_2} + \frac{\partial v_3}{\partial v_2} \frac{\partial v_2}{\partial x_2} \\ &= 1 \cdot 3x_2^2 \exp(x_1 + x_2^3)x_3 + 1 \cdot \frac{-\pi \cos(\pi(2-1)/2)}{\sqrt{16 \sin(\pi(2-1)/2)}} = 3e^3\end{aligned}$$

ד. נחשב בשיטת ה-central difference, מכיוון שהיא משיגה שגיאה נמוכה יחסית ופשוטה למימוש. כפי שהומלץ בהרצאה, נשתמש בגודל צעד

$$h = \left(1 + \max_i |x_i|\right) \sqrt{\epsilon} = 0.02$$

ונקבל

$$(\exp(2)(1+h) - \exp(2)(1-h))/(2h) = \exp(2)$$

ה. בגזירה נומרית ו-Forward mode autodiff הבעיה העיקרית היא שחישוב הנגזרת צריך להתבצע כמספר משתני הכניסה (כלומר, המשתנים שלפיהם גוזרים) – מספר זה לרוב הוא מאוד גדול (למשל, המשקולות ברשת עמוקה. זו אינה בעיה ב-Backward mode autodiff שם צריך לבצע את החישוב רק פעם אחת לכל משתני הכניסה.

בנוסף: בגזירה נומרית גם יש בעיה מסוימת של רעש נומרי (אם כי בד"כ בלמידת מכונה זו לא הבעיה העיקרית), ומצד שני זו היא שיטה מאוד פשוטה למימוש. ל-Forward mode autodiff יש יתרון שניתן ביעילות לגזור על פני גרף עם מספר רב של מוצאים, בעוד שבשאר השיטות בד"כ צריך לבצע את כל החישוב מחדש לכל מוצא. לעומת זאת, החיסרון העיקרי של Backward mode autodiff הוא שצריך לשמור בזיכרון את הערכים שחושבו בפעפוע הקדמי.