

חורף תשפ"ד
18.9.2024

הטכניון-מכון טכנולוגי לישראל
הפקולטה להנדסת חשמל ומחשבים

למידה עצמית - 046211
פתרון בחינה סופית - מועד א'

פתרון שאלה 1

א. לפי מה שלמדנו בהרצאות האיתחול הנדרש של המשקולות הוא גאוסי i.i.d. עם ממוצע אפס ושונות

$$\sigma_l = \frac{1}{\sqrt{d_{l-1} E_{z \sim N(0,1)} [\varphi_{l-1}^2(z)]}}$$

בשכבה הראשונה, בה אין פונקציית אקטיבציה בכניסה (כלומר פונקציית האקטיבציה היא זהות), הצבה בנוסחה נותן:

$$\mathbf{w}[i, j] \sim N(0, \frac{1}{d})$$

חישוב דומה עבור השכבה השנייה (בה פונקציית האקטיבציה היא ReLU), ייתן אתחול He:

$$\mathbf{w}'[i, j] \sim N(0, \frac{2}{d})$$

הערה: מה שחשוב בביטויים מעלה הם הממוצע והשונות, שנובעים מהחישוב. הבחירה של הפילוג כאן (גאוסי) היא לפי המקובל אבל אפשר גם דברים אחרים (כמו פילוג אחיד).

ב. כמו שראינו בהרצאה, מחוק השונות הכוללת (כאמור, השונות כאן מופעלת רכיב-רכיב):

$$\begin{aligned} \text{Var}(\mathbf{u}_{l+1}) &= E\text{Var}(\mathbf{u}_{l+1} | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_{l+1} | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(\mathbf{u}_l) = \text{Var}(\mathbf{u}_l) + \text{Var}(\mathbf{u}_l) \\ &= 2\text{Var}(\mathbf{u}_l) = 2^l \text{Var}(\mathbf{u}_0) \rightarrow \infty \end{aligned}$$

כאשר השיויון השני נובע ממשוואה (1) והשלישי ממשוואה (2).

ג. כדי לקבל אתחול שמקיים את (3) ו-(4), פשוט נכפיל את האתחול של שתי השכבות מסעיף א' ב- $c_l^{1/4}$. עבור אתחול זה, בדומה לפיתוח מסעיף ב'

$$\begin{aligned} \text{Var}(\mathbf{u}_{l+1}) &= E\text{Var}(\mathbf{u}_{l+1} | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_{l+1} | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(E(\mathbf{u}_l + \mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l)) \\ &= E\text{Var}(\mathbf{F}_l(\mathbf{u}_l) | \mathbf{u}_l) + \text{Var}(\mathbf{u}_l) = c_l \text{Var}(\mathbf{u}_l) + \text{Var}(\mathbf{u}_l) \end{aligned}$$

$$= (1 + c_l) \text{Var}(\mathbf{u}_l) = \text{Var}(\mathbf{u}_0) \prod_{l'=1}^l (1 + c_{l'}) < \infty$$

מכאן תנאי מספיק למניעת התפוצצות הוא $\prod_{l=1}^{\infty} (1 + c_l) < \infty$.

אפשר לפשט תנאי זה עוד (אבל לא חובה בשביל לזכות במלוא הניקוד). נתחיל בהפעלת לוג על שני הצדדים

$$\sum_{l=1}^{\infty} \log(1 + c_l) < \infty$$

שימוש בחסם $\log(1 + x) \leq x$ ייתן תנאי מספיק פשוט יותר

$$\sum_{l=1}^{\infty} c_l < \infty$$

תנאי המתקיים למשל עבור $c_l = 1/l^2$.

ד. עבור אתחול אפס, $\mathbf{u}_{l+1} = \mathbf{u}_l$ ולכן בפרט $\text{Var}(\mathbf{u}_{l+1}) = \text{Var}(\mathbf{u}_l) = \text{Var}(\mathbf{u}_0) = 1$, כלומר אין התפוצצות או דעיכה של השונות. אבל יש בעיה עם אתחול. כדי לראות אותה, נחשב את הנגזרת של פונקציית ההפסד ℓ על מוצא הרשת ביחס למשקולות, כפי שנרמז:

$$\frac{\partial \ell}{\partial \mathbf{w}'_l[i, j]} = \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[i]} \frac{\partial \mathbf{u}_{l+1}[i]}{\partial \mathbf{w}'_l[i, j]} = \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[i]} \varphi(\mathbf{w}_l \mathbf{u}_l)[j] = \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[i]} \varphi(\mathbf{0} \mathbf{u}_l)[j] = 0$$

$$\begin{aligned} \frac{\partial \ell}{\partial \mathbf{w}_l[i, j]} &= \frac{\partial \ell}{\partial \mathbf{u}_{l+1}} \frac{\partial \mathbf{u}_{l+1}}{\partial \mathbf{w}_l[i, j]} = \sum_k \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[k]} \frac{\partial \mathbf{u}_{l+1}[k]}{\partial \varphi(\mathbf{w}_l \mathbf{u}_l)[i]} \frac{\partial \varphi(\mathbf{w}_l \mathbf{u}_l)[i]}{\partial \mathbf{w}_l[i, j]} \\ &= \left(\sum_k \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[k]} \mathbf{w}'_l[k, i] \right) \varphi'(\mathbf{w}_l \mathbf{u}_l)[i] \mathbf{u}_l[j] \\ &= \left(\sum_k \frac{\partial \ell}{\partial \mathbf{u}_{l+1}[k]} 0 \right) \varphi'(\mathbf{w}_l \mathbf{u}_l)[i] \mathbf{u}_l[j] = 0 \end{aligned}$$

מכאן, הגרדיאנט יהיה אפס, ו-SGD יתקע ולא נוכל ללמוד כלום.

ה. הפתרון הוא להשתמש בשכבת נרמול כמו למשל עם Batch-Norm או Layer-norm. יתרון בשכבה כזו שהיא דואגת לנרמול גם אחרי האתחול (כלומר, בזמן האימון). חסרון לדוגמא הוא העלות החישובית של שכבות אלה, שיכול להיות משמעותי.

פתרון שאלה 2

א. בשיטה זו:

$$\begin{aligned}\frac{d\mathbf{a}(t)}{dt} &= \frac{d}{dt} \frac{d\mathbf{v}(t)}{d\mathbf{w}} = \frac{d}{d\mathbf{w}} \frac{d\mathbf{v}(t)}{dt} = \frac{d}{d\mathbf{w}} \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t) \\ &= \frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t)}{\partial \mathbf{w}} + \frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t)}{\partial \mathbf{v}(t)} \frac{d\mathbf{v}(t)}{d\mathbf{w}}\end{aligned}$$

כלומר

$$\frac{d\mathbf{a}(t)}{dt} = \frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t)}{\partial \mathbf{w}} + \frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t)}{\partial \mathbf{v}(t)} \mathbf{a}(t)$$

ב. מפתרון המד"ר (*) נקבל את $\mathbf{v}(t)$ לכל $t \in [0, T]$. לאחר מכן (או במקביל) נוכל לפתור את המד"ר שקיבלנו בסעיף א' אותה נריץ החל מאתחול אפס, מכיוון שהאתחול $\mathbf{v}(0) = \mathbf{v}_0$ אינו פונקציה של $\mathbf{w}$:

$$\mathbf{a}(0) = \frac{\partial \mathbf{v}(0)}{\partial \mathbf{w}} = 0$$

ונקבל את $\mathbf{a}(t)$ לכל $t \in [0, T]$. לבסוף נוכל לחשב את הגרדיאנט המבוקש באמצעות

$$\nabla C(\mathbf{w}) = \frac{1}{2} \frac{d}{d\mathbf{w}} \|\mathbf{v}(T)\|^2 = \mathbf{v}(T)^\top \frac{\partial \mathbf{v}(T)}{\partial \mathbf{w}} = \mathbf{v}(T)^\top \mathbf{a}(T)$$

ג. הלגרנז'יאן

$$\mathcal{L}(\mathbf{w}, \mathbf{v}, \mathbf{b}, \boldsymbol{\lambda}) = \frac{1}{2} \|\mathbf{v}(T)\|^2 + \int_0^T \mathbf{b}(t)^\top (\mathbf{f}(\mathbf{w}, \mathbf{v}(t), t) - \frac{d\mathbf{v}(t)}{dt}) dt + \boldsymbol{\lambda}^\top (\mathbf{v}_0 - \mathbf{v}(0))$$

כולל, משמאל לימין, את פונקציית המחיר, את האילוץ של קיום המד"ר (*) ואת האילוץ של תנאי ההתחלה של המד"ר (*). $\mathbf{b}$ ו- $\boldsymbol{\lambda}$ הם כופלי לגרנז', כאשר $\mathbf{b} = \{\mathbf{b}(t) | t \in [0, T]\}$, $\mathbf{v} = \{\mathbf{v}(t) | t \in [0, T]\}$ הם אוסף של וקטורים על האינטרוול $[0, T]$.

ד. זה נובע מאינטגרציה בחלקים:

$$\begin{aligned}\int_0^T \mathbf{b}(t)^\top \frac{d\mathbf{v}(t)}{dt} dt &= \int_0^T \left(\frac{d}{dt} (\mathbf{b}(t)^\top \mathbf{v}(t)) - \frac{d\mathbf{b}(t)^\top}{dt} \mathbf{v}(t) \right) dt \\ &= \mathbf{b}(T)^\top \mathbf{v}(T) - \mathbf{b}(0)^\top \mathbf{v}(0) - \int_0^T \frac{d\mathbf{b}(t)^\top}{dt} \mathbf{v}(t) dt\end{aligned}$$

לכן, ניתן לרשום

$$\begin{aligned}\mathcal{L}(\mathbf{w}, \mathbf{v}, \mathbf{b}, \boldsymbol{\lambda}) &= \frac{1}{2} \|\mathbf{v}(T)\|^2 - \mathbf{b}(T)^\top \mathbf{v}(T) + \mathbf{b}(0)^\top \mathbf{v}(0) \\ &\quad + \int_0^T \left(\frac{d\mathbf{b}(t)^\top}{dt} \mathbf{v}(t) + \mathbf{b}(t)^\top \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t) \right) dt + \boldsymbol{\lambda}^\top (\mathbf{v}_0 - \mathbf{v}(0))\end{aligned}$$

ה. כרגיל, גזירה של הלגרנז'יאן לפי כופל הלגרנז' $\mathbf{b}$ תיתן את האילוץ, כלומר המד"ר (*).

כפי שלמדנו בכיתה, נגזור לפי $\mathbf{v}(t)$ ונקבל לכל $t \in (0, T)$

$$\frac{\partial}{\partial \mathbf{v}(t)} \mathcal{L}(\mathbf{w}, \mathbf{v}, \mathbf{b}, \lambda) = \frac{d\mathbf{b}(t)^\top}{dt} + \mathbf{b}(t)^\top \frac{\partial}{\partial \mathbf{v}(t)} \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t) = 0$$

כלומר

$$\frac{d\mathbf{b}(t)}{dt} = - \left[\frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t)}{\partial \mathbf{v}(t)} \right]^\top \mathbf{b}(t)$$

ו. כפי שנתון, נדרוש שהמד"ר מסעיף קודם תתקיים לכל $t \in [0, T]$. לכן איבר האינטגרל בלגרנז'יאן יתאפס.

בקצה $t = T$, נגזור לפי $\mathbf{v}(T)$ ונקבל תנאי התחלה שימושי

$$\frac{\partial}{\partial \mathbf{v}(T)} \mathcal{L}(\mathbf{w}, \mathbf{v}, \mathbf{b}, \lambda) = \mathbf{b}^\top(T) - \mathbf{v}^\top(T) = 0 \Rightarrow \mathbf{b}(T) = \mathbf{v}(T)$$

הערה למתעניינים: בקצה $t = 0$, לא ניתן לקבל תנאי שפה שימושי ל- $\mathbf{v}(0)$ כי

$$\frac{\partial}{\partial \mathbf{v}(0)} \mathcal{L}(\mathbf{w}, \mathbf{v}, \mathbf{b}, \lambda) = \mathbf{b}(0)^\top - \lambda^\top = 0 \Rightarrow \mathbf{b}(0) = \lambda$$

ואנחנו לא יודעים את ערכו של λ (אבל אין צורך לדעת אותו כי פשוט נקיים את האילוץ $\mathbf{v}(0) = \mathbf{v}_0$ ע"י האיתחול של המד"ר (*)).

ז. מפתרון המד"ר (*) עם אתחול $\mathbf{v}_0$ נקבל את $\mathbf{v}^*(t)$ לכל $t \in [0, T]$. לאחר מכן נוכל לפתור את המד"ר שקיבלנו בסעיף ג'. זו משוואה שצריך להריץ אחורה בזמן החל מזמן T , אז ניתן לאתחל $\mathbf{b}^*(T) = \mathbf{v}^*(T)$. כך נקבל את $\mathbf{b}^*(t)$ לכל $t \in [0, T]$. כפי שראינו בהרצאה נוכל לחשב את הגרדיאנט המבוקש (עבור GD) באמצעות התנאי ההכרחי האחרון של כופלי לגרנז'

$$\nabla C(\mathbf{w}) = \frac{\partial}{\partial \mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) = \int_0^T \mathbf{b}^*(t)^\top \frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}^*(t), t)}{\partial \mathbf{w}} dt$$

כאשר $\mathbf{b}^*$ ו- $\mathbf{v}^*$ הן הפתרונות של המד"ר כפי שמוסבר מעלה. הערה למתעניינים: הסיבה לכך היא שמצד אחד

$$\begin{aligned} \frac{d}{d\mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) &= \frac{\partial}{\partial \mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) + \frac{\partial}{\partial \mathbf{v}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) \frac{d\mathbf{v}^*}{d\mathbf{w}} \\ &+ \frac{\partial}{\partial \mathbf{b}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) \frac{d\mathbf{b}^*}{d\mathbf{w}} + \frac{\partial}{\partial \lambda} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) \frac{d\lambda^*}{d\mathbf{w}} = \frac{\partial}{\partial \mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) \end{aligned}$$

$$\frac{\partial}{\partial \mathbf{v}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) = 0, \frac{\partial}{\partial \mathbf{b}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) = 0, \frac{\partial}{\partial \lambda} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) = 0$$

ומצד שני, מכיוון שכל האילוצים מתקיימים בשיוויון

$$\mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) = C(\mathbf{w}) \Rightarrow \frac{d}{d\mathbf{w}} \mathcal{L}(\mathbf{w}, \mathbf{v}^*, \mathbf{b}^*, \lambda) = \nabla C(\mathbf{w})$$

ח. השיטה הראשונה היא forward mode, והשנייה היא reverse mode. הבעיה בשיטה הראשונה היא שבכל זמן t שצריך לחשב ולשמור את $\mathbf{a}(t) \in \mathbb{R}^{dp}$ שהוא ממימד הרבה יותר גדול מאשר $\mathbf{b}(t) \in \mathbb{R}^d$. הבעיה בשיטה השנייה היא שצריך לשמור את $\mathbf{v}(t) \in \mathbb{R}^d$ לכל $t \in [0, T]$ כאשר עושים את הפעופע לאחר.

הערה כללית למתעניינים: בשאלה, במקום הפיתוחים בזמן רציף והשימוש בלגרנז'יאן, ניתן היה לחשב את כל התוצאות באמצעות דיסקרטזציה בזמן (חלוקה לצעדים קטנים)

$$\mathbf{v}(t) = \mathbf{v}(t - \epsilon) + \epsilon \mathbf{f}(\mathbf{w}, \mathbf{v}(t - \epsilon), t - \epsilon) \quad (*)$$

שימוש ב-Backpropagation רגיל (המשוואות דומות לרשת עם משוב), ולקחת גבול הרצף ($\epsilon \rightarrow 0$).

לדוגמא, אם היינו מגדירים $\mathbf{b}(t) \triangleq \frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t)}$, בדומה לגודל אותו אנחנו מפעפעים אחורה ב-Backpropagation, אז היינו יכולים לחשב את $\frac{d\mathbf{b}(t)}{dt}$ ללא שימוש בכופלי לגרנז':

$$\begin{aligned} \frac{d\mathbf{b}(t)}{dt} &= \lim_{\epsilon \rightarrow 0} \frac{\mathbf{b}(t) - \mathbf{b}(t - \epsilon)}{\epsilon} = \lim_{\epsilon \rightarrow 0} \frac{1}{\epsilon} \left(\frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t)} - \frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t - \epsilon)} \right) \\ &= \lim_{\epsilon \rightarrow 0} \frac{1}{\epsilon} \left(\frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t)} - \frac{\partial \mathbf{v}(t)}{\partial \mathbf{v}(t - \epsilon)} \frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t)} \right) = \lim_{\epsilon \rightarrow 0} \frac{1}{\epsilon} \left(\left(\mathbf{I} - \frac{d\mathbf{v}(t)}{d\mathbf{v}(t - \epsilon)} \right) \frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t)} \right) \\ &= \lim_{\epsilon \rightarrow 0} \frac{1}{\epsilon} \left(\left(\mathbf{I} - \frac{\partial}{\partial \mathbf{v}(t - \epsilon)} (\mathbf{v}(t - \epsilon) + \epsilon \mathbf{f}(\mathbf{w}, \mathbf{v}(t - \epsilon), t - \epsilon) + O(\epsilon^2)) \right) \frac{\partial C(\mathbf{w})}{\partial \mathbf{v}(t)} \right) \\ &= \lim_{\epsilon \rightarrow 0} \left(- \left[\frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t - \epsilon), t - \epsilon)}{\partial \mathbf{v}(t - \epsilon)} \right]^T \mathbf{b}(t) + O(\epsilon) \right) = - \left[\frac{\partial \mathbf{f}(\mathbf{w}, \mathbf{v}(t), t)}{\partial \mathbf{v}(t)} \right]^T \mathbf{b}(t) \end{aligned}$$

את תנאי הסיום ניתן לקבל גם ישירות מההגדרה

$$\mathbf{b}(T) \triangleq \frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{v}(T)} = \frac{\partial}{\partial \mathbf{v}(T)} \left(\frac{1}{2} \|\mathbf{v}(T)\|^2 \right) = \mathbf{v}(T)$$

א. זוהי בעיית סיווג, לכן פונקציית המחיר הרלוונטי היא Softmax-CrossEntropy, שנשמנה ב- ℓ ,

ונפעיל אותה על כל התווים שאנחנו רוצים לחזות כדי לקבל את שגיאת האימון:

$$\mathcal{L}(\theta) = \sum_{t=2}^T \ell(\mathbf{x}_t, \hat{\mathbf{x}}_t) = - \sum_{t=2}^T \sum_{i=1}^d \mathbf{x}_t[i] \log \left(\frac{\exp(\hat{\mathbf{x}}_t[i])}{\sum_{j=1}^d \exp(\hat{\mathbf{x}}_t[j])} \right)$$

ב. ב-teacher forcing אנחנו מחשבים את פונקציית המחיר ע"י כך שבכל זמן אנחנו מציבים את הערך

האימיתי של $\{\mathbf{x}_t\}_{t=1}^T$ במשוואות המצב של המודל:

$$\forall t = 1, \dots, T-1: \mathbf{v}_t = \varphi(\mathbf{W}\mathbf{v}_{t-1} + \mathbf{B}\mathbf{x}_t)$$

כאשר ללא teacher forcing, החישוב משתמש בערך המשוערך של $\{\mathbf{x}_t\}_{t=1}^T$

$$\forall t = 2, \dots, T-1: \mathbf{v}_t = \varphi(\mathbf{W}\mathbf{v}_{t-1} + \mathbf{B}\hat{\mathbf{x}}_t)$$

לכל הצעדים אחרי הצעד הראשון.

ג. הבעיה ש-teacher forcing מנסה לפתור היא ששערוך סדרת התווים הוא לא מדויק, במיוחד בתחילת

האימון, ולכן הוא יביא לחישוב לא יציב של שגיאת האימון, מה שיקשה על האימון להתכנס. לאחר

האימון, בזמן ההסקה, אין לנו ידע על $\{\mathbf{x}_t\}_{t=1}^T$ מלבד כמה מהאיברים הראשונים שלו (הפרומפט).

לאחר שנכניס את התווים האלו, לשאר המשפט נשמש בחיזוי של הרשת המאומנת $\hat{\mathbf{x}}_t$

$$\mathbf{v}_t = \varphi(\mathbf{W}\mathbf{v}_{t-1} + \mathbf{B}\hat{\mathbf{x}}_t)$$

ד. מודל רב שכבתי, עם L שכבות נראה כך:

$$\forall t = 1, \dots, T-1, \forall l = 1, \dots, L: \mathbf{v}_t^l = \varphi(\mathbf{W}^l \mathbf{v}_{t-1}^l + \mathbf{B}^l \mathbf{v}_t^{l-1}) ; \mathbf{v}_t^0 = \mathbf{x}_t$$


$$\hat{\mathbf{y}}_t = \sum_{l=1}^L \mathbf{C}^l \mathbf{v}_t^l$$

כפי שלמדנו בהרצאה, מודל כזה מאפשר לבנות ייצוג היררכי של המשפט (למשל: תוויות, הברות,

מילים, חלקי משפט, משפטים, פסקאות, פרקים,...), בדומה למה שקורה ברשתות קונוולוציה עבור

תמונות. חישוב ע"י wavefront, שעוזר במקבול החישוב (ומאיץ אותו) מתבצע לפי הציור הבא:

RNN modules state:



- ה. לא ניתן להשתמש ברשתות אלה במצב בו מקבלים את סדרת הקלט בצורה סדרתית וצריך לחזות את המוצא בכל צעד זמן בהתבסס על ההיסטוריה של סדרת הקלט עד כה (כמו במשימת החיזוי האוטו-רגרסיבית), מכיוון שהן דורשות ידע על העתיד.
- ו. רשתות אלה נדרשות כאשר בשביל החיזוי צריך ידע על העתיד, כמו הדוגמא של השלמת "טבעוני" בחלק החסר (****) במשפט: "אני **** [הרבה טקסט...] אני לא אוכל מוצרים מן החי".
- ז. מצד אחד, מכיוון שהפלט הוא בקידוד one-hot, הרשת צריכה להיות מסוגלת לייצג KM וקטורים אורתוגונליים. מצד שני המוצא של הרשת $\hat{\mathbf{y}}_t = \mathbf{C}\mathbf{v}_t + \bar{\mathbf{C}}\bar{\mathbf{v}}_t$ מורכב מסכום של שני וקטורים, כאשר אחד תלוי רק בעבר ואחד רק בעתיד. לכן לוקטור הראשון יש K אפשרויות ולוקטור השני יש M אפשרויות. לכן בסה"כ המוצא חייב להיות בתת מרחב הנפרש ע"י $K + M$ וקטורים. אבל מכיוון שאמרנו שהמוצא צריך לייצג KM וקטורים אורתוגונליים, חייב להתקיים $KM \leq K + M$, שזה בלתי אפשרי עבור $K > 2$ ו- $M > 2$.
- ח. ברשת זו אנחנו מריצים את הרשת על הקלט בשני כיוונים מנוגדים בכל שכבה, ומקבלים קלט משני הכיוונים בשכבה הקודמת. ספציפית נגדיר $\mathbf{v}_t^0 = \mathbf{x}_t$; $\bar{\mathbf{v}}_t^0 = 0$ בתור הכניסה לרשת, ואז בכל שכבה $(\forall l = 1, \dots, L)$ נפעיל:

$$\forall t = 1, \dots, T-1: \mathbf{v}_t^l = \varphi(\mathbf{W}^l \mathbf{v}_{t-1}^l + \mathbf{B}^l \mathbf{v}_t^{l-1} + \mathbf{C}^l \bar{\mathbf{v}}_t^{l-1})$$

$$\forall t = T-1, \dots, 1: \bar{\mathbf{v}}_t^l = \varphi(\bar{\mathbf{W}}^l \bar{\mathbf{v}}_{t+1}^l + \bar{\mathbf{B}}^l \mathbf{v}_t^{l-1} + \bar{\mathbf{C}}^l \bar{\mathbf{v}}_t^{l-1})$$

כאשר המוצא הוא שילוב משני הכיוונים: $\hat{\mathbf{y}}_t = \sum_{l=1}^L (\mathbf{D}_l \mathbf{v}_t^l + \bar{\mathbf{D}}_l \bar{\mathbf{v}}_t^l)$. ברשת זו המוצא הוא פונקציה לא לינארית כללית של העבר והעתיד, ואין בעיה לייצג KM וקטורים אורתוגונליים כמו בסעיף הקודם (כל עוד הרשת מספיק גדולה).