

למידה עצמית - 046211
בחינה סופית - מועד ב'

משך המבחן: 3 שעות

1. ניתן להשתמש ב-2 דפי נוסחאות (4 עמודים) ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.
6. אם קיבלת אישור מיוחד (עקב שירות מילואים), ניתן לבחור לענות רק על 2 שאלות מתוך 3. במקרה זה, הניקוד הכולל ינורמל חזרה ל-100.
7. כשסיימת את הבחינה, נא להעלות ל-Gradescope את הבחינה. בנוסף, יש להגיש את מחברת הבחינה (עליה כתוב הפתרון).

ב ה צ ל ח ה !!!

שאלה מס' 1 – למידה סידרתית ושכחה (30%)

בכיתה התמקדנו במקרה הרגיל של למידה מונחית, בו אנו רוצים למזער פונקציית מחיר על סט אימון נתון עם N דוגמאות מתויגות במימד d , שנשמך $\mathcal{D} = \{\mathbf{x}^{(n)}, y^{(n)}\}_{n=1}^N$. אז, ע"י אלגוריתם כמו SGD, אנחנו מוצאים את הפרמטרים $\mathbf{w}$ של חזאי $f(\mathbf{w}, \mathbf{x})$ ע"י מיזעור הסיכון האמפירי עם פונקציית הפסד נתונה ℓ

$$\mathcal{L}(\mathbf{w}) = \sum_{n=1}^N \ell(f(\mathbf{w}, \mathbf{x}^{(n)}), y^{(n)})$$

אבל, לעיתים, לא תמיד תהיה לנו גישה לסט האימון המלא, ונוכל לאמן כל פעם רק על חלק מסט האימון שנשמך ב- $\{1, \dots, N\}$, S_k , שמתקבל בצורה סידרתית $(k = 1, 2, \dots, K)$.

א. מתי מצב כזה יכול להתרחש בעולם האמיתי? תנו דוגמא.

תחילה נבחן את שיטת האימון הפשוטה ביותר, בה בכל שלב נאתחל את הפרמטרים במה שמצאנו בשלב הקודם, ואז, ע"י SGD, נמזער את הסיכון האמפירי על S_k :

$$\mathcal{L}_k(\mathbf{w}) = \sum_{n \in S_k} \ell(f(\mathbf{w}, \mathbf{x}^{(n)}), y^{(n)})$$

ב. אחת הבעיות העיקריות של שיטה זו היא "שכחה" של מה שהרשת למדה במשימות הקודמות. הסבירו במשפט את האינטואיציה למה זה קורה.

ג. כדי לפתור את בעיית השכחה יעל וריתי חשבו לאמן רשת נפרדת על כל חלק S_k . בזמן הבוחן, יעל הציעה להשתמש בממוצע של מוצאי הרשתות. לעומת זאת, הציעה רותי למצע את המשקולות של כל הרשתות כדי לקבל רשת בה נשתמש בזמן הבוחן. מה היתרונות והחסרונות של כל שיטה?

מכאן ואילך, לשם הפשטות, נתרכז בבעיית רגרסיה לינארית, כלומר חזאי לינארי $f(\mathbf{w}, \mathbf{x}) = \mathbf{w}^T \mathbf{x}$ עם פונקציית הפסד ריבועית $\ell(y, \hat{y}) = (y - \hat{y})^2$. הניחו כי $d < \frac{N}{K} = |S_k|$, $\text{Span}\{\mathbf{x}^{(n)}\}_{n \in S_k} = d$ וכי בכל חלק נאמן עם SGD עד שמגיעים למינימום על חלק זה.

ד. לאיזה פתרון נתכנס בסוף כל חלק (כפונקציה של סט האימון)? כתבו ביטוי אנליטי. הסבירו מדוע יש שכחה מוחלטת במקרה זה.

ה. כעת נוסיף רגולריזציה לאימון כל חלק S_k , כך שנמזער את

$$\mathcal{L}_k(\mathbf{w}) = \sum_{n \in S_k} (\mathbf{w}^T \mathbf{x}^{(n)} - y^{(n)})^2 + \lambda \|\mathbf{w} - \mathbf{w}_{k-1}\|^2$$

כאשר $\mathbf{w}_k$ הוא הפתרון על החלק S_k , ו- $\mathbf{w}_0 = \mathbf{0}$. לאיזה פתרון נתכנס בסוף כל חלק (כפונקציה של סט האימון, $\mathbf{w}_{k-1}$, ו- λ)? האם זה יכול לעזור למנוע שכחה? כיצד?

שאלה מס' 2 – מומנטום (35%)

בשאלה זו נבחן את קצב ההתכנסות ותנאי ההתכנסות של אופטימיזציה עם מומנטום. אנו רוצים למזער את הפונקציה $f: \mathbb{R}^d \rightarrow \mathbb{R}$ שהיא גזירה ברציפות אינסוף פעמים, ויש לה מינימום סופי, כלומר $\min_{\mathbf{w} \in \mathbb{R}^d} f(\mathbf{w}) = f_* > -\infty$. כלל העדכון למומנטום (Heavy ball momentum) הינו:

$$\mathbf{v}(t) = \gamma \mathbf{v}(t-1) + \nabla f(\mathbf{w}(t-1))$$

$$\mathbf{w}(t) = \mathbf{w}(t-1) - \eta \mathbf{v}(t)$$

כאשר $\mathbf{v}(0) = \mathbf{0}$. כפי שראינו בכיתה, סביב נקודה סטציונארית הפונקציה מתנהגת כתבנית ריבועית מהצורה:

$$f(\mathbf{w}) = \frac{1}{2} \mathbf{w}^T \mathbf{H} \mathbf{w}$$

כאשר $\mathbf{H}$ הינו ההסיאן של הפונקציה.

א. השתמשו בפירוק מטריצת ההסיאן $\mathbf{H} = \mathbf{U} \mathbf{\Lambda} \mathbf{U}^T$ כאשר $\mathbf{A}$ מטריצה אלכסונית המורכבת מהערכים העצמיים λ_i של $\mathbf{H}$ ו- $\mathbf{U}$ מטריצת הוקטורים העצמיים. הניחו $\mathbf{z} = \mathbf{U}^T \mathbf{w}$ ו- $\mathbf{q} = \mathbf{U}^T \mathbf{v}$ והראו שניתן לכתוב את כלל העדכון בצורה:

$$\begin{bmatrix} q_i(t) \\ z_i(t) \end{bmatrix} = \mathbf{A}_i \begin{bmatrix} q_i(t-1) \\ z_i(t-1) \end{bmatrix} \quad (*)$$

כאשר האינדקס i מציין את אחד איברים בוקטור הפרמטרים. רשמו מפורשות את מטריצה $\mathbf{A}_i$.

ב. נפרק את $\mathbf{A}_i = \mathbf{V}_i \mathbf{\Sigma}_i \mathbf{V}_i^{-1}$ כאשר $\mathbf{\Sigma}_i$ מטריצה אלכסונית המורכבת מהערכים העצמיים $\sigma_{i,\pm}$ של $\mathbf{A}_i$ ו- $\mathbf{V}_i$ מטריצת הוקטורים העצמיים. הראו שהערכים העצמיים הינם מהצורה:

$$\sigma_{i,\pm} = \frac{1}{2} \left(1 - \eta \lambda_i + \gamma \pm \sqrt{(1 - \eta \lambda_i + \gamma)^2 - 4\gamma} \right)$$

ג. רשמו את הפתרון $\mathbf{h}_i(t) = [q_i(t), z_i(t)]^T \in \mathbb{R}^2$ ל- $(*)$ באמצעות $\mathbf{V}_i, \mathbf{\Sigma}_i, \mathbf{V}_i^{-1}$ ו- $\mathbf{h}_i(0)$. הסבירו בעזרתו מדוע קצב ההתכנסות הוא $\text{rate} = \max_i \max_{\pm} |\sigma_{i,\pm}|$, והתנאי להתכנסות הוא $\text{rate} < 1$.

רמז לסעיפים הבאים: נתון כי $f_{\pm}(x) = |x \pm \sqrt{x^2 - c^2}|$ הן פונקציות מונוטוניות עולה/יורדת (לפי הסימן) בתחום $|x| > |c|$ וקבועות בתחום $|x| < |c|$.

ד. חשבו את $|\sigma_{i,\pm}|$ עבור כל הע"ע שאינם ממשיים. מצאו תנאי על γ כדי שכולם יהיו קטנים מ-1.

מכאן ואילך נניח כי קבענו את γ לערך קבוע כלשהו שמקיים את התנאי מסעיף ד'.

ה. כעת נגדיל את η כך ש $\text{rate} \rightarrow 1$. נסמן ב- $\lambda_{\max}$ את הע"ע הכי גדול של $\mathbf{H}$. הראו כי במקרה זה

$$\text{rate} = \max_i \max_{\pm} |\sigma_{i,\pm}| = \frac{1}{2} \left| 1 - \eta \lambda_{\max} + \gamma - \sqrt{(1 - \eta \lambda_{\max} + \gamma)^2 - 4\gamma} \right|$$

ו. הראו שכדי שהאלגוריתם ייתכנס, צריך להתקיים

$$\eta < \frac{2(1 + \gamma)}{\lambda_{\max}}$$

רמז: הציבו בתנאי מסעיף קודם והראו כי הוא מתקיים.

שאלה מס' 3 – קידוד טרנספורמרים (35%)

בשאלה זו נבחן את התכונות של קידוד המיקום (positional encoding) במודלי טרנספורמרים. נניח שניתן להכניס משפט של עד L מילים (tokens) למקודד הטרנספורמר, ושכל מילה מיוצגת כוקטור באורך d .

- א. הסבירו מה עושה קידוד מיקום מדוע הוא נדרש וכיצד הוא עובד?
- ב. הוצע לממש את קידוד המיקום באופן הבא. נשייך מספר בתחום $[0, 1]$ לכל מילה בכניסה, כך ש-0 מייצג את המילה הראשונה ו-1 את המילה האחרונה. כלומר, נניח שבכניסה סדרת מילים באורך N כך שמתקיים: $N \leq L$. נוסיף לייצוג של כל מילה את המספר
- $$\frac{t}{N-1} \quad 0 \leq t < N$$
- לדוגמא עבור סדרה באורך 4 מילים הקידוד יהיה 0 למילה הראשונה, 0.333 למילה השנייה וכן הלאה. מה הבעיות שעלולות לצוץ מקידוד בצורה הזו? שימו לב שכל משפט באורך N שונה, והאורך המקסימלי הוא L .
- ג. הוחלט להציע קידוד מיקום בצורה שונה. למילה הראשונה משייכים את המספר 1, למילה השנייה 2 וכן הלאה. האם זהו קידוד מיקום שיכול לעבוד? הסבירו מדוע.

מכאן והלאה נראה שפונקציית הקידוד שמשמשת במודל הטרנספורמר מאפשרת למודל ללמוד מיקומים יחסיים, מאחר והיא אינווריאנטית להזזה. נגדיר את פונקציית הקידוד כוקטור באורך d , כך שעבור המילה ה- t בכניסה איברי הוקטור מוגדרים כך:

$$\mathbf{p}_{t,k} = \begin{bmatrix} \sin(\omega_k t) \\ \cos(\omega_k t) \end{bmatrix}$$

כאשר $0 \leq t < N$, $0 \leq k < d$ וכן התדרים הם:

$$\omega_k = 10,000^{-2k/d}$$

כלומר ייצוג הקידוד נעשה על ידי וקטור באורך d המורכב מזוגות כאלו לכל תדירות:

$$\mathbf{p}_t = \begin{bmatrix} \sin(\omega_1 t) \\ \cos(\omega_1 t) \\ \vdots \\ \sin(\omega_{d/2} t) \\ \cos(\omega_{d/2} t) \end{bmatrix}$$

- ד. הסבירו מדוע נקבל קידוד ייחודי עבור כל מיקום של מילה בכניסה, ללא תלות באורך המשפט N .
- ה. הקידוד הזה מאפשר לרשת ללמוד בקלות self-attention של מיקומים יחסיים. נראה שקיימת טרנספורמציה לינארית עבור הסט בקידוד. כלומר, עבור תדר ω_k והסט של τ מצאו את המטריצה $\mathbf{M}_k^\tau \in \mathbb{R}^{2 \times 2}$ המקיימת:

$$\mathbf{p}_{t+\tau,k} = \mathbf{M}_k^\tau \mathbf{p}_{t,k}$$

רמז: השתמשו בזהויות הטריגונומטריות לסכום של זוויות:

$$\sin(\alpha + \beta) = \sin(\alpha)\cos(\beta) + \cos(\alpha)\sin(\beta)$$

$$\cos(\alpha + \beta) = \cos(\alpha)\cos(\beta) - \sin(\alpha)\sin(\beta)$$

- ו. הראו כיצד ניתן להרחיב את הטענה מ- $\mathbf{p}_{t,k}$ לוקטור המלא $\mathbf{p}_t$. כלומר מצאו מטריצה $\mathbf{M}^\tau \in \mathbb{R}^{d \times d}$ עבורה מתקיים:

$$\mathbf{p}_{t+\tau} = \mathbf{M}^\tau \mathbf{p}_t$$