

למידה עמוקה - 046211פתרון בחינה סופית - מועד ב'פתרון שאלה 1

- א. זה יכול לקרות למשל כאשר קיבלנו מודל, ואנחנו רוצים לאמן אותו לבצע גם משימה חדשה, אבל אין לנו גישה לסט האימון המקורי שעליו התאמן המודל. זה יכול לקרות מכל מיני סיבות, למשל, הורדנו את המודל מהאינטרנט (github), אבל אין לנו גישה לסט האימון שלו. יכול להיות גם שהסט האימון לא זמין מסיבות של פרטיות או זכויות יוצרים.
- ב. כאשר לומדים משימה חדשה, העדכונים של SGD לא מודעים כלל למשימה הקודמת, ויכולים לשנות את המשקולות ברשת בצורה שתהרוס את הביצועים שלה על המשימה הקודמת.
- ג. שתי השיטות כנראה יפגעו בביצועים לעומת רשת אחת שאומנה על כל סט האימון, אבל כפי שלמדנו, מיצוע של מוצאי הרשתות בד"כ עובד הרבה יותר טוב מאשר מיצוע של המשקולות. מצד שני השיטה של מיצוע מוצאי הרשתות הרבה יותר כבדה, כי צריך לשמור K רשתות שונות בזמן הבוחן.
- ד. כפי שלמדנו בכיתה, בסוף כל חלק נקבל את הפתרון של רגרסיה לינארית

$$\mathbf{w}_k = (\mathbf{X}_k^T \mathbf{X}_k)^{-1} \mathbf{X}_k^T \mathbf{y}_k$$

כאשר

$$\mathbf{y}_k = [y^{(n)}]_{n \in S_k}, \quad \mathbf{X}_k = [\mathbf{x}^{(n)}]_{n \in S_k}^T$$

במקרה זה יש שכחה מוחלטת, מכיוון שהפתרון בסוף כל חלק לא תלוי כלל בנתונים משימות קודמות.

ה. נבצע חילוף משתנים: $\tilde{\mathbf{w}} = \mathbf{w} - \mathbf{w}_{k-1}$, ופונקציית המחיר תראה כך:

$$\mathcal{L}_k(\tilde{\mathbf{w}}) = \sum_{n \in S_k} \left(\tilde{\mathbf{w}}^T \mathbf{x} - (y^{(n)} - \mathbf{w}_{k-1}^T \mathbf{x}) \right)^2 + \lambda \|\tilde{\mathbf{w}}\|^2$$

כפי שלמדנו בכיתה, זו בעיית רגרסיה לינארית עם רגולריזציה L_2 :

$$\tilde{\mathbf{w}}_k = (\mathbf{X}_k^T \mathbf{X}_k + \lambda \mathbf{I})^{-1} \mathbf{X}_k^T (\mathbf{y}_k - \mathbf{X}_k \mathbf{w}_{k-1})$$

כאשר, כמקודם

$$\mathbf{y}_k = [y^{(n)}]_{n \in S_k}, \quad \mathbf{X}_k = [\mathbf{x}^{(n)}]_{n \in S_k}^T$$

מכאן,

$$\mathbf{w}_k = (\mathbf{X}_k^T \mathbf{X}_k + \lambda \mathbf{I})^{-1} \mathbf{X}_k^T (\mathbf{y}_k - \mathbf{X}_k \mathbf{w}_{k-1}) + \mathbf{w}_{k-1}$$

פתרון זה תלוי במידע מהחלק הקודם $\mathbf{w}_{k-1}$, בניגוד לפתרון הקודם ולכן לא חייבת להיות שכחה מוחלטת. אינטואיטיבית, רגולריזציה זו מעודדת את הפתרון להישאר קרוב לפתרון הקודם, ויכולה לעזור למנוע שכחה.

א. מהמשוואה הראשונה של כלל העדכון:

$$\begin{aligned}\mathbf{U}^T \mathbf{v}(t) &= \gamma \mathbf{U}^T \mathbf{v}(t-1) + \mathbf{U}^T \mathbf{H} \mathbf{w}(t-1) \\ \mathbf{U}^T \mathbf{v}(t) &= \gamma \mathbf{U}^T \mathbf{v}(t-1) + \mathbf{U}^T \mathbf{U} \boldsymbol{\Lambda} \mathbf{U}^T \mathbf{w}(t-1)\end{aligned}$$

מאחר ו- $\mathbf{U}^T \mathbf{U} = \mathbf{I}$ ו- $\mathbf{z} = \mathbf{U}^T \mathbf{w}$, נקבל $\mathbf{q} = \mathbf{U}^T \mathbf{v}$

$$\mathbf{q}(t) = \gamma \mathbf{q}(t-1) + \boldsymbol{\Lambda} \mathbf{z}(t-1)$$

ניתן לפרק את המשוואה לכל אחד מרכיביה $0 \leq i \leq d$:

$$q_i(t) = \gamma q_i(t-1) + \lambda_i z_i(t-1)$$

עבור המשוואה השנייה של כלל העדכון:

$$\begin{aligned}\mathbf{U}^T \mathbf{w}(t) &= \mathbf{U}^T \mathbf{w}(t-1) - \eta \mathbf{U}^T \mathbf{v}(t) \\ \mathbf{z}(t) &= \mathbf{z}(t-1) - \eta \mathbf{q}(t)\end{aligned}$$

נפרק לכל אחד מהרכיבים:

$$z_i(t) = z_i(t-1) - \eta q_i(t)$$

נציב את $q_i(t)$ שמצאנו למעלה:

$$\begin{aligned}z_i(t) &= z_i(t-1) - \eta \gamma q_i(t-1) - \eta \lambda_i z_i(t-1) \\ &= -\eta \gamma q_i(t-1) + (1 - \eta \lambda_i) z_i(t-1)\end{aligned}$$

מהמשוואה עבור $q_i(t)$ ומהמשוואה האחרונה עבור $z_i(t)$ נקבל:

$$\begin{pmatrix} q_i(t) \\ z_i(t) \end{pmatrix} = \begin{pmatrix} \gamma & \lambda_i \\ -\eta \gamma & 1 - \eta \lambda_i \end{pmatrix} \begin{pmatrix} q_i(t-1) \\ z_i(t-1) \end{pmatrix}$$

ב. יש לחשב פולינום אופייני למטריצה ולמצוא את שורשיו:

$$|\mathbf{A}_i - \sigma \mathbf{I}| = 0 \Rightarrow \begin{vmatrix} \gamma - \sigma & \lambda_i \\ -\eta \gamma & 1 - \eta \lambda_i - \sigma \end{vmatrix} = 0$$

$$\Rightarrow (\gamma - \sigma)(1 - \eta \lambda_i - \sigma) + \eta \gamma \lambda_i = 0 \Rightarrow \sigma^2 - (1 - \eta \lambda_i + \gamma)\sigma + \gamma = 0$$

פתרון המשוואה הריבועית נותן את שני הערכים עצמיים.

ג. אם נסמן $\mathbf{h}_i = [q_i, z_i]^T$, $\mathbf{h} = (\mathbf{h}_1^T, \dots, \mathbf{h}_d^T)^T$, $\mathbf{p}_i = \mathbf{V}_i^{-1} \mathbf{h}_i$ ו- $p_{i,\pm}$ הם שני הרכיבים של $\mathbf{p}_i$, אז, בדומה למה שעשינו ב-GD בהרצאה:

$$\begin{aligned}\mathbf{h}_i(t) &= \mathbf{A}_i \mathbf{h}_i(t-1) \Rightarrow \mathbf{V}_i^{-1} \mathbf{h}_i(t) = \mathbf{V}_i^{-1} \mathbf{V}_i \boldsymbol{\Sigma}_i \mathbf{V}_i^{-1} \mathbf{h}_i(t-1) \\ &\Rightarrow \mathbf{p}_i(t) = \boldsymbol{\Sigma}_i \mathbf{p}_i(t-1) \Rightarrow p_{i,\pm}(t) = \sigma_{i,\pm} p_{i,\pm}(t-1) \Rightarrow p_{i,\pm}(t) = \sigma_{i,\pm}^t p_{i,\pm}(0) \\ &\Rightarrow \mathbf{h}_i(t) = \mathbf{V}_i \boldsymbol{\Sigma}_i^t \mathbf{V}_i^{-1} \mathbf{h}_i(0) \Rightarrow \mathbf{h}(t) = \begin{pmatrix} \mathbf{V}_1 \boldsymbol{\Sigma}_1^t \mathbf{V}_1^{-1} & 0 & 0 \\ 0 & \ddots & 0 \\ 0 & 0 & \mathbf{V}_d \boldsymbol{\Sigma}_d^t \mathbf{V}_d^{-1} \end{pmatrix} \mathbf{h}(0)\end{aligned}$$

קצב ההתכנסות תלוי בערך העצמי שערכו המוחלט הכי גדול וקרוב ל-1 (כי הוא "הכי איטי") לכן

$$\text{rate} = \max_i \max_{\pm} |\sigma_{i,\pm}|$$

התנאי להתכנסות הינו שכל הערכים העצמיים יהיו קטנים בערכם המוחלט מ-1: $\text{rate} < 1$.

הערה לסקרנים: כעת נראה מדוע, כפי שכתוב ברמז, $f_{\pm}(x) = |x \pm \sqrt{x^2 - c^2}|$ מונוטוניות עולה/יורדת (לפי הסימן) בתחום $|x| > |c|$ וקבועות בתחום $|x| < |c|$. לא היה צורך להראות את זה בפתרון. תחילה נגזור את הפונקציה כדי להראות מונוטוניות

$$\begin{aligned} \frac{d}{dx}(|x \pm \sqrt{x^2 - c^2}|) &= \left(1 \mp \frac{x}{\sqrt{x^2 - c^2}}\right) \text{sign}(x \pm \sqrt{x^2 - c^2}) \\ &= \left(1 \pm \frac{x}{\sqrt{x^2 - c^2}}\right) \text{sign}(x) = \text{sign}(x) \pm \frac{|x|}{\sqrt{x^2 - c^2}} \end{aligned}$$

באיבר השני עבור $|x| > |c|$ המכנה תמיד קטן מהמונה בערכו המוחלט מהאיבר השני, ולכן האיבר השני גדול בערכו המוחלט מ-1 וקובע את הסימן של הנגזרת. מכאן, עבור $|x| > |c|$, $f_+(x)$ מונוטונית עולה ו- $f_-(x)$ מונוטונית יורדת. עבור $|x| < |c|$, השורש נהיה מספר מדומה, ואז שתי הפונקציות קבועות

$$|x \pm \sqrt{x^2 - c^2}| = \sqrt{x^2 + c^2 - x^2} = |c|$$

ד. הערכים העצמיים מרוכבים עבור ערך שלילי מתחת לשורש: $(1 - \eta\lambda_i + \gamma)^2 < 4\gamma$

במקרה זה נסתכל על הערך מוחלט של הערכים העצמיים:

$$\begin{aligned} |\sigma_{i,\pm}| &= \frac{1}{2} \sqrt{(1 - \eta\lambda_i + \gamma)^2 + |(1 - \eta\lambda_i + \gamma)^2 - 4\gamma|} \\ &= \frac{1}{2} \sqrt{(1 - \eta\lambda_i + \gamma)^2 + 4\gamma - (1 - \eta\lambda_i + \gamma)^2} = \sqrt{\gamma} \end{aligned}$$

פונקציה זו קבועה, ואינה תלויה בע"ע של ההסיאן או η . מכאן, התנאי להתכנסות: $\sqrt{\gamma} < 1 \rightarrow \gamma < 1$

ה. עבור קצב לימוד η גדול, הביטוי $x = 1 - \eta\lambda_i + \gamma$ יהיה יותר שלילי. מסעיף ה', זה אומר ש-

$$|\sigma_{i,+}| = \frac{1}{2} \left| 1 - \eta\lambda_i + \gamma + \sqrt{(1 - \eta\lambda_i + \gamma)^2 - 4\gamma} \right|$$

יקטן, בעוד ש-

$$|\sigma_{i,-}| = \frac{1}{2} \left| 1 - \eta\lambda_i + \gamma - \sqrt{(1 - \eta\lambda_i + \gamma)^2 - 4\gamma} \right|$$

יגדל, כאשר שתיהן התחילו מאותו ערך של $\sqrt{\gamma}$ כאשר השורש התאפס. מכאן ש- $|\sigma_{i,-}|$ יהיה יותר גדול.

בנוסף, מכיוון ש- $|\sigma_{i,-}|$ קטן מונוטונית ב- x , נבחר $\lambda_i = \lambda_{\max}$ כדי לקבל את ה- $|\sigma_{i,-}|$ הכי גדול.

$$\frac{1}{2} \left| 1 - \eta\lambda_{\max} + \gamma - \sqrt{(1 - \eta\lambda_{\max} + \gamma)^2 - 4\gamma} \right| < 1$$

ו. הפונקציה $x - \sqrt{x^2 - c^2}$ מונוטונית לפיכך ניתן להציב את הביטוי שניתן ל- η :

$$\text{rate} = \frac{1}{2} \left| 1 - \eta\lambda_{\max} + \gamma - \sqrt{(1 - \eta\lambda_{\max} + \gamma)^2 - 4\gamma} \right|$$

$$< \frac{1}{2} \left| 1 - 2(1 + \gamma) + \gamma - \sqrt{(1 - 2(1 + \gamma) + \gamma)^2 - 4\gamma} \right|$$

$$\begin{aligned} &= \frac{1}{2} \left| -(1 + \gamma) - \sqrt{(1 + \gamma)^2 - 4\gamma} \right| = \frac{1}{2} \left| -(1 + \gamma) - \sqrt{(1 - \gamma)^2} \right| \\ &= \frac{1}{2} |-(1 + \gamma) - (1 - \gamma)| = 1 \end{aligned}$$

מכיוון שהראנו כי $\text{rate} < 1$, בהכרח האלגוריתם מתכנס.

- א. קידוד מיקום שייך מספר לכל מילה בכניסה. המספר הזה מייצג את המיקום של כל מילה. ללא קידוד המיקום, שכבת self-attention אינווריאנטית למיקום המילה. בניגוד ל-RNN. ללא קידוד מיקום אין משמעות לסדר הכניסות ול- self-attention אין יכולת להבדיל בין מיקומים של כניסות שונות. קידוד המיקום ממומש על ידי הוספה אריתמטית של פונקציית מיקום דטרמיניסטית לוקטור הייצוג של כל מילה.
- ב. ראשית הקידוד המוצע אינו וקטורי, בזמן שהייצוג למילה הוא וקטורי. נוכל לבנות וקטור באורך d המכיל את אותו מספר המשווייך לכל מילה. יתרון לקידוד הזה שהוא מנורמל בתחום $[0,1]$. הבעיה שעלולה להיווצר שאין משמעות מוחלטת לקידוד המיקום וההפרש בין קידודים שונים אינו מוחלט מה שאינו מאפשר לרשת להבין את המשמעות של קידוד המיקום. אם נשווה כניסה בעלת 3 מילים וכניסה בעלת 4 מילים, נגלה שהקידוד של המילה השנייה במקרה הראשון הוא 0.5 ובמקרה השני 0.33. כלומר הקידוד של כל מילה תלוי באורך משפט הכניסה.
- ג. בשיטה זו אכן כל מילה בכניסה מקבלת את אותו ערך של קידוד ביחד למיקומה, אך מלבד הבעיה שהמספרים הטבעיים אינם מוגבלים בגודלם (ולכן, אבל משפטים ארוכים מדי ייתכן שנקבל כניסות גדולות מדי, ונפגע בנרמול של השכבה), תהיה בעיה של הכללה עבור קידודים שלא נראו באימון.
- ד. הקידוד של המילה ה- t הוא וקטור המורכב מזוגות תדרים. התדרים תלויים במימד הייצוג d ואינם תלויים באורך משפט הכניסה N (או אורך המשפט המקסימלי L). וקטור הקידוד זהה המקום ה- t ללא קשר לגודל הכניסה.
- ה. נראה שמתקיים

$$\begin{bmatrix} \sin(\omega_k(t + \tau)) \\ \cos(\omega_k(t + \tau)) \end{bmatrix} = \mathbf{M}_k^\tau \begin{bmatrix} \sin(\omega_k t) \\ \cos(\omega_k t) \end{bmatrix}$$

נפרק את המטריצה לאבריה ונשתמש בזהויות הטריגונומטריות של סכום זוויות:

$$\begin{bmatrix} \sin(\omega_k \tau) \cos(\omega_k t) + \cos(\omega_k \tau) \sin(\omega_k t) \\ \cos(\omega_k \tau) \cos(\omega_k t) - \sin(\omega_k \tau) \sin(\omega_k t) \end{bmatrix} = \begin{bmatrix} M_{1,1} & M_{1,2} \\ M_{2,1} & M_{2,2} \end{bmatrix} \begin{bmatrix} \cos(\omega_k t) \\ \sin(\omega_k t) \end{bmatrix}$$

$$\begin{bmatrix} \sin(\omega_k \tau) \cos(\omega_k t) + \cos(\omega_k \tau) \sin(\omega_k t) \\ \cos(\omega_k \tau) \cos(\omega_k t) - \sin(\omega_k \tau) \sin(\omega_k t) \end{bmatrix} = \begin{bmatrix} \cos(\omega_k \tau) & \sin(\omega_k \tau) \\ -\sin(\omega_k \tau) & \cos(\omega_k \tau) \end{bmatrix} \begin{bmatrix} \sin(\omega_k t) \\ \cos(\omega_k t) \end{bmatrix}$$

מכאן שהמטריצה אינה תלויה בזמן t והינה

$$\mathbf{M}_k^\tau = \begin{bmatrix} \cos(\omega_k \tau) & \sin(\omega_k \tau) \\ -\sin(\omega_k \tau) & \cos(\omega_k \tau) \end{bmatrix}$$

- ו. כדי להרחיב לוקטור קידוד המיקום המלא p_t ניתן לראות שהמטריצה המורחבת הבאה אינה תלויה ב- t ומביאה להזזה ב- τ :

$$\mathbf{M}^{\tau} = \begin{bmatrix} \mathbf{M}_1^{\tau} & 0 & \cdots & 0 \\ 0 & \mathbf{M}_2^{\tau} & \cdots & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & \cdots & \mathbf{M}_{d/2}^{\tau} \end{bmatrix}$$