

למידה עצמית - 046195

בחינה סופית - מועד א'


משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

ב ה צ ל ח ה !!!

פתרון שאלה מס' 1: גזירה (35%)

א. כדי ששאר השאלה תהיה פשוטה, נבחר את הגרף הכי פשוט שאנחנו יכולים



ב. קודם נחשב פעפוע קדמי של הערכים:

$$v_1 = \exp(x_1 + x_2^3)x_3 = e^3, v_2 = \sqrt{x_3 \sin(\pi(x_1 - x_2)/2)} = 1$$

$$\rightarrow v_3 = v_1 + v_2 = e^3 + 1$$

כעת פעפוע קדמי של הנגזרות:

$$\dot{v}_1 \triangleq \frac{\partial v_1}{\partial x_1} = \exp(x_1 + x_2^3)x_3 = e^3$$

$$\dot{v}_2 \triangleq \frac{\partial v_2}{\partial x_1} = \frac{\pi \cos(\pi(2 - 1)/2)}{\sqrt{16 \sin(\pi(2 - 1)/2)}} = 0$$

$$\rightarrow \dot{v}_3 \triangleq \frac{\partial v_3}{\partial v_{-2}} = \frac{\partial v_3}{\partial x_1} = \dot{v}_1 + \dot{v}_2 = e^3$$

ג. מכיוון שזו אותה נקודה כמו בסעיף קודם, נשתמש באותו פעפוע קדמי. נשאר לחשב פעפוע אחורי של

הנגזרות:

$$\bar{v}_3 \triangleq \frac{\partial v_3}{\partial v_3} = 1, \bar{v}_2 \triangleq \frac{\partial v_3}{\partial v_2} = 1, \bar{v}_1 \triangleq \frac{\partial v_3}{\partial v_1} = 1$$

$$\begin{aligned}\bar{v}_{-1} &\triangleq \frac{\partial v_3}{\partial v_0} = \frac{\partial v_3}{\partial x_2} = \frac{\partial v_3}{\partial v_1} \frac{\partial v_1}{\partial x_2} + \frac{\partial v_3}{\partial v_2} \frac{\partial v_2}{\partial x_2} \\ &= 1 \cdot 3x_2^2 \exp(x_1 + x_2^3)x_3 + 1 \cdot \frac{-\pi \cos(\pi(2-1)/2)}{\sqrt{16 \sin(\pi(2-1)/2)}} = 3e^3\end{aligned}$$

ד. נחשב בשיטת ה-central difference, מכיוון שהיא משיגה שגיאה נמוכה יחסית ופשוטה למימוש. כפי שהומלץ בהרצאה, נשתמש בגודל צעד

$$h = \left(1 + \max_i |x_i|\right) \sqrt{\epsilon} = 0.02$$

ונקבל

$$(\exp(2)(1+h) - \exp(2)(1-h))/(2h) = \exp(2)$$

ה. בגזירה נומרית ו-Forward mode autodiff הבעיה העיקרית היא שחישוב הנגזרת צריך להתבצע כמספר משתני הכניסה (כלומר, המשתנים שלפיהם גוזרים) – מספר זה לרוב הוא מאוד גדול (למשל, המשקולות ברשת עמוקה. זו אינה בעיה ב-Backward mode autodiff שם צריך לבצע את החישוב רק פעם אחת לכל משתני הכניסה.

בנוסף: בגזירה נומרית גם יש בעיה מסוימת של רעש נומרי (אם כי בד"כ בלמידת מכונה זו לא הבעיה העיקרית), ומצד שני זו היא שיטה מאוד פשוטה למימוש. ל-Forward mode autodiff יש יתרון שניתן ביעילות לגזור על פני גרף עם מספר רב של מוצאים, בעוד שבשאר השיטות בד"כ צריך לבצע את כל החישוב מחדש לכל מוצא. לעומת זאת, החיסרון העקרי של Backward mode autodiff הוא שצריך לשמור בזיכרון את הערכים שחושבו בפעפוע הקדמי.

פתרון שאלה מס' 2: רשתות עם משוב (35%)

א. קודם כל נחשב את $\mathbf{v}_t$ ו- $\mathbf{u}_t$ בפעפוע קדמי:

$$\forall t = 1, 2, \dots, T: \mathbf{v}_t = \varphi(\mathbf{u}_t), \quad \mathbf{u}_t = \mathbf{W}\mathbf{v}_{t-1} + \mathbf{B}\mathbf{x}_t$$

לאחר מכן נבצע פעפוע אחורי. מכיוון שהנגזרות הן

$$\begin{aligned} \frac{\partial}{\partial \mathbf{W}[i,j]} \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t) &= \frac{\partial \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t)}{\partial \hat{\mathbf{y}}_t} \frac{\partial \hat{\mathbf{y}}_t}{\partial \mathbf{v}_t} \sum_{t'=1}^t \left(\prod_{\tau=t'+1}^t \frac{\partial \mathbf{v}_\tau}{\partial \mathbf{v}_{\tau-1}} \right) \frac{\partial \mathbf{v}_{t'}}{\partial \mathbf{u}_{t'}[i]} \mathbf{v}_{t'-1}[j] \\ &= \left[\frac{\partial \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t)}{\partial \hat{\mathbf{y}}_t} \mathbf{C} \sum_{t'=1}^t \left(\prod_{\tau=t'+1}^t \text{Diag}(\varphi'(\mathbf{u}_\tau)) \mathbf{W} \right) \text{Diag}(\varphi'(\mathbf{u}_{t'})) \right] [i] \mathbf{v}_{t'-1}[j] \end{aligned}$$

הפעפוע האחורי יתבצע ע"י:

$$\bar{\mathbf{v}}_t = \mathbf{C}^\top \frac{\partial \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t)}{\partial \hat{\mathbf{y}}_t}$$

$$\forall t = 1, 2, \dots, T: \bar{\mathbf{v}}_{t-1} = \mathbf{W}^\top \text{Diag}(\varphi'(\mathbf{u}_t)) \bar{\mathbf{v}}_t$$

והעדכון:

$$\frac{\partial}{\partial \mathbf{W}} \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t) = \sum_{t'=1}^t \text{Diag}(\varphi'(\mathbf{u}_{t'})) \bar{\mathbf{v}}_{t'} \mathbf{v}_{t'-1}^\top$$

ב. הבעיה הראשונה היא שבתהליך הנתון יש צורך לשמור בזיכרון (או לחשב מחדש) את הערכים של $\mathbf{v}_t$, $\mathbf{u}_t$ ו- $\bar{\mathbf{v}}_t$, $\forall t = 1, 2, \dots, T$, מה שיכול להיות בעייתי כאשר t שואף לאינסוף, כי זה מצריך משאבים אינסופיים. שיטה נפוצה לפתור בעיה זו היא פשוט לבצע את הפעפוע האחורי לכל היותר מספר קבוע של צעדים אחורה. זה יוצר חוסר דיוק מסוים בחישוב הגרדיאנט שיכול לפגוע בביצועים בבעיות מסוימות.

הבעיה השנייה, היא שהיעקוביאן

$$\prod_{\tau=t'+1}^t \frac{\partial \mathbf{v}_\tau}{\partial \mathbf{v}_{\tau-1}} = \prod_{\tau=t'+1}^t \text{Diag}(\varphi'(\mathbf{u}_\tau)) \mathbf{W}$$

יכול להתפוצץ או לשאוף לאפס כאשר t שואף לאינסוף. זה יכול לפגוע בחישוב מדויק של הגרדיאנט הסופי $\frac{\partial}{\partial \mathbf{W}} \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t)$, בגלל בעיות נומריות (קשה לבצע פעולות מדויקות על משתנים ששואפים לאפס או אינסוף). שיטה נפוצה לפתור בעיה זו היא לשנות ארכיטקטורה לכוז שפחות סובלת מבעיות אלו, כמו LSTM או Transformer.

ג. קודם כל נחשב פעפוע קדמי $2d^2$ פעמים (כמספר הפעפועים הקדמיים במשוואת מטה):

$$\forall \tau = 1, 2, \dots, t, \forall j = 1, 2, \dots, d^2: \mathbf{v}_\tau^+ = \varphi(\mathbf{u}_\tau^+), \quad \mathbf{u}_\tau^+ = (\mathbf{W} + h\mathbf{e}_j)\mathbf{v}_{\tau-1}^+ + \mathbf{B}\mathbf{x}_\tau$$

$$\forall \tau = 1, 2, \dots, t, \forall j = 1, 2, \dots, d^2: \mathbf{v}_\tau^- = \varphi(\mathbf{u}_\tau^-), \quad \mathbf{u}_\tau^- = (\mathbf{W} - h\mathbf{e}_j)\mathbf{v}_{\tau-1}^- + \mathbf{B}\mathbf{x}_\tau$$

כאשר $\mathbf{e}_j$ זו מטריצה שכולה אפסים מלבד ערך אחד ששווה לאחד, שמיקומו שונה לכל j , ו

$$h = \left(1 + \max_{i,j} |W_{ij}|\right) \sqrt{\epsilon}$$

לבסוף נחשב $\hat{\mathbf{y}}_t^+ = \mathbf{C}\mathbf{v}_t^+$ ו- $\hat{\mathbf{y}}_t^- = \mathbf{C}\mathbf{v}_t^-$, ונקבל

$$\frac{\partial}{\partial \mathbf{W}} \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t) \approx (\ell(\mathbf{y}_t, \hat{\mathbf{y}}_t^+) - \ell(\mathbf{y}_t, \hat{\mathbf{y}}_t^-)) / (2h)$$

בשיטה זו לא נצטרך לשמור בזיכרון כמות לא מוגבלת של ערכים. לא נראה התפוצצות או התבדרות של גרדיאנטים. אולם, הרעש הנומרי יכול להיות בעיה אם הגרדיאנטים האמיתי קטן מדי. אבל כזכור הבעיה הגדולה היא שצריך לחזור על הפעפוע הקדמי $2d^2$ פעמים, שזה יקר כאשר d גדול.

הערה: חישבנו כאן בשיטת ההפרשים המרכזית, מכיוון שהשגיאה הנומרית שלה יותר קטנה, כפי שלמדנו בהרצאה.

פתרון שאלה מס' 3: למידה עם מעט תגיות (30%)

1. א. למידה בה לומדים תחילה בצורה מונחית משימה אחת (מקור) ואז רוצים להשתמש בתוצאות למידה זו כדי לשפר למידה מונחית של משימה אחרת (מטרה).

ב. למשל, במשימה אחת נלמד רשת עמוקה לזהות סוגים של כלבים, ונרצה כעת ללמוד לזהות של סוגים של חתולים ע"י שימוש במאפיינים שלמדנו עבור כלבים (זיהוי אזניים, עיניים, אף, צבע...).

ג. נלמד תחילה רשת לזיהוי כלבים. כעת ניקח את אותה הרשת, נאתחל מחדש את השכבה האחרונה (של המסווג) ונמשיך לאמן אותה על המשימה החדשה של זיהוי חתולים.

2. א. נרצה ללמוד ייצוג המתאים לדגימות של פונקציית מרחק על אוסף הנתונים, למשל

$$S(x_i, x_k) = \frac{f(x_i)^T f(x_k)}{\|f(x_i)\| \|f(x_k)\|} = \begin{cases} \text{high,} & x_i \text{ similar to } x_k \\ \text{low,} & \text{otherwise} \end{cases}$$

זו יכולה להיות המשימה עצמה, או שנשתמש במשימה זו כדי ללמוד ייצוג שיהיה טוב למשימות אחרות.

ב. למשל, נרצה ללמוד רשת המזהה האם פנים המופיעות בכרטיס תעודת זהות דומות לפנים של מי שמחזיק את הכרטיס.

ג. במקרה זה הנתונים יהיו אוסף של אנשים שונים, כאשר לכל איש יהיו כמה תמונות שונות של הפנים שלהם. נבנה רשת עמוקה המסתיימת בשכבת ייצוג ונאמן אותה עם פונקציית מחיר

$$-\sum_i \sum_{n \in A_i, m \in A_i} S(x_i^n, x_i^m) + \sum_{i \neq k} \sum_{n \in A_i, m \in A_k} S(x_i^n, x_k^m)$$

כאשר x_i^n מסמן את הייצוג של התמונה ה- n השייכת לאיש ה- i , ו- A_i את אוסף האינדקסים של התמונות השייכות לאיש ה- i .

3. א. זהו מקרה פרטי של metric learning, בו אנו רוצים למזער את המרחק בין דוגמאות הנצרות מאוגמנטציות שונות של אותה דוגמא, ולמקסם את המרחק בין דוגמאות שונות.

ב. למשל, נרצה ללמוד לשפר את הסיווג של תמונות ב-CIFAR10 אבל עם מעט תגיות. אז נבצע למידה של הייצוג ולאחר מכן נלמד מסווג לינארי על גבי ייצוג זה.

ג. דוגמא לשיטה זו היא Noise-Contrastive Estimation:

$$\mathcal{L}_{\text{NCE}} \triangleq -\sum_{b \in B} (z_b^A)^T z_b^B + \sum_{b \in B} \ln \sum_{b' \neq b} \exp((z_b^A)^T z_{b'}^B)$$

כאשר z_b^A הוא הייצוג המנורמל של הדוגמא ה- b במיני-באטצ', אחרי אוגמנטציה A . הבעיה עם שיטה זו היא שצריכים מיני-באטצ'ים גדולים כדי שהיא תעבוד, מה שמאט את האימון.

4. א. זהו מקרה פרטי של למידה מונחית בו התגיות מאוד רועשות, כלומר לא מאוד אמינות.

ב. למשל, נניח שאנחנו רוצים לסווג בין דובים שחורים לדובים לבנים מתמונות, ויש לנו מעט תיוגים איכותיים של תמונות למחלקות אלה (כי אין לנו הרבה כסף לשלם לאנשים שיתייגו את התמונות). אבל יש המון תמונות מאינסטגרם שאנשים תייגו בתור @BrownBear או @WhiteBear. חלק גדול מהתמונות אלה יכולות להיות מתוייגות בצורה לא נכונה.

ג. דוגמא לשיטה ללמידה במקרה זה היא ללמוד רשת עמוקה בצורה מונחית על התיוגים החלשים, ואז לאמן אותה קצת על מעט התיוגים האמינים שכן יש לנו (כמו ב-Transfer learning).

5. א. במקרה זה יש לנו הרבה דוגמאות: מעט עם תיוגים והרבה ללא תיוגים. נרצה להשתמש בכולן.

ב. למשל, נרצה לבצע sentiment analysis ולחזות מטקסט של ביקורת על סרט האם הביקורת חיובית או שלילית בעיתון מסוים. נניח שיש לנו מעט ביקורות מתוייגות, אבל הרבה טקסט לא מתוייג מאותו העיתון.

ג. נוכל למשל לאמן רשת עצבית מסוג Transformer לחזות מילים חסרות בטקסט מהעיתון כדי ליצור ייצוג טוב לסוג טקסט זה. לאחר מכן נוסיף שכבת סיווג ונאמן את כל הרשת על משימת סיווג הביקורות עם התגיות הנתונות.