

למידה עמוקה - 046211
בחינה סופית - מועד ב'

משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

בהצלחה !!!

שאלה מס' 1: גזירה ורשתות עם משוב (33%)

נתונה רשת עם משוב ואקטיבציות LReLU $\varphi(u) = \max[\rho u, u]$ עם $\rho \in (0,1)$ המקבלת כניסה $\mathbf{x}_t$, ומעדכנת את הייצוג $\mathbf{v}_t$ לפי

$$\forall t = 1, 2, \dots: \mathbf{v}_t = \varphi(\mathbf{W}\mathbf{v}_{t-1} + \mathbf{B}\mathbf{x}_t)$$

החל מאתחול $\mathbf{v}_0$. כזכור, ניתן לרשום את, עבור $t' < t$, כלומר היעקוביאן של הרשת, בתור

$$\frac{\partial \mathbf{v}_t}{\partial \mathbf{v}_{t'}} = \prod_{\tau=t'+1}^t \frac{\partial \mathbf{v}_\tau}{\partial \mathbf{v}_{\tau-1}} = \prod_{\tau=t'+1}^t \text{Diag}(\varphi'(\mathbf{u}_\tau)) \mathbf{W}$$

א. הראו כי כאשר $|\rho^2 \lambda_{\min}(\mathbf{W}^T \mathbf{W})| > 1$ הגרדיאנטים מתפוצצים, כלומר $\left\| \frac{\partial \mathbf{v}_t}{\partial \mathbf{v}_0} \right\| \rightarrow \infty$,

כאשר $\lambda_{\min}(\mathbf{A})$ הוא הערך העצמי המינימלי של $\mathbf{A}$.

רמז: זכרו כי ניתן להשתמש בערכים העצמיים בצורה הבאה

$$\lambda_{\min}(\mathbf{A}^T \mathbf{A}) \|\mathbf{u}\|^2 \leq \|\mathbf{A}\mathbf{u}\|^2 \leq \lambda_{\max}(\mathbf{A}^T \mathbf{A}) \|\mathbf{u}\|^2$$

ב. רשמו כיצד נחשב את היעקוביאן $\frac{\partial \mathbf{v}_t}{\partial \mathbf{v}_0}$ באמצעות Backpropagation.

ג. כזכור, בחישוב באמצעות Backpropagation יש שתי בעיות עבור $t \rightarrow \infty$: (1) משאבי החישוב הנדרשים גדלים בלי הגבלה, ו-(2) הגרדיאנטים מתפוצצים או דועכים. עבור כל בעיה: הסבירו מהי, תנו דוגמא לשיטה נפוצה להקל על הבעיה, והאם יש מגבלות כלשהן לשיטה זו.

ד. הסבירו כעת כיצד נחשב את היעקוביאן $\frac{\partial \mathbf{v}_t}{\partial \mathbf{v}_0}$ באמצעות Forward mode autodiff. האם עדיין

מתקיימות בעיות (1) ו-(2) מסעיף ז' האם צצות בעיות אחרות? הסבירו.

שאלה מס' 2: למידה עם שכבה אחת (33%)

נתונה רשת ReLU עם שכבה נסתרת אחת ו- k נוירונים, ללא היסטים (biases):

$$(*) \quad f(\mathbf{x}) = \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :]\mathbf{x}]_+$$

מאמנים את הרשת בעזרת Gradient Flow עם פונקציית מחיר ריבועית ורגולריזציית L2:

$$\mathcal{L} = \sum_{n=1}^N \|y^{(n)} - f(\mathbf{x}^{(n)})\|^2 + \mu \sum_{i=1}^k (w_2[i]^2 + \|\mathbf{W}_1[i, :]\|^2)$$

עם הדוגמאות המתייגות $\{\mathbf{x}^{(n)}, y^{(n)}\}_{n=1}^N$, כאשר $N < k$, וכל הדוגמאות $\mathbf{x}^{(n)} \in \mathbb{R}^d$ שונות אחת מהשנייה. מאתחלים אקראית את $\mathbf{W}_1$ ומנרמלים אותה, כך ש $\forall i: \|\mathbf{W}_1[i, :]\|^2 = 1$ והמוצאים של השכבה הנסתרת $\{\mathbf{v}^{(n)} = [\mathbf{W}_1 \mathbf{x}^{(n)}]_+\}_{n=1}^N$ פורשים מרחב N מימדי. $\mathbf{w}_2$ מאותחלת לאפס.

בשאלה זו: הניחו כי מקפידים את $\mathbf{W}_1$ ומאמנים רק את השכבה השנייה $\mathbf{w}_2$.

- הוכיחו, כי ללא רגולריזציה, כלומר $\mu = 0$, נתכנס לפתרון עם שגיאה אפס.
- עבור $\mu = 0$, האם $\mathbf{w}_2$ יכול להגיע מחוץ לתת המרחב הנפרש ע"י $\{\mathbf{v}^{(n)}\}_{n=1}^N$? הסבירו.
- הוכיחו שכאשר $\mu = 0$, השכבה השנייה תתכנס לפתרון שממזער את הנורמה הריבועית:

$$\min_{\mathbf{w}_2} \|\mathbf{w}_2\|_2^2 \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :]\mathbf{x}^{(n)}]_+ = y^{(n)}$$

רמז: כתבו את התנאים לאופטימליות של משוואה זו באמצעות כופלי לגרנז', והראו ש-GD מתכנס לפתרון שמקיים תנאים אלה.

- עם רגולריזציה, כלומר $\mu > 0$, לאיזה פתרון נתכנס? אין צורך להוכיח.

שאלה מס' 3: למידה עם שתי שכבות (34%)

לשאלה זו יש את אותם נתונים כמו שאלה 2, מלבד שכעת כי מאמנים את שתי שכבות המשקולות ביחד.

- איזה סימטריות (Invariances) קיימות בפרמטרים ברשת?
- עבור $\mu = 0$, הוכיחו כי הגודל $A_i = w_2^2[i] - \|\mathbf{W}_1[i, :]\|^2$ לא משתנה בזמן האימון, לכל i .
- רמז: ניתן להשתמש בנוסחא שפותחה בהרצאה, $\dot{\mathbf{w}}^T \left[\frac{\partial}{\partial \alpha} \psi_\alpha(\mathbf{w}) \right]_{\alpha=1} = 0$ (מהו $\psi_\alpha(\mathbf{w})$?)
- מכאן נניח שהתכנסנו לפתרון הממזער את $\mathcal{L}$, ומקיים $y^{(n)} = f(\mathbf{x}^{(n)})$ עם $\mu > 0$ אינפטיסימלי.

- הראו כי בפתרון ניתן לרשום $w_2[i]^2 + \|\mathbf{W}_1[i, :]\|^2 = 2|w_2[i]| \|\mathbf{W}_1[i, :]\|$.
- רמז: בצעו את הטרנספורמציה $w_2[i] \rightarrow c_i w_2[i], \mathbf{W}_1[i] \rightarrow \frac{1}{c_i} \mathbf{W}_1[i, :]$ עבור $c_i > 0$ ובחרו את הערך האופטימלי של c_i .

- הראו כי הפונקציה שמתכנסים אליה $f(\mathbf{x})$ שקולה ל- $(*)$ עם הפרמטרים שמתקבלים מ

$$\min_{\mathbf{w}_2, \mathbf{W}_1} \|\mathbf{w}_2\|_1 \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :]\mathbf{x}^{(n)}]_+ = y^{(n)}, \forall i: \|\mathbf{W}_1[i, :]\|^2 = 1$$

- רמז: ניתן להשתמש בתוצאות סעיף ג', גם אם לא הוכחתם אותו.
- עבור רשת ברוחב ששואף לאינסוף ($k \rightarrow \infty$ עם N שנשאר קבוע), מה ההבדל בין הפתרון עבור אימון של השכבה השנייה (שאלה ג') או שתי השכבות (שאלה ד')? מה ההשלכות של כך?