

שאלה מס' 1: גזירה ורשתות עם משוב (33%)

א. נסמן $D_\tau = \text{Diag}(\varphi'(u_\tau))$ מתקיים:

$$\left\| \frac{\partial v_t}{\partial v_0} \right\|^2 = \left\| \prod_{\tau=0}^t D_\tau W \right\|^2 = \max_{u \in \mathbb{R}^d: \|u\|=1} \|D_t W (\prod_{\tau=0}^{t-1} D_\tau W) u\|^2$$

ע"י שימוש ברמז פעמיים:

$$\geq \rho^2 \max_{u \in \mathbb{R}^d: \|u\|=1} \left\| W \left(\prod_{\tau=1}^{t-1} D_\tau W \right) u \right\|^2 \geq \rho^2 \lambda_{\min}(W^T W) \max_{u \in \mathbb{R}^d: \|u\|=1} \left\| \left(\prod_{\tau=1}^{t-1} D_\tau W \right) u \right\|^2$$

נמשיך לעשות זאת לכל איברי המכפלה, ונקבל:

$$\geq \dots \geq \rho^{2t} \lambda_{\min}^{2t}(W^T W) \cdot |\rho^2 \lambda_{\min}(W^T W)| > 1 \text{ כאשר } t \rightarrow \infty$$

ב. קודם כל נחשב את v_τ ו- u_τ בפעפוע קדמי:

$$\forall \tau = 1, 2, \dots, t: v_\tau = \varphi(u_\tau), \quad u_\tau = W v_{\tau-1} + B x_\tau$$

נשמור בזיכרון את u_τ $\forall \tau = 1, 2, \dots, t$ שהתקבלו. לאחר מכאן, נבצע פעפוע אחורי:

$$\bar{v}_t = I$$

$$\forall \tau = 1, 2, \dots, t: \bar{v}_{\tau-1} = W^T D_\tau \bar{v}_\tau$$

ג. הבעיה הראשונה היא שבתהליך Backpropagation יש צורך לשמור בזיכרון (או לחשב מחדש) את

הערכים של u_τ $\forall \tau = 1, 2, \dots, t$, מה שיכול להיות בעייתי כאשר t שואף לאינסוף, כי זה מצריך משאבים אינסופיים. שיטה נפוצה לפתור בעיה זו היא פשוט לבצע את הפעפוע האחורי לכל היותר מספר קבוע של צעדים אחורה. זה יוצר חוסר דיוק מסוים בחישוב הגרדיאנט שיכול לפגוע בביצועים בבעיות מסוימות.

הבעיה השנייה, היא שהיעקוביאן

$$\prod_{\tau=t'+1}^t \frac{\partial v_\tau}{\partial v_{\tau-1}} = \prod_{\tau=t'+1}^t \text{Diag}(\varphi'(u_\tau)) W$$

יכול להתפוצץ או לשאוף לאפס כאשר t שואף לאינסוף. זה יכול לפגוע בחישוב מדויק של הגרדיאנט הסופי $\frac{\partial}{\partial w} \ell(y_t, \hat{y}_t)$, בגלל בעיות נומריות (קשה לבצע פעולות מדויקות על משתנים ששואפים לאפס או אינסוף). שיטה נפוצה לפתור בעיה זו היא לשנות ארכיטקטורה לכזו שפחות סובלת מבעיות אלו, כמו LSTM או Transformer.

ד. נחשב את v_τ ו- u_τ בפעפוע קדמי:

$$\forall \tau = 1, 2, \dots, t: v_\tau = \varphi(u_\tau), \quad u_\tau = W v_{\tau-1} + B x_\tau$$

ובמקביל, בכל צעד לחשב גם את הנגזרות בפעפוע קדמי:

$$\dot{\mathbf{v}}_0 = \mathbf{I}$$

$$\forall \tau = 1, 2, \dots, t: \dot{\mathbf{v}}_\tau = \mathbf{D}_\tau \mathbf{W} \dot{\mathbf{v}}_{\tau-1}$$

מכיוון שבכל צעד אנחנו מחשבים את הנגזרות המתאימות $\dot{\mathbf{v}}_\tau$ ביחד עם $\mathbf{v}_\tau$ ו- $\mathbf{u}_\tau$, לא צריך לשמור שום דבר בזיכרון, והבעיה הראשונה נפתרה. הבעיה השנייה נשארה בעינה, מכיוון שהנגזרות עדיין יכולות לשאוף לאפס או להתפוצץ (כפי שראינו בהרצאה, ובסעיף א').

שאלה מס' 2: למידה עם שיכבה אחת (33%)

א. כיוון שמאמנים רק את השכבה השנייה, זו בעיית רגרסייה לינארית על דוגמאות

כאשר $\mathbf{v}^{(n)} \in \mathbb{R}^k$, עם פונקציית מחיר ריבועית $\{\mathbf{v}^{(n)} = [\mathbf{w}_1 \mathbf{x}^{(n)}]_+\}_{n=1}^N$

$$\mathcal{L} = \sum_{n=1}^N \|y^{(n)} - \mathbf{w}_2^T \mathbf{v}^{(n)}\|^2$$

מכיוון ש- $N < k$ בבעיה יש יותר פרמטרים מדוגמאות, ו- $\mathbf{v}^{(n)}$ פורשים מרחב N מימדי, אנו יודעים שקיים פתרון $\mathbf{w}_2$ כך ש- $y^{(n)} = \mathbf{w}_2^T \mathbf{v}^{(n)}$, $\forall n$, כלומר עם שגיאה אפס $\mathcal{L} = 0$. מכיוון שזוהי בעיה קמורה, בהכרח נתכנס לפתרון שכזה.

ב. לא. כזכור, ב-GD של רגרסייה לינארית, העדכונים תמיד נמצאים במרחב של הכניסה, כי כל עדכון הוא מהצורה

$$\Delta \mathbf{w}_2 = \sum_{n=1}^N \mathbf{v}^{(n)} (\mathbf{w}_2^T \mathbf{v}^{(n)} - y^{(n)}) \in \text{span}(\mathbf{v}_1, \dots, \mathbf{v}_N)$$

מכיוון שהתחלנו מאתחול אפס, הפתרון בהכרח נמצא ב- $\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_N)$.

ג. מסעיף א', אנו יודעים שמתכנסים לפתרון שמשגיג שגיאה אפס, כלומר האילוץ מתקיים

$$\sum_{i=1}^k w_2[i] [\mathbf{w}_1[i, :]] \mathbf{x}^{(n)}]_+ = \mathbf{w}_2^T \mathbf{v}^{(n)} = y^{(n)}$$

נשאר רק להוכיח שהפתרון ממזער את נורמת L2, כפי שלמדנו בכיתה. נבצע זאת באמצעות כופלי לגרנז'.

$$\min_{\mathbf{w}_2} \|\mathbf{w}_2\|_2 \quad \text{such that } \mathbf{w}_2^T \mathbf{v}^{(n)} = y^{(n)}$$

והלגרנז'יאן שלה הוא

$$L(\mathbf{w}_2, \boldsymbol{\lambda}) = \|\mathbf{w}_2\|_2^2 - \sum_{n=1}^N \lambda^{(n)} (\mathbf{w}_2^T \mathbf{v}^{(n)} - y^{(n)})$$

נגזור לפי $\boldsymbol{\lambda}$, נשווה לאפס ונקבל:

$$\mathbf{w}_2^T \mathbf{v}^{(n)} = y^{(n)}$$

קיבלנו כצפוי שהאילוץ צריך להתקיים, כפי שמתקיים לפתרון שנקבל מ-GD, מסעיף א'. נגזור לפי $\mathbf{w}_2$, נשווה לאפס ונקבל:

$$\mathbf{w}_2 = \frac{1}{2} \sum_{n=1}^N \lambda^{(n)} \mathbf{v}^{(n)}$$

מכאן שהפתרון צריך להיות ב- $\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_N)$, כפי שמתקיים לפתרון שנקבל מ-GD, מסעיף ב'.

מכאן הפתרון שנתכנס אליו ב-GD הוא פתרון של בעיית האופטימיזציה.

ד. מכיוון שהבעיה קמורה בצורה חזקה, נתכנס לפתרון הממזער את השגיאה $\mathcal{L}$. כזכור, הפתרון האנליטי הוא

$$\mathbf{w}_2 = (\mu \mathbf{I} + \mathbf{V}^T \mathbf{V})^{-1} \mathbf{V}^T \mathbf{y}$$

כאשר

$$\mathbf{y} = [y^{(1)}, \dots, y^{(N)}]^T \in \mathbb{R}^N, \mathbf{V} = [\mathbf{v}^{(1)}, \dots, \mathbf{v}^{(N)}]^T \in \mathbb{R}^{N \times k}$$

שאלה מס' 3: למידה עם שתי שכבות (34%)

א. יש סימטריה להחלפה (פרמוטציה) בין נוירונים של השכבה הנסתרת, כלומר לכל מטריצת פרמוטציה P מתקיים כי הטרנספורמציה הבאה לא תשנה את מוצא הרשת

$$\mathbf{w}_2 \rightarrow P \mathbf{w}_2, \mathbf{W}_1 \rightarrow P \mathbf{W}_1$$

בגלל שאנחנו ברשת ReLU, יש גם rescale symmetry, כלומר עבור עבור $c_i > 0$, מוצא הרשת לא ישתנה עקב לשינוי סקאלה מהצורה

$$w_2[i] \rightarrow c_i w_2[i], \mathbf{W}_1[i] \rightarrow \frac{1}{c_i} \mathbf{W}_1[i, :]$$

ב. נגדיר $\psi_\alpha(\mathbf{w})$ שעבור אינדקס i מסוים מבצע את הטרנספורמציה

$$w_2[i] \rightarrow \alpha w_2[i], \mathbf{W}_1[i] \rightarrow \frac{1}{\alpha} \mathbf{W}_1[i, :]$$

ואת שאר המשקולות משאיר ללא שינוי. מהנוסחה הנתונה

$$\dot{\mathbf{w}}^T \left[\frac{\partial}{\partial \alpha} \psi_\alpha(\mathbf{w}) \right]_{\alpha=1} = 0$$

נקבל

$$\dot{w}_2[i] w_2[i] - \dot{\mathbf{W}}_1[i, :]^T \mathbf{W}_1[i, :] = 0$$

כלומר

$$\frac{d}{dt} (w_2^2[i] - \|\mathbf{W}_1[i, :]\|^2) = 0$$

מכאן שהגודל $w_2^2[i] - \|\mathbf{W}_1[i, :]\|^2$ הוא גודל נשמר.

ג. השינוי ברמז לא משנה את המוצא של הרשת, בגלל ה-rescale symmetry, ומכאן את איבר השגיאה האמפירית ב- $\mathcal{L}$. נשאר לבחון רק את ההשפעה על הרגולריזציה:

$$\sum_{i=1}^k \left(c_i^2 w_2[i]^2 + \frac{1}{c_i^2} \|\mathbf{W}_1[i, :]\|^2 \right)$$

נגזור לפי c_i ונשווה לאפס:

$$2c_i w_2[i]^2 - 2 \frac{1}{c_i^3} \|\mathbf{W}_1[i, :]\|^2 = 0$$

מכאן

$$c_i^2 = \frac{\|\mathbf{W}_1[i, :]\|}{|w_2[i]|}$$

לכן בפתרון

$$c_i w_2[i] = \frac{1}{c_i} \|\mathbf{W}_1[i, :]\| = \sqrt{|w_2[i]| \|\mathbf{W}_1[i, :]\|}$$

נציב באיבר הרגולריזציה ונקבל

$$\begin{aligned} & \sum_{i=1}^k \left(c_i^2 w_2[i]^2 + \frac{1}{c_i^2} \|\mathbf{W}_1[i, :]\|^2 \right) \\ &= 2 \sum_{i=1}^k |w_2[i]| \|\mathbf{W}_1[i, :]\| \end{aligned}$$

ה. מסעיף קודם מתקיים:

$$\mathcal{L} = \sum_{n=1}^N \|y^{(n)} - f(\mathbf{x}^{(n)})\|^2 + 2\mu \sum_{i=1}^k |w_2[i]| \|\mathbf{W}_1[i, :]\|$$

מכיוון שנתון כי הרגולריזציה קטנה מספיק כך ש- $y^{(n)} = f(\mathbf{x}^{(n)})$, יתאפס האיבר של השגיאה האמפירית, $\sum_{n=1}^N \|y^{(n)} - f(\mathbf{x}^{(n)})\|^2$, וניתן לרשום את הפתרון כ-

$$\min_{\mathbf{w}_2, \mathbf{W}_1} \sum_{i=1}^k |w_2[i]| \|\mathbf{W}_1[i, :]\| \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :] \mathbf{x}^{(n)}]_+ = y^{(n)}$$

כעת נשתמש ב-rescale symmetry שוב, ונוכל לקבוע בלי הגבלת כלליות $\forall i: \|\mathbf{W}_1[i, :]\| = 1$, מכיוון שזה לא ישנה את $f(\mathbf{x})$ המתקבל (רק את הפרמטרים שלו), ונקבל:

$$\min_{\mathbf{w}_2, \mathbf{W}_1} \sum_{i=1}^k |w_2[i]| \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :] \mathbf{x}^{(n)}]_+ = y^{(n)}, \forall i: \|\mathbf{W}_1[i, :]\|^2 = 1$$

ששקול למה שצריך היה למצוא

$$\min_{\mathbf{w}_2, \mathbf{W}_1} \|\mathbf{w}_2\|_1 \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :] \mathbf{x}^{(n)}]_+ = y^{(n)}, \forall i: \|\mathbf{W}_1[i, :]\|^2 = 1$$

1. בשאלה 2' קיבלנו (כאשר נוסף בצורה מפורשת את האיתחול, למרות שהוא לא באמת אילוץ)

$$\min_{\mathbf{w}_2} \|\mathbf{w}_2\|_2^2 \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :] \mathbf{x}^{(n)}]_+ = y^{(n)}, \forall i: \|\mathbf{W}_1[i, :]\|^2 = 1$$

לעומת זאת, בסעיף 3' קיבלנו

$$\min_{\mathbf{w}_2, \mathbf{W}_1} \|\mathbf{w}_2\|_1 \text{ such that } \sum_{i=1}^k w_2[i] [\mathbf{W}_1[i, :] \mathbf{x}^{(n)}]_+ = y^{(n)}, \forall i: \|\mathbf{W}_1[i, :]\|^2 = 1$$

בגבול ש- $k \rightarrow \infty$, אם מאתחלים אקראית, כל ה- $\mathbf{W}_1[i, :]$ המנורמלים האפשריים (כלומר, כל הספירה) קיימים בשכבה הראשונה של הרשת, לכן אין צורך לעשות אופטימיזציה על $\mathbf{W}_1[i, :]$ ומספיק לבחור את הנוירונים בשכבה השנייה ע"י $\mathbf{w}_2$. מכאן, נקבל שההבדל היחיד בין שתי בעיות האופטימיזציה היא הנורמה אותה ממזערים.

כתוצאה מכך, באימון של שתי השכבות ברשת, ממזערים את נורמת L1 של השכבה השנייה, ולכן מקבלים פתרון דליל, עם מעט נוירונים. לעומת זאת, באימון של השכבה השנייה נמזער את נורמת L2, שבאופן כללי לא מביאה לפתרון דליל.