

למידה עצמית - 046211

בחינה סופית - מועד א'

משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

ב ה צ ל ח ה !!!

שאלה מס' 1 – שיטות אימון (35%)

גורדון, עובד בחברת "הר-השולחן השחור", מקבל משימה לאמן רשת נוירונים גדולה במיוחד, וסט נתונים מתויג. הוא מבין שזה ייקח לו זמן רב אם יעשה זאת בצורה רגילה, לכן הוא נזכר שהוא למד בכיתה על האפשרות של מקבול. הוא זוכר במעורפל שיש שתי אפשרויות שיטות של מקבול:

I מקבול נתונים ("Data Parallelism") ומקבול מודל ("Model Parallelism").

- א. הסבירו מהו מקבול נתונים. כיצד מידת המקבול תלויה בגודל ה-minibatch של SGD?
- ב. מהו החסרון העיקרי של מקבול נתונים?
- ג. איזה בעיות מתרחשות כאשר אנו מבצעים Batch-Normalization ומאמנים עם גודל minibatch גדול או קטן במיוחד? הציעו פתרונות לבעיות.
- ד. הסבירו מהו מקבול מודל. ציינו חסרון אחד ויתרון אחד לעומת מקבול נתונים.
- ה. בהנחה שאין מגבלות חומרה, האם ניתן לבצע מקבול מודל מושלם על פני השכבות ברשת עמוקה? כלומר, עבור מספר עובדים k , שכל אחד מהם אחראי על כמה שכבות, האם נוכל לקבל האצה של פי k במהירות האימון? הסבירו.

מכיוון שגורדון לא מצליח לזכור בדיוק מה צריך לעשות בכל שיטה, הוא מחליט לאמן פשוט במקביל הרבה מודלים שונים עם אותה ארכיטקטורה, כולם על אותו סט הנתונים, ואז למצע את המשקולות של המודלים המאומנים, כדי לקבל מודל חדש.

- ו. הסבירו מדוע באופן כללי שיטה זו תוביל לשגיאת בוחן גבוהה. הציעו שיטה אחרת (שלא כוללת מיצוע של המשקולות) המשתמשת באותו אוסף של מודלים מאומנים שבד"כ תיתן שגיאה נמוכה יותר. מה החיסרון העיקרי של שיטה זו?

שאלה מס' 2 – רגרסיה לוגיסטית והטייה חבויה (35%)

כזכור, למדנו בכיתה שעבור נתונים מתויגים $\{x^{(n)} \in R^d, y^{(n)} \in \{-1, 1\}\}_{n=1}^N$ GD אימון Hard SVM של מסווג לינארי ללא היסט (bias) על בעיית רגרסיה לוגיסטית, מתכנס בכיוון לפתרון בעיית ה-Hard SVM:

$$(1) \hat{w} = \operatorname{argmin}_w \|w\|^2 \text{ s.t. } \forall n: w^T x^{(n)} \geq y^{(n)}$$

בשאלה זו נרצה להוכיח תוצאה זו, תחת הנחות מפשטות.

א. תוצאה זו היא דוגמא ל"הטייה חבויה" ("implicit bias"). מה זה? למה זה רלוונטי ללמידה עמוקה?

ב. רשמו מתמטית מהי ההגדרה של נתונים פרידים לינאריים, ומהי ההגדרה של בעיית רגרסיה לוגיסטית.

לשם הפשטות, מכאן ואילך נניח כי $\forall n: y^{(n)} = 1$, כי פונקציית המחיר היא אקספוננציאלית

$$\mathcal{L}(w) = \sum_{n=1}^N \exp(-w^T x^{(n)})$$

ג. מדוע יכולנו להניח כי $\forall n: y^{(n)} = 1$, בלי הגבלת הכלליות? איזה תכונה צריכה להתקיים כדי שנוכל

לבצע הנחה זו גם ברשת נוירונים עמוקה? מתי זה יתקיים ברשת fully-connected ללא היסט?

מכאן ואילך, ניקח את הגבול של גודל צעד קטן (gradient flow). כלומר, הדינמיקה היא

$$(2) \dot{w}(t) = -\nabla \mathcal{L}(w) = \sum_{n=1}^N x^{(n)} \exp(-w(t)^T x^{(n)})$$

ד. הוכיחו כי $\dot{w}(t)$ שואף לאפס.

ה. הוכיחו כי נורמת המשקולות שואפת לאינסוף, וכי $\mathcal{L}(w)$ מתכנסת לאפס.

נניח מכאן ואילך כי בפתרון בעיית ה-SVM (1) כל הדוגמאות בבעיה הן וקטורי התמיכה (Support vectors), כלומר כל האילוצים בבעיה (1) מתקיימים בשוויון.

ו. רשמו את הלגרנז'יאן של בעיה (1) במקרה זה, ואת התנאים לאופטימליות עבורו (מסדר ראשון).

ז. הוכיחו כי $w(t)$ פתרון משוואה (2), שואף בכיוון לפתרון משוואה (1), ע"י בדיקה שהתנאים מסעיף קודם מתקיימים עבור

$$\hat{w} = \lim_{t \rightarrow \infty} \frac{w(t)}{\min_n w^T(t) x^{(n)}}$$

כאשר נתון כי, עבור כל הדוגמאות, $\hat{w}^T x^{(n)} = 1$.

שאלה מס' 3 – יעילות משאבים (30%)

א. נתונה רשימה של סוגי דחיסה של משקולות ברשת עצבית:

1. Uniform Quantization.
2. Unstructured pruning.
3. Weight Sharing (or Clustering).

עבור כל סוג דחיסה ברשימה, הסבירו איכותית מהו, והאם סוג דחיסה זה עוזר בהקטנת עלות הזיכרון, עלות החישוב, או שניהם?

ב. הסבירו בצורה מפורטת ומתמטית שיטה לביצוע קוונטיזציה סימטרית של המשקולות לאחר האימון.

האם כדאי להשתמש בקוונטיזציה כזו גם על האקטיבציות ברשת ReLU?

ג. הסבירו בצורה מפורטת מה זה Knowledge Distillation, וכיצד הוא מתבצע. כתבו את פונקציית ההפסד של הבעיה.

ד. תארו בצורה מפורטת ומתמטית שיטה אחת לדלל את המשקולות, הכולל אימון של הרשת. הסבירו את ההיגיון מאחורי השיטה.