

# פתרון מועד א' בלמידה עמוקה 046211 חורף תשפ"ב

## שאלה מס' 1

א. בשיטה של מקבול נתונים, כל עובד מקבל חלק מהדוגמאות ב-minibatch  $B$ , ומבצע את חישוב הגרדיאנט (באמצעות backpropagation), על דוגמאות אלה. הפרמטרים של המודל,  $w$ , משותפים לכל העובדים, מעודכנים ע"י צעד עדכון הממצע את כל הגרדיאנטים  $\nabla \mathcal{L}_n(w(t))$  מכל העובדים, למשל ב-SGD:

$$w(t+1) = w(t) - \eta \frac{1}{|B|} \sum_{n \in B} \nabla \mathcal{L}_n(w(t))$$

כך שהחישוב של הגרדיאנטים בסכום מתחלק על פני כל העובדים שמשתתפים. כדי לבצע מקבול משמעותי, יש צורך ב- $|B|$  גדול.

ב. מקבול נתונים מצריך כוונון מחדש של היפר-פרמטרים, כדי למנוע פגיעה בהכללה. בנוסף, בד"כ ההאצה המתקבלת קטנה ככל ש- $|B|$  גדל, עד שאין יותר האצה מעבר לאיזושהו סף (השערוך של הגרדיאנט כבר מספיק מדויק, והגדלה נוספת  $|B|$  לא משפרת את המצב). לכן, יש בד"כ גבול לכמה ניתן להאיץ בשיטה זו.

ג. ב-Batch-Normalization משערכים את הממוצע והשונות על הדוגמאות ב-minibatch. אם  $|B|$  קטן מדי, השערוך אינו טוב, והאימון יכול לקרוס (שגיאת האימון וההכללה). במקרה זה הפתרון הוא בד"כ לעבור לשיטת נרמול אחרת, כגון layer-normalization או group-normalization. לחילופין, אם  $|B|$  גדול מדי, זה מקטין את הרעש בשערוך, מה שיכול לפגוע בהכללה (כי, כפי שלמדנו, רעש זה יכול לעזור להכללה). פתרון אפשרי לכך הוא לבצע את שערוך הממוצע והשונות של Batch-Normalization על פחות דגימות מאשר ב-minibatch. זה נקרא גם ghost batch normalization.

ד. בשיטה של מקבול מודל, מחלקים את המודל עצמו (הפרמטרים) לקבוצות זרות. כל עובד מחשב את כל השלבים של backpropagation על קבוצה אחת של פרמטרים (פעפוע קדמי, פעפוע אחורי, ועדכון), כאשר הוא רואה את אותם הדוגמאות כמו שאר העובדים. כדי לחשב את הגרדיאנט יש צורך להעביר את האקטיבציות והגרדיאנטים בין העובדים. היתרון הוא שאין צורך לשנות היפר-פרמטרים (כי האימון עצמו לא משתנה, רק דרך החישוב של הגרדיאנט), בניגוד למקבול נתונים. החסרון הוא שצריך תעבורת תקשורת בעל רוחב פס גדול כדי להעביר את האקטיבציות והגרדיאנטים בין העובדים. ספציפית, עבור  $K$  עובדים רוחב הפס הנדרש עבור התקשורת בין העובדים גדל פרופורציונלית ל- $K^2$ . בד"כ זה מגביל מאוד את מספר העובדים בו ניתן להשתמש.

ה. מכיוון שב-backpropagation, השכבות חייבות להיות מופעלות בצורה סידרתית, לא ניתן למקבל אותן בצורה מושלמת (הערה למתעניינים: קיימת אפשרות של pipelining). לכן, לא ניתן למקבל את כל הפרמטרים ברשת גם אם היה לנו את רוחב הפס המתאים.

ו. כפי שלמדנו, מיצוע של פרמטרים של כמה מודלים שונים יכול להגדיל משמעותית את השגיאה. שיטה אחרת, שלמדנו שהיא בד"כ עובדת טוב יותר, היא מיצוע של מוצאי הרשתות (ensemble). החיסרון העיקרי של שיטה זו הוא שאנחנו מגדילים את גודל המודל הסופי (בו נשתמש לאחר האימון).

## שאלה מס' 2

א. בסיווג לינארי על נתונים פרידים לינארית קיימים הרבה (למעשה, אינסוף) פתרונות עם שגיאה אפס. זה מתקיים גם בלמידה עמוקה. בשני המקרים, הפתרון שאליו נתכנס בסופו של תהליך האימון תלוי באלגוריתם האימון – זו ה"הטייה חבויה" של האלגוריתם לעבר פתרון מסוים. הבנה של הטייה זו יכולה לעזור להבין כיצד תכונות הפתרון (למשל ההכללה שלו) משתנה כתלות בבחירות שאנחנו עושים בתהליך האימון.

ב. הנתונים פרידים לינארית אם קיים וקטור מפריד  $\mathbf{w}_*$ , המקיים  $\mathbf{w}_*^T \mathbf{x}^{(n)} y^{(n)} > 0$  לכל  $n$ . ברגרסיה לוגיסטית אנחנו רוצים למזער את הסיכון האמפירי

$$\frac{1}{N} \sum_{n=1}^N \log(1 + \exp(-\mathbf{w}^T \mathbf{x}^{(n)} y^{(n)}))$$

ג. נשים לב כי פונקציית המחיר של רגרסיה לוגיסטית היא תלויה רק במכפלות  $\mathbf{x}^{(n)} y^{(n)}$ . לכן נוכל להגדיר מחדש את  $\mathbf{x}^{(n)} y^{(n)}$  בתור  $\mathbf{x}^{(n)}$ . כלומר, כל דוגמא  $\mathbf{x}^{(n)}$  עם תגית חיובית  $y^{(n)} = 1$  לא תשנה, וכל דוגמא  $\mathbf{x}^{(n)}$  עם תגית שלילית  $y^{(n)} = -1$  תעבור שיקוף ותהפוך לדוגמא  $-\mathbf{x}^{(n)}$  עם תגית חיובית  $y^{(n)} = 1$ . עבור רשתות נוירונים עמוקות, באופן כללי לא ניתן להניח זאת, מכיוון שפונקציית המחיר לא תלויה רק במכפלות  $\mathbf{x}^{(n)} y^{(n)}$ :

$$\frac{1}{N} \sum_{n=1}^N \log(1 + \exp(-f(\mathbf{w}, \mathbf{x}^{(n)}) y^{(n)}))$$

כאשר  $f(\mathbf{w}, \mathbf{x}^{(n)})$  מוצא הרשת. כדי שזה יתקיים, צריך לדרוש

$$f(\mathbf{w}, \mathbf{x}^{(n)}) = -f(\mathbf{w}, -\mathbf{x}^{(n)})$$

זה יתקיים למשל ברשת עמוקה ללא איברי היסט ועם פונקציית אקטיבציה אי-זוגיות, כמו למשל  $\tanh$ . בדומה למה שעשינו בכיתה.

$$\frac{d}{dt} \mathcal{L}(\mathbf{w}(t)) = \nabla \mathcal{L}(\mathbf{w}(t))^T \dot{\mathbf{w}}(t) = -\dot{\mathbf{w}}(t) \dot{\mathbf{w}}(t) = -\|\dot{\mathbf{w}}(t)\|^2 \leq 0$$

מכאן שפונקציית המחיר יורדת מונוטונית. מכיוון שפונקציית המחיר חסומה מלמטה (באפס), חייב להתקיים כי הזרימה  $\dot{\mathbf{w}}(t)$  שואפת לאפס.

ה. בדומה למה שעשינו בהרצאה, נבצע מכפלה סקאלרית של משוואה 2 עם איזושהו וקטור מפריד  $\mathbf{w}_*$ :

$$\mathbf{w}_*^T \dot{\mathbf{w}}(t) = \sum_{n=1}^N \mathbf{w}_*^T \mathbf{x}^{(n)} \exp(-\mathbf{w}(t)^T \mathbf{x}^{(n)})$$

מסעיף קודם, אגף שמאל של המשוואה שואף לאפס. בנוסף, מכיוון ש- $\mathbf{w}_*$  הוא וקטור מפריד,  $\mathbf{w}_*^T \mathbf{x}^{(n)} > 0$ . מכאן, חייב להתקיים ש- $\mathbf{w}(t)^T \mathbf{x}^{(n)}$  שואף לאינסוף עבור כל הדוגמאות. לכן, הנורמה של  $\mathbf{w}(t)$  שואפת גם לאינסוף, והשגיאה  $\mathcal{L}(\mathbf{w})$  מתכנסת לאפס.

ו. במקרה זה, משוואה (1) הופכת ל

$$\hat{\mathbf{w}} = \operatorname{argmin}_{\mathbf{w}} \|\mathbf{w}\|^2 \text{ s.t. } \forall n: \mathbf{w}^T \mathbf{x}^{(n)} = 1 \quad (3)$$

שימו לב שזהו פתרון הנורמה המינימלי, שקיבלנו עבור רגרסיה לינארית (במקרה של  $d > N$ ).

נרשום את הלגרנז'יאן של בעיה (3):

$$L(\mathbf{w}, \lambda) = \|\mathbf{w}\|^2 - \sum_n \lambda_n (\mathbf{w}^T \mathbf{x}^{(n)} - 1)$$

גזירה לפי המשקולות תיתן את תנאי הסטציונאריות:

$$\nabla_{\mathbf{w}} L(\mathbf{w}, \lambda) = 2\|\mathbf{w}\| - 2 \sum_n \lambda_n \mathbf{x}^{(n)} = 0 \Rightarrow \mathbf{w} = \sum_n \lambda_n \mathbf{x}^{(n)}$$

כלומר, הפתרון צריך להיות קומבינציה לינארית של הדוגמאות.  
גזירה לפי כופלי לגרנז' תיתן חזרה את האילוצים של הבעיה:

$$\nabla_{\lambda} L(\mathbf{w}, \lambda) = \mathbf{w}^T \mathbf{x}^{(n)} - 1 = 0 \Rightarrow \mathbf{w}^T \mathbf{x}^{(n)} = 1$$

ז. תחילה, תנאי הסטציונריות מתקיים כי

$$\begin{aligned} \lim_{t \rightarrow \infty} \frac{\mathbf{w}(t)}{\min_n \mathbf{w}^T(t) \mathbf{x}^{(n)}} &= \lim_{t \rightarrow \infty} \frac{\mathbf{w}(0) + \sum_{n=1}^N \mathbf{x}^{(n)} \int_0^t dt' \exp(-\mathbf{w}^T(t') \mathbf{x}^{(n)})}{\min_n \mathbf{w}^T(t) \mathbf{x}^{(n)}} \\ &= \lim_{t \rightarrow \infty} \frac{\mathbf{w}(0)}{\min_n \mathbf{w}^T(t) \mathbf{x}^{(n)}} + \lim_{t \rightarrow \infty} \sum_{n=1}^N \mathbf{x}^{(n)} \frac{\int_0^t dt' \exp(-\mathbf{w}^T(t') \mathbf{x}^{(n)})}{\min_n \mathbf{w}^T(t) \mathbf{x}^{(n)}} = \sum_{n=1}^N \mathbf{x}^{(n)} \lambda_n \end{aligned}$$

כאשר בשוויון האחרון השתמשנו בכך ש- $\min_n \mathbf{w}^T(t) \mathbf{x}^{(n)}$  שואף לאינסוף, והגדרנו

$$\lambda_n = \lim_{t \rightarrow \infty} \frac{\int_0^t dt' \exp(-\mathbf{w}^T(t') \mathbf{x}^{(n)})}{\min_n \mathbf{w}^T(t) \mathbf{x}^{(n)}}$$

מהנתון, עבור כל הדוגמאות,

$$\hat{\mathbf{w}}^T \mathbf{x}^{(n)} = 1$$

לכן התנאי השני מתקיים.

הראנו שהפתרון מקיים את שני התנאים ולכן הוכחנו את הטענה.

### שאלה מס' 3

א. בקוונטיזציה אחידה אנחנו מחליפים את הייצוג של כל משקל ב-32 ביט בייצוג עם דיוק נומרי נמוך. זה כמובן חוסך בזיכרון. אם גם האקטיבציות מיוצגות בדיוק נומרי נמוך, זה גם חוסך בפעולות חישוב, מכיוון שמכפלה בין שני מספרים בדיוק נומרי נמוך מצריך פחות פעולות חישוב.

בדילול חסר מבנה, אנו מאפסים חלק מהמשקולות ברשת. זה חוסך בזיכרון, אבל בד"כ לא חוסך בפעולות חישוב (אלא אם כן מדללים את הרשת מאוד).

בשיתוף משקולות עושים אשכול למשקולות ל-K משקולות ומחליפים כל משקל במרכזים של האשכול המתאים. זהו למעשה קוונטוט לא אחיד ל-K ערכים. זה חוסך בזיכרון, אך לא חוסך בפעילות חישוב.

ב. בקוונטיזציה סימטרית תחילה קובעים את צעד הקוונטוט:

$$\Delta = \text{round} \frac{2\max(|x|)}{2^{\text{nbits}}} \text{ to nearest power of 2}$$

בהינתן מספר ביטים nbits, מקוונטים ל-integer:

$$x_i^q = \begin{cases} 2^{\text{nbits}} - 1 & \frac{x_i}{\Delta} \geq 2^{\text{nbits}} - 1 \\ \text{round} \left( \frac{x_i}{\Delta} \right) & -2^{\text{nbits}} < \frac{x_i}{\Delta} < 2^{\text{nbits}} - 1 \\ -2^{\text{nbits}} & \frac{x_i}{\Delta} \leq -2^{\text{nbits}} \end{cases}$$

לבסוף, ממירים לערך הסופי על ידי מכפלה בגודל צעד  $x_i^d = \Delta \cdot x_i^q$ .

ברשת ReLU מוצא האקטיבציות הוא אי-שלילי, לכן שימוש בקוונטיזציה סימטרית יהיה מאוד בזבזני: לא יהיה שום צורך ברמות הקוונטוט של הצד השלילי, ולכן כמעט חצי מטווח הקוונטוט יתבזבז.

ג. ב-Knowledge Distillation אנו משתמשים ברשת גדולה ומאומנת במשימת סיווג ("מורה") לייצר תגיות הסתברותיות עבור אימון של רשת קטנה יותר ("סטודנט"). עבור הרשת הגדולה אנחנו מגדילים את הטמפרטורה של ה-softmax:

$$y_i(x|T) = \frac{e^{u_i(x)/T}}{\sum_j e^{u_j(x)/T}}$$

עבור טמפרטורה  $T > 1$ , ו-logits  $u_i(x)$  כדי להקטין את הבטחון של הרשת בתיוגים שלה (כי פעמים רבות רשתות מאומנות בטוחות מדי בתיוגים שלהם). לאחר מכן נאמן את הרשת הקטנה עם פונקציית המחיר הבאה:

$$\ell(x|T) = -T^2 \sum_i \hat{y}_i(x|T) \log y_i(x|T) - \sum_i \bar{y}_i \log y_i(x|1)$$

כאשר  $y_i(x|1)$  זה המוצא של הסטודנט,  $\bar{y}_i$  אלה התגיות האמיתיות, ו- $\hat{y}_i$  זה המוצא של המורה.

ד. תחילה ניקח רשת ונבצע אימון מלא שלה (ללא דילול של המשקולות). אח"כ נבצע דילול של המשקולות לפי סף: נזרוק כל משקולת מתחת לסף מסויים. גודל הסף נקבע לפי מספר המשקולות אותם רוצים לדלל. כתוצאה מהסף נקבל מסיכה של אפסים ואחדים, אותה נסמן ב- $\mathbf{M}_l$  עבור שכבת המשקולות ה-l. לאחר מכן נאמן את הרשת בצורה הבאה.

פעפוע קדמי:

$$\mathbf{W}_l^p = \mathbf{W}_l \circ \mathbf{M}_l$$

$$\mathbf{u}_l = \mathbf{W}_l^p \mathbf{v}_{l-1} + \mathbf{b}_l$$

$$\mathbf{v}_l = \varphi(\mathbf{u}_l)$$

פעפוע אחורי:

$$\mathbf{g}_{l-1} = \text{Diag}(\varphi'(\mathbf{u}_l)) (\mathbf{W}_l^p)^T \mathbf{g}_l$$

עדכון המשקולות:

$$\mathbf{W}_l^{(t+1)} = \mathbf{W}_l^{(t)} + \eta \mathbf{g}_l \mathbf{v}_{l-1}^T - \mu (\mathbf{1} - \mathbf{M}_l) \circ \mathbf{W}_l$$

כאשר  $\mathbf{W}_l$  הם משקולות חבויים לכל שכבה,  $\mathbf{W}_l^p$  הם המשקולות המדוללים,  $\varphi$  האקטיבציות בכל שכבה. בשלב העדכון אנו מעדכנים את  $\mathbf{W}_l$  ע"י התעלמות מהמסיכה שמכפילה אותו (קצת בדומה ל-STE), ומוסיפים Weight decay השואף לאפס כל משקל עבורו המסיכה מאופסת.