

למידה עצמית - 046211
בחינה סופית - מועד ב'

משך המבחן: 3 שעות

1. ניתן להשתמש בדפי נוסחאות ומחשבון.
2. יש לענות על כל השאלות.
3. משקל כל שאלה מצוין בטופס הבחינה. סך הנקודות הוא 100.
4. נא לכתוב בצורה ברורה ומסודרת.
5. יש לכלול פירוט מלא של דרך הפתרון. תשובות לא מנומקות לא יזכו בניקוד, אם לא נאמר אחרת.

ב ה צ ל ח ה !!!

שאלה מס' 1: למידה עם מעט תגיות (30%)

נתונה רשימה של סוגי למידה:

1. Semi-supervised Learning
2. Supervised Transfer Learning
3. Weakly-Supervised Learning
4. Metric Learning
5. Self-Supervised Contrastive Learning

לכל אחד מסוגי הלמידה ברשימה:

א. הסבירו איכותית במשפט או שניים מהו.

ב. תנו דוגמא למקרה בו נשתמש בסוג למידה זה (דוגמא שונה מזו שהצעתם לסוגי הלמידה האחרים).

ג. הציעו שיטה לבצע למידה שכזו (שיטה שונה מזו שהצעתם לסוגי הלמידה האחרים) ותארו אותה בצורה מפורטת (פונקציית המחיר, שלבי האלגוריתם, וכו'). הסבירו איכותית כיצד נשתמש בשיטה זו במשימה שרשמתם בסעיף ב'.

שאלה מס' 2: אינווריאנטות (40%)

בכיתה למדנו על סוגים של אינווריאנטות (סימטריות) ברשת עמוקה, בשאלה זו נראה עוד סוג של אינווריאנטה.

נתונה רשת שהשכבה הראשונה שלה היא fully-connected ללא היסט, מטריצת משקולות $\mathbf{W}$ בגודל $d \times d$, והפרמטרים של שאר השכבות שלה הם θ , כך שעבור כניסה $\mathbf{x}$ מוצא הרשת הוא $f(\mathbf{W}\mathbf{x}, \theta)$, עבור סט אימון מתויג $\{\mathbf{x}^{(n)}, \mathbf{y}^{(n)}\}_{n=1}^N$ נתון, ופונקציית הפסד ℓ , הסיכון האמפירי הוא

$$\mathcal{L}(\mathbf{W}, \theta) = \sum_{n=1}^N \ell(f(\mathbf{W}\mathbf{x}^{(n)}, \theta), \mathbf{y}^{(n)})$$

נתון כי כל משקל ברשת מאותחל לפי i.i.d. $N(0, \sigma_l^2)$, עם שונות σ_l^2 כפי שלמדנו בכיתה (מתאימה לכל שכבה l). כל פילוגי ההסתברות הם ביחס לאקראיות של המשקולות באתחול (אין אקראיות בסט האימון).

בשאלה זו נוכיח כי פילוג (הסתברות) מוצא הרשת $f(\mathbf{W}\mathbf{x}, \theta)$ לאחר אימון ב-GD לא ישתנה בעקבות הטרנספורמציה $\mathbf{x} \rightarrow \mathbf{U}\mathbf{x}$ עבור מטריצה אורתוגונלית ממשית $\mathbf{U}$ (כלומר $\mathbf{U}^T \mathbf{U} = \mathbf{U} \mathbf{U}^T = \mathbf{I}$) בגודל $d \times d$.

כמה שאלות כלליות לפני שנתחיל בהוכחה:

- א. מה משמעות האינווריאנטה החדשה? כיצד זה שונה מהאינווריאנטה שלמדנו, ברשתות קונוולוציה למשל? רמז: עבור אתחול נתון וכניסה $\mathbf{x}$, כיצד $f(\mathbf{W}\mathbf{x}, \theta)$ ישתנה עקב הטרנספורמציה $\mathbf{x} \rightarrow \mathbf{U}\mathbf{x}$?
- ב. מתי אינווריאנטה זו טובה להכללה? מתי לא?

כעת, נוכיח את הטענה באינדוקציה. תחילה, נראה את בסיס האינדוקציה

ג. הראו כי פילוג המשקולות באתחול לא ישתנה בעקבות הטרנספורמציה $(\mathbf{W}, \theta) \rightarrow (\mathbf{W}\mathbf{U}, \theta)$.

ד. הראו כי פילוג מוצא הרשת $f(\mathbf{W}\mathbf{x}, \theta)$ באתחול לא ישתנה בעקבות הטרנספורמציה $\mathbf{x} \rightarrow \mathbf{U}\mathbf{x}$.

כעת, בהנחה כי סעיפים ג' ו-ד' מתקיימים עבור איטרציה t של GD, נוכיח את צעד האינדוקציה לאחר צעד

$$(\mathbf{W}_{t+1}, \theta_{t+1}) = (\mathbf{W}_t, \theta_t) - \eta \nabla \mathcal{L}(\mathbf{W}_t, \theta_t) : (\eta \text{ גודל צעד})$$

ה. הראו כי הפילוג של θ_{t+1} הוא אותו הדבר עם הטרנספורמציה או בלעדיה.

ו. הראו כי $\nabla_{\mathbf{W}} \ell(f(\mathbf{W}\mathbf{U}\mathbf{x}, \theta), \mathbf{y}) = ([\nabla_{\mathbf{z}} \ell(f(\mathbf{z}, \theta), \mathbf{y})]_{\mathbf{z}=\mathbf{W}\mathbf{U}\mathbf{x}}) \mathbf{x}^T \mathbf{U}^T$.

ז. הראו כי הפילוג של $(\mathbf{W}_{t+1}, \theta_{t+1})$ עם הטרנספורמציה זהה לפילוג של $(\mathbf{W}_{t+1}, \theta_{t+1})$ ללא

הטרנספורמציה. הסבירו למה זה מסיים את ההוכחה.

שאלה מס' 3: למידה סידרתית ושכחה (30%)

בכיתה התמקדנו במקרה הרגיל של למידה מונחית, בו אנו רוצים למזער פונקציית מחיר על סט אימון נתון עם N דוגמאות מתויגות במימד d , שנשמך $\mathcal{D} = \{\mathbf{x}^{(n)}, y^{(n)}\}_{n=1}^N$. אז, ע"י אלגוריתם כמו SGD, אנחנו מוצאים את הפרמטרים $\mathbf{w}$ של חזאי $f(\mathbf{w}, \mathbf{x})$ ע"י מיזעור הסיכון האמפירי עם פונקציית הפסד נתונה ℓ

$$\mathcal{L}(\mathbf{w}) = \sum_{n=1}^N \ell(f(\mathbf{w}, \mathbf{x}^{(n)}), y^{(n)})$$

אבל, לעיתים, לא תמיד תהיה לנו גישה לסט האימון המלא, ונוכל לאמן כל פעם רק על חלק מסט האימון שנשמך ב- $S_k \subset \{1, \dots, N\}$, שמתקבל בצורה סידרתית $(k = 1, 2, \dots, K)$.

א. מתי מצב כזה זה יכול להתרחש בעולם האמיתי? תנו דוגמא.

תחילה נבחן את שיטת האימון הפשוטה ביותר, בה בכל שלב נאתחל את הפרמטרים במה שמצאנו בשלב הקודם, ואז, ע"י SGD, נמזער את הסיכון האמפירי על S_k :

$$\mathcal{L}_k(\mathbf{w}) = \sum_{n \in S_k} \ell(f(\mathbf{w}, \mathbf{x}^{(n)}), y^{(n)})$$

ב. אחת הבעיות העיקריות של שיטה זו היא "שכחה" של מה שהרשת למדה במשימות הקודמות. הסבירו במשפט את האינטואיציה למה זה קורה.

ג. כדי לפתור את בעיית השכחה יעל ורתי חשבו לאמן רשת נפרדת על כל חלק S_k . בזמן הבוחן, יעל הציעה להשתמש בממוצע של מוצאי הרשתות. לעומת זאת, הציעה רותי למצע את המשקולות של כל הרשתות כדי לקבל רשת בה נשתמש בזמן הבוחן. מה היתרונות והחסרונות של כל שיטה?

מכאן ואילך, לשם הפשטות, נתרכז בבעיית רגרסיה לינארית, כלומר חזאי לינארי $f(\mathbf{w}, \mathbf{x}) = \mathbf{w}^T \mathbf{x}$ עם פונקציית הפסד ריבועית $\ell(y, \hat{y}) = (y - \hat{y})^2$. הניחו כי $d < \frac{N}{K} = |S_k|$, $\text{Span}\{\mathbf{x}^{(n)}\}_{n \in S_k} = d$ וכי בכל חלק נאמן עם SGD עד שמגיעים למינימום על חלק זה.

ד. לאיזה פתרון נתכנס בסוף כל חלק (כפונקציה של סט האימון)? כתבו ביטוי אנליטי. הסבירו מדוע יש שכחה מוחלטת במקרה זה.

ה. כעת נוסיף רגולריזציה לאימון כל חלק S_k , כך שנמזער את

$$\mathcal{L}_k(\mathbf{w}) = \sum_{n \in S_k} (\mathbf{w}^T \mathbf{x}^{(n)} - y^{(n)})^2 + \lambda \|\mathbf{w} - \mathbf{w}_{k-1}\|^2$$

כאשר $\mathbf{w}_k$ הוא הפתרון על החלק S_k , ו- $\mathbf{w}_0 = \mathbf{0}$. לאיזה פתרון נתכנס בסוף כל חלק (כפונקציה של סט האימון, $\mathbf{w}_{k-1}$, ו- λ)? האם זה יכול לעזור למנוע שכחה? כיצד?