

למידה עמוקה - 046211

פתרון מועד ב'

פתרון שאלה מס' 1 (30%)

1. א. במקרה זה יש לנו הרבה דוגמאות: מעט עם תיוגים והרבה ללא תיוגים. נרצה להשתמש בכולן.
ב. למשל, נרצה לבצע sentiment analysis ולחזות מטקסט של ביקורת על סרט האם הביקורת חיובית או שלילית בעיתון מסוים. נניח שיש לנו מעט ביקורות מתויגות, אבל הרבה טקסט לא מתויג מאותו העיתון.
ג. נוכל למשל לאמן רשת עצבית מסוג Transformer לחזות מילים חסרות בטקסט מהעיתון כדי ליצור ייצוג טוב לסוג טקסט זה. לאחר מכן נוסיף שכבת סיווג ונאמן את כל הרשת על משימת סיווג הביקורות עם התגיות הנתונות.
2. א. למידה בה לומדים תחילה בצורה מונחית משימה אחת (מקור) ואז רוצים להשתמש בתוצאות למידה זו כדי לשפר למידה מונחית של משימה אחרת (מטרה).
ב. למשל, במשימה אחת נלמד רשת עמוקה לזהות סוגים של כלבים, ונרצה כעת ללמוד לזהות של סוגים של חתולים ע"י שימוש במאפיינים שלמדנו עבור כלבים (זיהוי אזניים, עיניים, אף, צבע...).
ג. נלמד תחילה רשת לזיהוי כלבים. כעת ניקח את אותה הרשת, נאתחל מחדש את השכבה האחרונה (של המסווג) ונמשיך לאמן אותה על המשימה החדשה של זיהוי חתולים.
3. א. זהו מקרה פרטי של למידה מונחית בו התגיות מאוד רועשות, כלומר לא מאוד אמינות.
ב. למשל, נניח שאנחנו רוצים לסווג בין דובים שחורים לדובים לבנים מתמונות, ויש לנו מעט תיוגים איכותיים של תמונות למחלקות אלה (כי אין לנו הרבה כסף לשלם לאנשים שיתייגו את התמונות). אבל יש המון תמונות מאינסטגרם שאנשים תייגו בתור @BrownBear או @WhiteBear. חלק גדול מהתמונות אלה יכולות להיות מתויגות בצורה לא נכונה.
ג. דוגמא לשיטה ללמידה במקרה זה היא ללמוד רשת עמוקה בצורה מונחית על התיוגים החלשים, ואז לאמן אותה קצת על מעט התיוגים האמינים שכן יש לנו (כמו ב-Transfer learning).
4. א. נרצה ללמוד ייצוג המתאים לדגימות של פונקציית מרחק על אוסף הנתונים, למשל

$$S(x_i, x_k) = \frac{f(x_i)^T f(x_k)}{\|f(x_i)\| \|f(x_k)\|} = \begin{cases} \text{high,} & x_i \text{ similar to } x_k \\ \text{low,} & \text{otherwise} \end{cases}$$

זו יכולה להיות המשימה עצמה, או שנשתמש במשימה זו כדי ללמוד ייצוג שיהיה טוב למשימות אחרות.

ב. למשל, נרצה ללמוד רשת המזהה האם פנים המופיעות בכרטיס תעודת זהות דומות לפנים של מי שמחזיק את הכרטיס.

ג. במקרה זה הנתונים יהיו אוסף של אנשים שונים, כאשר לכל איש יהיו כמה תמונות שונות של הפנים שלהם. נבנה רשת עמוקה המסתיימת בשכבת ייצוג ונאמן אותה עם פונקציית מחיר

$$-\sum_i \sum_{n \in A_i, m \in A_i} S(x_i^n, x_i^m) + \sum_{i \neq k} \sum_{n \in A_i, m \in A_k} S(x_i^n, x_k^m)$$

כאשר x_i^n מסמן את הייצוג של התמונה ה- n השייכת לאיש ה- i , ו- A_i את אוסף האינדקסים של התמונות השייכות לאיש ה- i .

5. א. זהו מקרה פרטי של metric learning, בו אנו רוצים למזער את המרחק בין דוגמאות הנוצרות מאוגמנטציות שונות של אותה דוגמא, ולמקסם את המרחק בין דוגמאות שונות.

ב. למשל, נרצה ללמוד לשפר את הסיווג של תמונות ב-CIFAR10 אבל עם מעט תגיות. אז נבצע למידה של הייצוג ולאחר מכן נלמד מסווג לינארי על גבי ייצוג זה.

ג. דוגמא לשיטה זו היא Noise-Contrastive Estimation:

$$\mathcal{L}_{\text{NCE}} \triangleq -\sum_{b \in B} (\mathbf{z}_b^A)^\top \mathbf{z}_b^B + \sum_{b \in B} \ln \sum_{b' \neq b} \exp((\mathbf{z}_b^A)^\top \mathbf{z}_{b'}^B)$$

כאשר $\mathbf{z}_b^A$ הוא הייצוג המנורמל של הדוגמא ה- b במיני-באטצ', אחרי אוגמנטרציה A . הבעיה עם שיטה זו היא שצריכים מיני-באטצ'ים גדולים כדי שהיא תעבוד, מה שמאט את האימון.

- א. הסימטריה החדשה אומרת שהכפלה של הכניסה ב- $\mathbf{U}$ לא משנה את ההסתברות שנקבל חזאי מסויים, לאחר אתחול אקראי ואימון ב-GD, כלומר אלגוריתם הלימוד שלנו הוא אינוואריאנטי לטרנספורמציה. זה שונה מהאינוואריאנט שלמדנו ברשתות קונבולוציה, שם החזאי עצמו אינוואריאנטי (להזות). במקרה שלנו החזאי אינו אינוואריאנטי לטרנספורמציה, כפי שנרמז.
- ב. הסימטריה הזו טובה להכללה אם הפעולה $\mathbf{x} \rightarrow \mathbf{Ux}$ לא משנה את התגית (כי אז החזאי לא אמור להיות תלוי בטרנספורמציה). אחרת, הסימטריה הזו מיותרת, ויכולה לפגוע בהכללה.
- ג. לפני הטרנספורמציה, פילוג המשקולות בשכבה הראשונה הוא i.i.d. $N(0, \sigma_1^2)$. טרנספורמציה לינארית תשאיר את הפילוג גאوسي, ולא תשנה את הממוצע. נשאר רק להראות כי מטריצת הקווארינס לא משתנה. תחילה, קל לראות כי טרנספורמציה זו לא תשנה את העובדה שהמשקולות בכניסה של נירון $\mathbf{w}_i = \mathbf{W}[i, :]$ הן בלתי תלויות בין שני נירונים שונים, כלומר

$$\begin{aligned} \forall i \neq j: E[\mathbf{w}_i^T \mathbf{U} \mathbf{U}^T \mathbf{w}_j] &= E \left[\sum_{k,r,p} \mathbf{w}_i[k] \mathbf{U}[k,r] \mathbf{U}[p,r] \mathbf{w}_j[p] \right] \\ &= \sum_{k,r,p} \mathbf{U}[k,r] \mathbf{U}[p,r] E[\mathbf{w}_i[k] \mathbf{w}_j[p]] = \sum_{k,r,p} \mathbf{U}[k,r] \mathbf{U}[p,r] \cdot \mathbf{0} = \mathbf{0} = E[\mathbf{w}_i^T \mathbf{w}_j] \end{aligned}$$

בנוסף, מכיוון ש- $\mathbf{U} \mathbf{U}^T = \mathbf{I}$ הקוואריאנס נשמר גם בין הרכיבים של $\mathbf{w}_i$:

$$E[\mathbf{w}_i^T \mathbf{U} \mathbf{U}^T \mathbf{w}_i] = E[\mathbf{w}_i^T \mathbf{w}_i]$$

פילוג המשקולות θ בשאר השכבות לא מושפע.

- ד. מוצא הרשת לפני הטרנספורמציה $f(\mathbf{Wx}, \theta)$ ואחרי הטרנספורמציה $f(\mathbf{WUx}, \theta)$. מסעיף קודם, נובע שהפילוג של $(\mathbf{W}, \theta)$ ו- $(\mathbf{WU}, \theta)$ זהה. לכן גם הפילוג של $f(\mathbf{Wx}, \theta)$ ו- $f(\mathbf{WUx}, \theta)$ זהה.
- ה. לפני הטרנספורמציה, לאחר צעד גרדיאנט אחד עם גודל צעד η , מתקיים עבור θ :

$$(1) \quad \theta_{t+1} = \theta_t - \eta \nabla_{\theta} \left(\sum_{n=1}^N \ell(f(\mathbf{W}_t \mathbf{x}^{(n)}, \theta), \mathbf{y}^{(n)}) \right)_{(\theta=\theta_t)}$$

לאחר הטרנספורמציה, לאחר צעד גרדיאנט אחד עם גודל צעד η , מתקיים עבור θ :

$$(2) \quad \theta_{t+1} = \theta_t - \eta \nabla_{\theta} \left(\sum_{n=1}^N \ell(f(\mathbf{W}_t \mathbf{U} \mathbf{x}^{(n)}, \theta), \mathbf{y}^{(n)}) \right)_{(\theta=\theta_t)}$$

מהסעיפים הקודמים, הפילוג של $f(\mathbf{W}_t \mathbf{U} \mathbf{x}^{(n)}, \theta)$ זהה לפילוג של $f(\mathbf{W}_t \mathbf{x}^{(n)}, \theta)$. מכאן גם הפילוג של θ_{t+1} בשתי המשוואות למעלה זהה, כלומר הוא לא משתנה עקב הטרנספורמציה.

ו. נגזור לפי רכיב אחד של המטריצה, ונשתמש בכלל השרשרת:

$$\nabla_{\mathbf{W}[i,j]} \ell(f(\mathbf{WUx}, \theta), \mathbf{y}) = ([\nabla_{\mathbf{z}} \ell(f(\mathbf{z}, \theta), \mathbf{y})]_{\mathbf{z}=\mathbf{WUx}})_i \sum_k \mathbf{U}[j,k] \mathbf{x}[k]$$

אם נכתוב זאת בצורה מטריצית נקבל את הפתרון הנדרש:

$$\nabla_{\mathbf{W}} \ell(f(\mathbf{WUx}, \theta), \mathbf{y}) = ([\nabla_{\mathbf{z}} \ell(f(\mathbf{z}, \theta), \mathbf{y})]_{\mathbf{z}=\mathbf{WUx}}) \mathbf{x}^T \mathbf{U}^T.$$

ז. עבור $\mathbf{W}$, לפני הטרנספורמציה:

$$\mathbf{w}_{t+1} = \mathbf{w}_t - \eta \nabla_{\mathbf{w}} \left(\sum_{n=1}^N \ell(f(\mathbf{Wx}^{(n)}, \theta_t), \mathbf{y}^{(n)}) \right)_{(\mathbf{w}=\mathbf{w}_t)}$$

$$(3) \quad \mathbf{w}_{t+1} = \mathbf{w}_t - \eta \left(\sum_{n=1}^N [\nabla_{\mathbf{z}} \ell(f(\mathbf{z}, \theta_t), \mathbf{y}^{(n)})]_{\mathbf{z}=\mathbf{w}_t \mathbf{x}^{(n)}} (\mathbf{x}^{(n)})^T \right)$$

ואחרי הטרנספורמציה:

$$\mathbf{w}_{t+1} \mathbf{U} = \mathbf{w}_t \mathbf{U} - \eta \nabla_{\mathbf{w}} \left(\sum_{n=1}^N \ell(f(\mathbf{WUx}^{(n)}, \theta_t), \mathbf{y}^{(n)}) \right)_{(\mathbf{w}=\mathbf{w}_t)} \mathbf{U}$$

$$= \mathbf{w}_t \mathbf{U} - \eta \left(\sum_{n=1}^N [\nabla_{\mathbf{z}} \ell(f(\mathbf{z}, \boldsymbol{\theta}_t), \mathbf{y}^{(n)})]_{\mathbf{z}=\mathbf{w}_t \mathbf{U} \mathbf{x}^{(n)}} (\mathbf{x}^{(n)})^T \right) \mathbf{U}^T \mathbf{U}$$

$$(4) \quad \mathbf{w}_{t+1} \mathbf{U} = \mathbf{w}_t \mathbf{U} - \eta \left(\sum_{n=1}^N [\nabla_{\mathbf{z}} \ell(f(\mathbf{z}, \boldsymbol{\theta}_t), \mathbf{y}^{(n)})]_{\mathbf{z}=\mathbf{w}_t \mathbf{U} \mathbf{x}^{(n)}} (\mathbf{x}^{(n)})^T \right)$$

מכיוון שהפילוג של $(\mathbf{w}_t \mathbf{U}, \boldsymbol{\theta}_t)$ אחרי הטרנספורמציה זהה לפילוג של $(\mathbf{w}_t, \boldsymbol{\theta}_t)$ לפני הטרנספורמציה, הפילוג של $(\mathbf{w}_{t+1}, \boldsymbol{\theta}_{t+1})$ במשוואות (1+3), לפני הטרנספורמציה, זהה לפילוג של $(\mathbf{w}_{t+1} \mathbf{U}, \boldsymbol{\theta}_{t+1})$ במשוואות (2+4), אחרי הטרנספורמציה. מכאן הפילוג של $f(\mathbf{w}_{t+1} \mathbf{x}, \boldsymbol{\theta}_{t+1})$ נשאר זהה לפילוג של $f(\mathbf{w}_{t+1} \mathbf{U} \mathbf{x}, \boldsymbol{\theta}_{t+1})$.

שאלה מס' 3

- א. זה יכול לקרות למשל כאשר קיבלנו מודל, ואנחנו רוצים לאמן אותו לבצע גם משימה חדשה, אבל אין לנו גישה לסט האימון המקורי שעליו התאמן המודל. זה יכול לקרות מכל מיני סיבות, למשל, הורדנו את המודל מהאינטרנט (github), אבל אין לנו גישה לסט האימון שלו. יכול להיות גם שהסט האימון לא זמין מסיבות של פרטיות או זכויות יוצרים.
- ב. כאשר לומדים משימה חדשה, העדכונים של SGD לא מודעים כלל למשימה הקודמת, ויכולים לשנות את המשקולות ברשת בצורה שתהרוס את הביצועים שלה על המשימה הקודמת.
- ג. שתי השיטות כנראה יפגעו בביצועים לעומת רשת אחת שאומנה על כל סט האימון, אבל כפי שלמדנו, מיצוע של מוצאי הרשתות בד"כ עובד הרבה יותר טוב מאשר מיצוע של המשקולות. מצד שני השיטה של מיצוע מוצאי הרשתות הרבה יותר כבדה, כי צריך לשמור K רשתות שונות בזמן הבוחן.
- ד. כפי שלמדנו בכיתה, בסוף כל חלק נקבל את הפתרון של רגרסיה לינארית

$$\mathbf{w}_k = (\mathbf{X}_k^T \mathbf{X}_k)^{-1} \mathbf{X}_k^T \mathbf{y}_k$$

כאשר

$$\mathbf{y}_k = [y^{(n)}]_{n \in S_k}, \quad \mathbf{X}_k = [\mathbf{x}^{(n)}]_{n \in S_k}^T$$

- במקרה זה יש שכחה מוחלטת, מכיוון שהפתרון בסוף כל חלק לא תלוי כלל בנתונים ממשיות קודמות.
- ה. נבצע חילוף משתנים: $\tilde{\mathbf{w}} = \mathbf{w} - \mathbf{w}_{k-1}$, ופונקציית המחיר תראה כך:

$$\mathcal{L}_k(\tilde{\mathbf{w}}) = \sum_{n \in S_k} \left(\tilde{\mathbf{w}}^T \mathbf{x} - (y^{(n)} - \mathbf{w}_{k-1}^T \mathbf{x}) \right)^2 + \lambda \|\tilde{\mathbf{w}}\|^2$$

כפי שלמדנו בכיתה, זו בעיית רגרסיה לינארית עם רגולריזציה L_2 :

$$\tilde{\mathbf{w}}_k = (\mathbf{X}_k^T \mathbf{X}_k + \lambda \mathbf{I})^{-1} \mathbf{X}_k^T (\mathbf{y}_k - \mathbf{X}_k \mathbf{w}_{k-1})$$

כאשר, כמקודם

$$\mathbf{y}_k = [y^{(n)}]_{n \in S_k}, \quad \mathbf{X}_k = [\mathbf{x}^{(n)}]_{n \in S_k}^T$$

מכאן,

$$\mathbf{w}_k = (\mathbf{X}_k^T \mathbf{X}_k + \lambda \mathbf{I})^{-1} \mathbf{X}_k^T (\mathbf{y}_k - \mathbf{X}_k \mathbf{w}_{k-1}) + \mathbf{w}_{k-1}$$

פתרון זה תלוי במידע מהחלק הקודם $\mathbf{w}_{k-1}$, בניגוד לפתרון הקודם ולכן לא חייבת להיות שכחה מוחלטת. אינטואיטיבית, רגולריזציה זו מעודדת את הפתרון להישאר קרוב לפתרון הקודם, ויכולה לעזור למנוע שכחה.